

智能数据准备研究综述

关键技术、流程优化与评测方法

范举 范梅浩

中国人民大学信息学院，数据工程与知识工程教育部重点实验室
北京 100872

摘 要：数据准备通过数据发现、语义理解、清洗修复、匹配融合、结构转换和标注增强，将异构原始数据转化为满足下游任务要求的数据资源，是数据分析与机器学习的重要基础。近年来，预训练语言模型和大语言模型的发展拓展了数据准备的语义处理能力，研究对象也由单项操作逐步延伸至任务感知的流程生成与执行优化。然而，现有方法在监督条件、目标表达、操作空间及验证方式方面存在明显差异，单项任务的性能提升尚不能直接说明完整流程的可靠性。本文围绕国内外代表性研究，建立任务类型、技术机制与流程能力相结合的分类框架，梳理规则约束、统计学习、多任务匹配、知识增强及智能体规划等技术，比较其输入条件、适用范围与主要局限。进一步从局部处理质量、流程正确性、下游效用和综合成本四个层次分析评测方法，并讨论任务语义约束、跨域适应、执行验证与持续维护等开放问题。文献分析表明，智能数据准备的发展需要将语言模型的语义推断能力与数据系统的确定性执行、可追溯状态及任务相关验证相结合，以提高复杂数据处理流程的可用性与可检验性。

关键词：数据准备；数据清洗；数据集成；大语言模型；程序合成；数据质量

1 引言

数据分析和机器学习通常以结构、语义和质量满足要求的数据为前提，而实际数据往往分散于异构数据源，并伴随字段含义不明确、值表示不一致、实体重复及记录缺失等问题。数据准备研究面向这些问题，连接原始数据与下游任务，其处理对象既包括数据值，也包括数据模式、跨源对应关系和可执行变换流程。Chai 等对人工智能辅助数据准备的讨论，以及面向机器学习的数据管理综述，均将数据准备视为数据系统与学习方法交叉的重要研究环节。^[1, 2] 从数据质量角度看，处理结果的准确性、完整性和一致性需要结合使用情境评价，统一格式或消除异常并不足以保证数据适合目标任务。^[3, 4]

该领域已经形成多条相互关联的技术路线。交互式工具利用用户示例与规则降低变换表达成本；统计学习方法根据数据分布和完整性约束进行检测与修复；预训练模型通过共享表示支持语义类型识别和实体匹配；大语言模型则进一步支持自然语言需求解释及代码生成。^[5-9] 这些方法并非简单的替代关系。学习模型有助于处理规则难以完整描述的语义问题，数据库算子和显式约束则为批量执行、错误定位和结果验证提供基础。如何把单项模型组织为可执行、可验证且成本可控的准备流程，是当前研究的重要问题。

国内学者在上述方向开展了持续研究。范举及其合作者围绕统一匹配模型、人工与自动流程组合、问题感知的数据准备和执行反馈驱动的智能体展开探索，相关工作包括 Unicorn、HAIPipe、AutoPrep 和 DeepPrep。^[10-13] 李国良及其合作者在交互式确定性清洗、面向机器学习的数据管理、低成本实体匹配及自然语言数据准备评测等方面形成了相互衔接的研究。^[2, 14-16] 高云君及其合作者则从数据集成技术出发，进一步研究数据准备模型的知识增强与迁移、自然语言流程表达和无目标实例的流程搜索。^[17-20] 上述工作包含跨团队合作，本文依据技术问题组织国内外文献，并与 Aurum、Raha、Snorkel 等代表性方法进行对照。^[21-23]

1.1 文献范围与组织方法

本文采用围绕技术问题的代表性文献梳理方法，以数据准备及其关键子任务为范围，检索截止日期为 2026 年 9 月 9 日。文献线索来自学术出版平台、作者公开论文页面及 arXiv，使用 Crossref 核验可获取的 DOI 元数据，并通过中文期刊官网补充中文综述。检索词包括 data preparation、data cleaning、entity matching、pipeline synthesis 及其中文对应词，同时结合范举、李国良、高云君等学者的相关论文开展引文追溯。选文重点是具有明确任务定义、技术机制或评测设计的研究，保留必要的早期基础文献，并关注 2023 年以来的语言模型与流程自动化工作。正式发表版本优先；对仅据预印本讨论的工作标明版本，不将其与正式出版记录混合使用。本文不进行穷尽式文献计量或跨基准元分析，也不以发表数量或引用次数评价研究团队。

讨论对象以关系表、异构记录及其相关元数据为主，并延伸至机器学习训练数据的标注、样本选择和语料处理。文档与半结构化内容仅在其参与数据理解、转换或集成时纳入讨论。数据库性能调优、通用问答和模型结构设计不作为独立综述主题。这一范围使数据准备的技术问题能够与具体输入、处理操作和输出要求建立对应关系。

1.2 已有综述与本文定位

已有综述分别从数据管理、数据质量、数据集成和语言模型应用等角度组织该领域。高云君等以关系型数据和知识图谱为对象，分析实体解析、融合与清洗技术；Chai 等从机器学习生命周期讨论数据发现、清洗和标注；Chen 等则按获取、集成、清洗与转换梳理语言模型辅助的表格数据准备。^[2, 17, 24] Zhou 等近期预印本关注大语言模型支持的应用就绪数据准备，Liang 等从大模型训练阶段讨论训练数据的准备流程。^[25, 26] 二者分别强调使用语言模型准备数据和为语言模型准备数据，研究目标有所区别。

近期中文综述也提供了较明确的论述组织方式。刘祺等从概念内涵、理论与方法等层面梳理数据质量研究；周立等先界定不完整时序数据补全问题，再分类比较方法并分析评测设置。^[4, 27] 本文借鉴其概念界定、分类比较与问题归纳的组织方式，重点讨论不同准备操作如何在下游任务约束下形成完整流程。表1给出相关综述的范围差异。本文的主要工作是建立任务与机制相结合的分类框架，比较代表方法的监督条件和验证边界，并将评测视角从单项操作扩展到流程、下游任务和维护成本。

表 1 相关综述的研究范围与本文关注点

文献	年份	主要研究范围	与本文的关系
高云君等 ^[17]	2023	关系数据与知识图谱的集成	提供匹配、融合与清洗的技术基础
Chai 等 ^[2]	2023	机器学习全生命周期的数据管理	说明准备操作与学习任务的关系
刘祺等 ^[4]	2025	数据质量的理论、方法与应用	提供质量概念与研究体系参照
周立等 ^[27]	2025	深度学习时序数据补全	提供任务分类和评测组织参照
Chen 等 ^[24]	2026	语言模型辅助表格数据准备	讨论语言模型与各类准备任务的适配
Zhou 等 ^[25]	2026*	大语言模型辅助应用就绪数据准备	讨论清洗、集成与增强的机制
Liang 等 ^[26]	2026	大模型训练数据准备	对照不同训练阶段的数据需求
本文	—	智能数据准备的任务、机制与流程	强调输入条件、流程验证及评测边界

注：* 表示本文引用的版本为预印本；表中范围为研究侧重点，不表示各综述完全不涉及其他内容。

2 问题定义与分类框架

2.1 任务定义与输出要求

为比较不同研究, 本文将数据准备任务抽象为三元组 $(\mathcal{D}, q, \mathcal{C})$ 。其中, $\mathcal{D}$ 为可访问的原始数据及其元数据集合, q 为下游问题、目标模式或学习任务描述, $\mathcal{C}$ 为类型、完整性、资源预算和访问范围等约束。给定算子集合 $\mathcal{O}$, 数据准备需要构造流程 P , 使其执行结果 $D' = P(\mathcal{D})$ 满足目标要求。 P 可以是操作序列, 也可以是支持多表输入的有向无环图; 算子包括选择、连接、聚合、类型转换、匹配、修复和标注等。这里的形式化描述用于统一讨论, 不意味着现有方法均显式表示所有约束。

若将任务效用与处理成本同时考虑, 可用下式概括准备流程的选择目标:

$$\max_{P \in \mathcal{P}(\mathcal{O})} U_q(P(\mathcal{D})), \quad \text{s.t.} \quad P(\mathcal{D}) \models \mathcal{C}_{\text{hard}}, \quad C_{\text{exec}}(P) \leq B_e, \quad C_{\text{human}}(P) \leq B_h. \quad (1)$$

其中, $\mathcal{P}(\mathcal{O})$ 为可构造的流程空间, U_q 表示任务相关效用, $\mathcal{C}_{\text{hard}}$ 为必须满足的约束, C_{exec} 和 C_{human} 分别表示执行与人工投入成本, B_e 和 B_h 为相应预算。在实际研究中, U_q 可以对应目标表正确性或验证集上的预测性能, 而无法直接观测的真实性通常需要通过规则、参考数据及人工检查间接验证。因此, 该表达式是一种分析框架, 而不是本文提出并验证的优化算法。

不同任务对输入监督的要求差异较大。有的方法假设提供匹配标签或正确值, 有的方法需要用户示例、已有流程或目标模式, 也有的方法仅利用自然语言描述和执行状态开展搜索。这些条件决定了系统需要自行推断的信息范围。比较方法时, 应同时说明它获得了哪些目标信息, 以及哪些正确性标准仅由评测器掌握, 避免把更强的输入监督误认为更强的自动化能力。

2.2 任务类型、技术机制与流程能力

按处理对象与预期输出, 本文将关键任务归纳为六类: 数据发现输出相关数据源及候选关联; 语义理解输出字段类型与模式对应; 清洗修复输出错误标记或候选修复值; 匹配融合输出对象对应关系及整合记录; 结构转换输出满足目标模式的数据; 标注增强输出训练标签、派生信息或任务相关样本。这些类别具有交叉关系, 例如模式匹配既依赖语义理解, 也为数据集成提供输入; 标注既是准备目标, 也可能成为匹配模型的监督信号。分类意在明确主要技术问题, 而非强制规定处理顺序。

从实现机制看, 可以区分显式规则与程序搜索、统计与深度学习、语言模型语义推断, 以及结合外部工具的流程规划。同一任务可以由不同机制解决, 同一系统也可能组合多种机制。例如, 实体匹配可以采用监督分类、上下文学习或多任务表示, 而结构转换既可以由示例驱动, 也可以通过目标模式搜索或自然语言代码生成完成。图1展示任务类型与支撑机制之间的总体关系。

从流程能力看, 单项预测、固定流程执行、任务感知规划与基于反馈的流程修订应分别考察。多任务模型能够覆盖多类输入, 并不意味着其具备自动确定操作顺序的能力; 流程可以成功执行, 也不意味着它符合用户的业务语义。数据准备的完整输出因而可以分为目标数据、可执行流程和验证记录三个层次。其中, 来源说明和变换记录有助于复现处理过程, 但其存在本身并不能证明结果正确。^[28, 29]

3 智能数据准备的关键技术

3.1 数据发现与语义理解

数据发现需要从大量异构资源中定位与任务相关的数据源, 并识别潜在的可连接或可合并关系。Aurum 通过数据关系表示及声明式发现操作支持跨源检索, 体现了以索引和关系组织降低数据




图1 智能数据准备的任务体系。六类任务可根据下游目标组合，规则约束、统计学习、语言模型与流程规划构成可互补的实现机制。图为本文对相关研究的综合归纳，非特定系统架构。

定位成本的思路。^[21] 这类系统主要回答数据位于何处以及可能存在何种关系；候选关联是否满足当前任务的语义要求，仍需要进一步的模式与内容分析。因此，发现阶段的召回率、候选规模和后续验证成本应共同考虑。

语义理解进一步处理列名、值域及表内上下文之间的对应关系。Sato 结合列值特征、表级主题和结构化预测识别列语义类型，说明字段含义不能仅由孤立单元格或表头确定。^[7] 与之相比，语言模型能够联合利用自然语言说明、样例值和外部知识，但其输出仍可能受字段命名、序列化方式和上下文截断影响。^[9, 24] 对涉及单位、编码和统计粒度的字段，语义相近不应直接作为可替换或可连接的充分条件。

Unicorn 将包括模式匹配、列类型标注和实体匹配在内的多个匹配任务统一到共享表示与判别框架中，并通过专家混合机制处理任务语义差异。^[10] 它将知识共享的范围由单一数据集扩展至多类匹配问题，为准备组件复用提供了路径。不过，多任务共享的有效性仍取决于任务相关程度、训练覆盖及输入表示，不能据此假设任意新模式均能直接对齐。从系统角度看，语义模型更适合生成带有依据和置信信息的候选映射，再结合模式约束进行筛选。

3.2 错误检测、数据修复与缺失补全

数据清洗首先需要区分错误检测与错误修复。检测回答哪些值或记录不满足预期，修复则需要进一步决定如何修改。HoloClean 综合完整性约束、统计关系和参考信息，以概率推断选择修复结果。^[6] 其优势在于同时利用多种证据，但修复质量仍受候选值覆盖、约束准确性与数据相关结构影响。约束被满足只能说明一组逻辑条件成立，不足以单独保证所有值均恢复为真实记录。

Raha 将多种检测策略的输出转化为特征，并利用聚类、抽样及用户标注减少手工配置成本。^[22] 它弱化了用户逐项设置检测规则和参数的负担，但仍需要一定的人工监督。He、Li 等提出的 Falcon

则从用户给出的修复出发, 搜索并确认可推广的 SQL 更新规则, 将人工反馈用于确定性清洗。^[14] 两类方法分别侧重减少检测配置和复用修复知识, 说明人在回路的主要作用可以是选择有价值的监督, 而非逐条完成全部处理。

语言模型为错误解释和候选值生成提供了新的实现方式。Narayan 等探索通过基础模型统一表达多类数据整理任务; Jellyfish 进一步利用面向数据预处理的指令微调, 支持错误检测、缺失补全、模式匹配和实体匹配。^[9, 30] 其可本地部署的模型形态有利于复用任务能力, 但自然语言解释不构成事实依据。对于原始数据中不可观测的信息, 应区分基于记录证据的纠错与基于统计或模型知识的估计, 并保留估计值的来源及不确定性。

缺失补全还受到缺失机制和数据结构的影响。周立等的综述将缺失场景、缺失率、变量数量、序列长度及下游效果纳入评讨论, 表明方法比较需要控制数据缺失的形成条件。^[27] 这一要求同样适用于一般表格: 在随机遮蔽数据上的较小重构误差, 并不能直接说明方法适用于与业务过程相关的系统性缺失。不同补全结果还可能改变变量关系和样本分布, 因此应同时检查局部数值误差与后续分析的稳定性。

3.3 实体匹配与多源融合

实体匹配判断不同来源的记录是否指向同一对象, 多源融合则进一步处理同一对象的属性冲突、来源差异和表示统一问题。高云君等对关系数据与知识图谱集成的梳理表明, 实体解析、融合和清洗之间存在紧密联系。^[17] 匹配错误会把不同对象合并, 融合规则则可能在对应关系正确的前提下选取错误值, 因此两个阶段需要分别验证。此外, 候选对生成的遗漏会限制后续匹配的召回率, 不能只评价分类器在已筛选候选对上的性能。

Ditto 将实体匹配转化为预训练语言模型上的序列对分类, 并结合领域知识、文本摘要和数据增强改善输入表达。^[8] 该路线通过有监督微调获得较强的任务适配能力, 但跨领域应用仍涉及标注与训练成本。Unicorn 侧重跨匹配任务共享表示, 关注的是复用范围; 二者解决的问题有所重叠, 监督组织方式和泛化目标则并不相同。^[10]

Fan 等提出 BATCHER, 从示例选择和问题分批两个方面研究实体解析中的上下文学习成本。^[15] 其覆盖式示例选择与批量提示使多个待匹配问题共享上下文, 有助于在匹配质量和模型调用开销之间选择合适配置。这一思路将示例组织本身视为优化对象, 但仍依赖示例标签质量以及批内信息的可区分性。因此, 使用语言模型代替人工产生示例标签时, 需要把标签错误传播计入评估, 而不能只统计调用次数的减少。

从匹配到融合, 还需要引入来源可信度、时间有效性和字段级一致性等信息。将所有冲突统一为多数投票会忽略来源之间的依赖, 也可能覆盖更新的有效记录。已有集成研究提供了冲突分析的基础; 在语言模型参与的流程中, 保留候选值、来源及采用规则, 是使后续融合决定可以复查的重要条件。^[3, 17]

3.4 结构转换与程序合成

结构转换处理嵌套表头、宽窄表变换、字段拆分、类型转换及列派生等问题, 其输出通常需要满足关系结构或下游程序的输入要求。Wrangler 通过交互式示范和变换建议生成处理脚本, 使用户能够在数据预览中逐步确定操作。^[5] 其价值在于降低表达门槛并保留可重复执行的脚本, 而转换目标和关键操作仍主要由用户指定。

Auto-Tables 面向非规范表格的关系化处理, 通过合成多步变换恢复适合分析的结构, 且不求用户提供转换后的示例表。^[31] 其模型利用行列方向的特征预测算子及参数, 并通过束搜索保留多

个候选流程。这一路线将变换预测与受限搜索结合, 说明自动转换并不必然依赖自然语言指令。但目标结构的合理性与目标业务语义仍是不同问题: 获得规范关系表后, 还需要检查值的单位、聚合粒度和跨表对应关系。

语言模型代码生成扩大了可表达变换的范围, 同时也使验证问题更加突出。受控算子便于检查类型、参数和前置条件, 自由代码则能够表达复杂清洗逻辑, 但可能引入难以静态分析的行为。AutoPrep 与 BAT 分别通过逻辑操作分解和操作沙箱约束流程构造。^[12, 20] 对数据准备而言, 二者之间的取舍取决于目标任务是否需要开放式语义转换, 以及系统能否为扩展代码提供独立验证。

3.5 数据标注、样本选择与训练数据准备

面向机器学习的数据准备还需要构造监督信号并确定训练样本。Snorkel 允许用户以标注函数表达领域启发式, 并对含噪、冲突的弱监督输出进行建模, 减少逐样本标注需求。^[23] 这种方法将人工劳动由重复标签判定转移到标注知识的组织, 但仍受规则覆盖和噪声建模条件限制。对语言模型生成的标签也应采用类似的分析方式, 区分标签来源、错误相关性和下游效用。

样本选择与数据修复可以联合考虑。ActiveClean 针对凸损失模型, 在逐步清洗数据的过程中更新模型, 并优先处理可能影响训练结果的记录。^[32] GoodCore 进一步研究不完整数据上的核心子集选择, 将数据补全与梯度近似联系起来, 以兼顾训练质量、训练效率和人工补全成本。^[33] 两者均体现了任务驱动的数据准备思想, 但各自的模型假设和优化目标限制了结论的适用范围, 不能直接推广到任意学习模型。

对于大模型训练语料, 去重、过滤、来源管理与数据配比需要在不同训练阶段共同设计。DataJuicer 将数据分析和处理算子组织为可组合的系统, 支持处理配方的调整与比较; Liang 等的综述则区分预训练、持续预训练和后训练的数据需求。^[26, 34] 这里的评价对象是语料对模型训练的贡献, 与利用大语言模型执行表格清洗的评价对象不同。处理规模、内容覆盖及下游性能应结合讨论, 单一过滤分数难以完整表示训练数据价值。

3.6 关键技术的比较

表2从所需监督、核心机制与适用边界比较代表方法。规则和统计方法具有较明确的执行或推断条件, 语言模型方法扩大了语义处理范围, 但往往引入提示、示例选择和模型版本等新的敏感因素。监督需求也没有随模型规模增加而消失, 而是由实例标签转移到任务说明、提示示例、知识资源或验证规则。因此, 方法选择需要同时考虑错误类型、可用监督和维护成本, 不能仅依据模型是否采用大语言模型划分优劣。

表 2 代表性数据准备组件的技术比较

方法	主要任务	所需信息与核心机制	适用边界或比较注意点
Aurum ^[21]	数据发现	数据关系及发现查询	候选关系仍需任务语义验证
Sato ^[7]	列语义类型	类型标签、列值与表上下文	受类型集合及训练覆盖影响
HoloClean ^[6]	数据修复	约束、统计及参考信息的概率融合	依赖候选修复与约束质量
Raha ^[22]	错误检测	检测策略特征及少量用户标注	降低配置需求, 仍需监督
Falcon ^[14]	确定性清洗	用户修复与 SQL 规则确认	规则的推广范围需人工核验
Ditto ^[8]	实体匹配	标注记录对与预训练模型微调	关注域内质量及跨域标注成本
Unicorn ^[10]	多类匹配	多任务训练与专家混合	多任务覆盖不同于流程规划
BATCHER ^[15]	实体解析	示例覆盖选择与批量上下文学习	对示例质量与批组织敏感
Jellyfish ^[30]	多类预处理	指令微调与领域知识注入	解释文本不等于正确性证明
Snorkel ^[23]	数据标注	标注函数与弱监督建模	依赖覆盖和噪声建模条件
GoodCore ^[33]	补全与样本选择	不完整数据上的梯度近似	受目标模型与补全条件约束

4 任务感知的数据准备流程

4.1 从局部操作到下游目标优化

单项操作的最优配置不一定形成整体最优流程。清洗可能改变实体匹配的候选集合, 连接可能放大重复值, 样本过滤则可能改变训练分布。这些相互作用要求流程构造同时考虑操作顺序、数据依赖和下游目标。面向机器学习, 优化信号通常来自验证集性能; 面向数据分析, 则更多依赖目标表定义、问题语义与结构约束。二者都可视为式(1)的具体情形, 但其效用函数及可获得的反馈并不相同。

HAIPipe 研究同一机器学习任务下人工生成流程与自动生成流程的组合, 通过搜索和筛选寻找具有更好下游表现的准备流程。^[11] 人工流程能够包含领域经验, 自动流程则在候选操作集合中开展优化, 二者的结合为已有工作流的改进提供了方法。其输入中包含可利用的流程结构, 与从自然语言需求直接构造流程的任务存在区别。评价时应将已有流程视为重要先验, 并计算候选流程试运行带来的开销。

4.2 自然语言驱动的逻辑规划与执行

AutoPrep 针对表格问答提出问题感知的数据准备, 将流程划分为规划、编程与执行三个部分, 并利用 Chain-of-Clauses 推理和工具辅助生成连接问题语义与具体变换。^[12] 其主要处理需求包括列派生、值规范化和相关列筛选, 核心思想是先确定逻辑准备操作, 再生成适配当前表格与问题的物理实现。这种分层使语义决策和执行代码能够分别处理, 但原论文的主要证据来自表格问答设置, 不能直接视为任意多表准备任务的性能保证。

Text-to-Pipeline 将自然语言准备指令到可执行操作组合的映射定义为独立任务, 构建 PAR-ROT 基准, 并提出利用中间执行状态的 Pipeline-Agent。^[19] 与 AutoPrep 以问答需求为起点不同, Text-to-Pipeline 关注的是准备意图与操作序列的对应关系。其分析指出, 失败既可能来自多步操作组合, 也可能来自语义参数定位, 即操作类别合理但列、条件或参数选择错误。这一区分提示流程评测应分别检查操作结构和实例化参数。

自然语言接口降低了用户描述流程的技术门槛, 却不能消除需求中的歧义。同一目标描述可能对应不同的时间范围、去重键和统计粒度, 而这些解释都可能生成能够运行的程序。PrepBench 将交互澄清纳入评测, 为观察系统是否能识别和解决此类问题提供了任务设置。^[16] 因此, 交互能力应与代码生成能力分别测量, 并报告澄清次数及其对最终结果的影响。

4.3 执行反馈、结构化搜索与流程修订

长流程中的错误可能在后续阶段才显现, 局限于修改最后一步的策略难以纠正前序语义决策。DeepPrep 将中间表状态显式保存在执行环境中, 通过树状推理组织不同尝试, 支持根据反馈回退到较早状态并修订流程, 同时采用渐进式智能体训练学习相关行为。^[13] 其贡献在于把流程构造与可观测执行状态联系起来, 并使修订范围超出局部代码纠错。但执行反馈的有效性仍取决于哪些错误能够被观测; 如果目标口径本身未被正确表达, 单纯增加搜索分支仍可能得到语义不符的结果。

BAT 研究无需目标表实例的准备流程合成, 利用操作沙箱约束候选行为, 通过语言模型驱动蒙特卡洛树搜索构造流程, 并结合执行结果筛选候选。^[20] 其“无目标实例”指不依赖目标表中的具体记录, 仍利用目标模式等信息限定任务。与 DeepPrep 侧重训练可回退的智能体行为不同, BAT 强调免训练条件下的受控流程搜索。两类方法都利用执行信息减少无效尝试, 但搜索空间、监督来源与成本构成不同, 比较时需要控制目标信息和执行预算。

图2归纳任务规划、工具执行、独立验证与失败反馈之间的关系。其中，独立验证指使用能够在模型生成之外检查结果的约束、参考数据或任务判定过程；它是本文综合分析中的设计要求，不表示所有被综述系统已经包含同等能力的验证器。中间状态有助于定位与回退，数据来源和版本记录则用于复现同一处理过程。这种机制划分有助于区分更强的搜索能力与更可靠的验证依据。




图 2 任务感知数据准备中的执行反馈与验证。实线表示主要处理及数据流，虚线表示语义澄清；验证失败后可定位中间状态并修订前序决策。该图是本文的综合机制示意，不是 AutoPrep、DeepPrep 或 BAT 的原始架构图。

4.4 跨任务复用与系统边界

流程自动化需要复用已有的算子、匹配模型和领域知识。Unicorn 与 Jellyfish 分别通过多任务学习和指令微调共享准备能力，而 KnowTrans 将知识增强与数据准备模型的迁移能力联系起来。^[10, 18, 30] 这里需要区分组件迁移和完整流程迁移：一个匹配模型在新数据上可用，并不意味着原流程中的关联顺序、过滤条件或验证规则仍然成立。跨领域复用因而应分别评价语义预测、操作选择和流程结果三个层面。

表3总结不同流程研究的目标和信息条件。这些工作共同推动数据准备从预定义脚本走向按任务构造的流程，但研究证据对应不同程度的任务封闭性。固定算子集使搜索和评测更可控，开放式代码生成提供更高的表达能力；目标实例、已有流程与自然语言描述则提供不同强度的监督。对系统自动化程度的判断，应建立在这些条件被明确披露的基础上。

表 3 数据准备流程研究的目标、输入与反馈方式

方法	目标与主要输入	流程构造或反馈	需要控制的比较条件
Wrangler ^[5]	原始表与用户交互	交互变换及脚本生成	用户指定操作的工作量
Auto-Tables ^[31]	非规范表的关系化	多步转换合成	无输出示例仍有结构目标
HAIPipe ^[11]	学习任务与已有流程	组合搜索及下游评价	已有流程先验、候选试运行成本
AutoPrep ^[12]	表格与自然语言问题	逻辑规划、编程、执行反馈	问答后端、表格与问题类型
Pipeline-Agent ^[19]	原始表与准备指令	基于中间状态的迭代操作	算子集合与指令精确度
DeepPrep ^[13]	多个源表与目标描述	状态保存、树状推理与训练	训练数据、模型与回退预算
BAT ^[20]	源表与目标模式	操作沙箱及执行感知树搜索	无目标实例条件与搜索预算

5 评测方法与现有证据的适用范围

5.1 局部处理质量与流程正确性

局部评测通常针对可明确标注的子任务。错误检测、类型识别和实体匹配可采用准确率、精确率、召回率及 F1 值；数值补全可采用平均绝对误差或均方根误差。这些指标必须与标签粒度、类别比例和缺失机制一起解释。例如，单元格错误检测与记录级错误检测使用不同的评价单元，匹配候选对上的 F1 也不包含候选生成阶段的遗漏。仅报告总体均值可能掩盖稀有类型或少数数据源上的性能下降。^[7, 8, 22, 27]

流程正确性则需要检查操作之间的组合结果。可执行率只能反映程序是否完成运行，目标表比较能够进一步判断输出结构和值是否符合参考结果，操作序列比较则反映流程表达的相似程度。由于不同流程可能产生相同输出，严格的序列匹配可能低估语义等价的实现；反之，在单个输入上输出一致，也不能证明流程在其他输入上仍然正确。对连接、聚合、重复记录、空值和排序语义的约定应提前固定，并在评测工具中保持一致。

Text-to-Pipeline 和 PrepBench 代表两种互补的评测入口。PARROT 从已有转换模式出发构造约 1.8 万项任务，覆盖 16 类核心操作，适合研究指令到操作组合的映射。^[19] PrepBench 基于 Preppin' Data 任务扩展评测，将交互消歧、准备代码生成和代码到工作流转换分别纳入考察，任务涉及 3 至 18 个准备步骤。^[16] 前者强调规模化操作组合，后者强调现实准备任务中的交互和表达问题。它们的结果不能在未统一任务难度、工具支持和目标信息条件时直接比较。

5.2 下游效用与综合成本

数据准备的最终效用需要结合使用任务判断。在表格问答中，准备后的答案准确性还受到问答后端影响；在机器学习中，预测性能受到模型类型、超参数和训练数据划分影响。因此，应同时报告准备结果本身的质量与固定下游系统上的表现，通过消融实验区分语义理解、操作选择和执行反馈的贡献。^[11, 12, 33] 使用下游指标选择准备流程时，只能利用训练集及验证集，测试集应保留用于最终评估，防止由反复选择造成信息泄漏。

成本评价至少应区分模型调用、工具执行、存储与人工四部分。批量提示可能降低上下文重复开销，但其效果与批大小和示例共享程度有关；树搜索可以增加修订机会，也会引入候选执行和中间状态保存成本。^[13, 15, 20] 因此，比较报告需要披露模型版本、输入输出 token、重试次数、最大搜索深度、运行环境和人工确认量。仅以单次推理价格或单条样本时延代表完整任务成本，容易遗漏失败重试和流程维护开销。

5.3 基准覆盖与可复现性

表4汇总不同层次的评测对象与控制条件。本表是对评测设计的归纳, 本文未重新运行所列系统, 也未将原论文的分数合并为统一排名。现有证据分别支持模型在特定任务、数据及预算下的表现; 对跨域迁移、长期数据更新和复杂业务语义的结论, 需要更有针对性的基准或应用实验。

表 4 智能数据准备的评测层次与控制条件

评测层次	典型对象与文献	可观测指标	必须说明的条件
检测与匹配	Raha、Ditto、Sato ^[7, 8, 22]	精确率、召回率、F1 及分类结果	标注单元、候选生成、训练测试划分
补全与修复	HoloClean、补全综述 ^[6, 27]	修复准确性、重构误差、误修改比例	真实或合成错误、缺失机制、可用参考值
操作与流程	PARROT、DeepPrep、BAT ^[13, 19, 20]	执行成功、目标输出一致性	算子、目标信息、比较语义与搜索预算
交互及表达	PrepBench ^[16]	澄清效果、代码正确性、流程翻译质量	交互轮数、用户模拟及参考流程定义
下游效用	AutoPrep、HAIPipe、GoodCore ^[11, 12, 33]	问答或预测性能、单位成本增益	固定后端、数据划分及准备成本
运行与维护	本文归纳的扩展维度	时延、人工修订、版本复现与变化后失效率	模型和数据版本、缓存、重试及更新条件

为提高结果可复查性, 评测产物应包含原始数据版本、任务说明、实际输入给系统的信息、执行脚本、处理后数据和失败案例。对于随机推理或搜索, 应披露随机种子、采样设置及多次运行差异。数据来源与用途说明可参考 Datasheets 和 FAIR 提出的记录要求, 但仍需补充具体准备操作的参数及验证条件。^[28, 29] 这些信息使研究者能够区分算法差异、模型更新与数据变化造成的结果波动。

6 开放问题与研究方向

6.1 任务语义的显式表达与交互获取

自然语言需求与可执行操作之间仍缺少稳定的语义连接。数据类型、主外键和非空约束能够描述结构条件, 却难以完整表达统计口径、时间有效性与实体边界。AutoPrep 和 PrepBench 分别从问题感知规划和交互消歧揭示了这一问题。^[12, 16] 后续研究可以将任务解释转化为可检查的条件集合, 使同一约束同时用于流程生成和结果验证, 并研究不同条件之间的冲突检测。

交互策略还需要明确何时提问以及确认何种信息。候选流程之间若仅存在不影响结果的实现差异, 额外询问会增加负担; 若在连接键、聚合粒度或异常处理上存在分歧, 则有必要获取领域知识。可研究依据候选结果差异选择澄清问题, 并以正确性增益与人工成本的关系评价交互策略。这一方向的关键是建立可验证的语义状态, 而非仅增加对话轮次。

6.2 知识迁移与分布变化下的适应

跨任务复用已经在统一匹配和专用预处理模型中得到探索, 知识增强也成为数据准备模型迁移的重要研究方向。^[10, 18, 30] 但模式变化、值域变化与业务语义变化需要不同的适应机制。列名替换可能不改变数据含义, 单位变更却会改变有效转换; 旧领域中的异常模式也可能在新领域成为正常取值。因此, 迁移评价应区分新数据集、新模式和新任务, 并观察模型在少量标注、无标注及带外部知识条件下的表现。

可复用准备组件还应附带适用条件及来源说明。当知识库、数据字典或示例流程发生变化时, 系统需要判断已有步骤是否仍然有效。未来可以结合数据画像、规则版本和执行失败信息, 定位需

要更新的组件, 并评价更新所需人工工作量。相较于一次性跨域测试, 这类持续适应设置更接近数据准备流程的实际维护过程。

6.3 独立验证与错误传播控制

执行感知流程在定位错误方面具有优势, 但运行反馈主要覆盖语法、类型、工具异常及部分结构问题。对业务语义错误, 验证器本身还需要参考数据或显式约束。DeepPrep 和 BAT 提供了利用中间状态进行修订的机制, 进一步的问题是如何识别验证盲区, 以及如何避免错误判断在搜索过程中反复强化。^[13, 20]

一种值得研究的方式是按操作定义前置条件、后置条件及数据影响范围, 并将模型提出的变换与独立程序检查相结合。对于缺乏完整参考答案的任务, 可以研究关系不变量、输入扰动下的预期行为及多个实现之间的差异检测。这些检查只能覆盖相应的错误类型, 仍需明确其证明边界。对缺少事实依据的修复, 应允许拒绝修改、保留缺失或提交候选结果, 以避免把模型推断无条件写回数据。

6.4 质量、成本与持续维护的联合优化

现有研究已分别考察批量推理、学习任务驱动的清洗和核心子集选择, 显示准备成本可以通过任务信息重新分配。^[15, 32, 33] 完整系统仍需协调模型推理与数据库执行: 确定性的过滤、聚合和类型检查可批量执行, 语义难例则交由学习模型处理。如何在错误风险、数据规模和时延约束下选择执行方式, 是比单纯压缩提示长度更广泛的优化问题。

持续更新还要求准备流程支持影响分析与增量验证。数据新增、模式变化或模型版本更新后, 不同操作的适用范围可能改变, 历史上正确的结果不能直接作为新版本的保证。未来评测可引入按时间推进的数据版本, 测量结果失效率、受影响步骤定位能力和修复成本。同时, 应保留原始数据、操作记录和权限边界, 使流程重放与错误恢复具有明确依据。该方向需要结合数据系统的版本管理机制及任务相关质量评价共同推进。

7 结论

本文围绕国内外智能数据准备研究, 从数据发现、语义理解、清洗修复、匹配融合、结构转换和标注增强六类任务出发, 分析了规则约束、统计学习、语言模型和流程规划的技术联系。以范举、李国良、高云君等学者及其合作者的研究为重要线索, 并与国际代表性工作比较, 可以看到研究关注点正在由单项任务建模扩展到下游目标驱动的流程构造、执行修订与成本优化。现有方法在输入监督、目标表达和可用反馈方面具有不同假设, 其有效性应在相应条件下解释。

智能数据准备的进一步发展, 需要将语义推断、确定性执行与独立验证贯通, 并建立覆盖局部质量、流程正确性、下游效用和持续维护的评测体系。任务约束的显式化、跨域知识的可控复用以及中间状态和来源的可追溯管理, 是提高复杂准备流程可靠性的关键研究方向。在此基础上, 自动化系统才能同时提供适用的数据、可复现的流程和能够检查的处理依据。

参考文献

- [1] CHAI C, TANG N, FAN J, et al. Demystifying Artificial Intelligence for Data Preparation[C]//Companion of the 2023 International Conference on Management of Data. New York: ACM, 2023: 13-20. DOI: 10.1145/3555041.3589406.
- [2] CHAI C, WANG J, LUO Y, et al. Data Management for Machine Learning: A Survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(5): 4646-4667. DOI: 10.1109/tkde.2022.3148237.
- [3] BATINI C, CAPPIELLO C, FRANICALANCI C, et al. Methodologies for Data Quality Assessment and Improvement[J]. ACM Computing Surveys, 2009, 41(3): 16:1-16:52. DOI: 10.1145/1541880.1541883.
- [4] 刘祺, 黄君义, 冯耕中, 等. 数字经济发展根基: 数据质量研究述评与未来展望[J]. 系统工程理论与实践, 2025, 45(7): 2101-2123. DOI: 10.12011/SETP2023-2891.
- [5] KANDEL S, PAEPCKE A, HELLERSTEIN J M, et al. Wrangler: Interactive Visual Specification of Data Transformation Scripts[C]//Proceedings of the SIGCHI Conference on Human Factors in Computing Systems. New York: ACM, 2011: 3363-3372. DOI: 10.1145/1978942.1979444.
- [6] REKATSINAS T, CHU X, ILYAS I F, et al. HoloClean: Holistic Data Repairs with Probabilistic Inference[J]. Proceedings of the VLDB Endowment, 2017, 10(11): 1190-1201. DOI: 10.14778/3137628.3137631.
- [7] ZHANG D, HULSEBOS M, SUHARA Y, et al. Sato: contextual semantic type detection in tables[J]. Proceedings of the VLDB Endowment, 2020, 13(12): 1835-1848. DOI: 10.14778/3407790.3407793.
- [8] LI Y, LI J, SUHARA Y, et al. Deep entity matching with pre-trained language models[J]. Proceedings of the VLDB Endowment, 2020, 14(1): 50-60. DOI: 10.14778/3421424.3421431.
- [9] NARAYAN A, CHAMI I, ORR L, et al. Can Foundation Models Wrangle Your Data?[J]. Proceedings of the VLDB Endowment, 2022, 16(4): 738-746. DOI: 10.14778/3574245.3574258.
- [10] TU J, FAN J, TANG N, et al. Unicorn: A Unified Multi-tasking Model for Supporting Matching Tasks in Data Integration[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 84:1-84:26. DOI: 10.1145/3588938.
- [11] CHEN S, TANG N, FAN J, et al. HAIPipe: Combining Human-generated and Machine-generated Pipelines for Data Preparation[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 91:1-91:26. DOI: 10.1145/3588945.
- [12] FAN M, FAN J, TANG N, et al. AutoPrep: Natural Language Question-Aware Data Preparation with a Multi-Agent Framework[J]. Proceedings of the VLDB Endowment, 2025, 18(10): 3504-3517. DOI: 10.14778/3748191.3748211.
- [13] FAN M, FAN J, ZHANG Y, et al. DeepPrep: An LLM-Powered Agentic System for Autonomous Data Preparation[J]. Proceedings of the VLDB Endowment, 2026, 19(11): 3371-3384. DOI: 10.14778/3836663.3836695.
- [14] HE J, VELTRI E, SANTORO D, et al. Interactive and Deterministic Data Cleaning: A Tossed Stone Raises a Thousand Ripples[C]//Proceedings of the 2016 International Conference on Management of Data. ACM, 2016: 893-907. DOI: 10.1145/2882903.2915242.
- [15] FAN M, HAN X, FAN J, et al. Cost-Effective In-Context Learning for Entity Resolution: A Design Space Exploration[C]//2024 IEEE 40th International Conference on Data Engineering (ICDE). IEEE, 2024: 3696-3709. DOI: 10.1109/icde60146.2024.00284.
- [16] XU J, WANG R, WANG J, et al. PrepBench: How Far are We from Natural-Language-Driven Data Preparation?[J]. Proceedings of the VLDB Endowment, 2026, 19(10): 2866-2879. DOI: 10.14778/3828612.3828638.
- [17] 高云君, 葛丛丛, 郭宇翔, 等. 面向关系型数据与知识图谱的数据集成技术综述[J]. 软件学报, 2023, 34(5): 2365-2391. DOI: 10.13328/j.cnki.jos.006808.
- [18] GE Y, LI F, MAO Y, et al. KnowTrans: Boosting Transferability of Data Preparation LLMs via Knowledge Augmentation[C]//2025 IEEE 41st International Conference on Data Engineering. Piscataway: IEEE, 2025: 2852-2866. DOI: 10.1109/ICDE65448.2025.00214.
- [19] GE Y, LIU Y, YE Z, et al. Text-to-Pipeline: Bridging Natural Language and Data Preparation Pipelines[EB/OL]. (2025-11-10) [2026-09-09]. <https://arxiv.org/abs/2505.15874v2>.

- [20] GE C, LIU Y, TANG Y, et al. BAT: Target-Instance-Free Data Preparation Synthesis via LLM-Driven Tree Search[J]. *Proceedings of the ACM on Management of Data*, 2026, 4(3): 143:1-143:25. DOI: 10.1145/3802020.
- [21] CASTRO FERNANDEZ R, ABEDJAN Z, KOKO F, et al. Aurum: A Data Discovery System[C]//2018 IEEE 34th International Conference on Data Engineering (ICDE). IEEE, 2018: 1001-1012. DOI: 10.1109/icde.2018.00094.
- [22] MAHDAVI M, ABEDJAN Z, CASTRO FERNANDEZ R, et al. Raha: A Configuration-Free Error Detection System[C]//Proceedings of the 2019 International Conference on Management of Data. ACM, 2019: 865-882. DOI: 10.1145/3299869.3324956.
- [23] RATNER A, BACH S H, EHRENBERG H, et al. Snorkel: rapid training data creation with weak supervision[J]. *Proceedings of the VLDB Endowment*, 2017, 11(3): 269-282. DOI: 10.14778/3157794.3157797.
- [24] CHEN M, SUN Y, LI T, et al. Empowering Tabular Data Preparation with Language Models: Why and How?[C]//Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2026: 228-246. DOI: 10.18653/v1/2026.acl-long.8.
- [25] ZHOU W, ZHOU J, WANG H, et al. Can LLMs Clean Up Your Mess? A Survey of Application-Ready Data Preparation with LLMs[EB/OL]. (2026-01-22) [2026-09-09]. <https://arxiv.org/abs/2601.17058v1>.
- [26] LIANG H, WONG Z H, LIU R T, et al. Data Preparation for Large Language Models[J]. *Journal of Computer Science and Technology*, 2026, 41(1): 289-317. DOI: 10.1007/s11390-026-5948-8.
- [27] 周立, 吴洋洋, 苗晓晔. 基于深度学习的不完整时序数据补全方法综述[J]. *计算机研究与发展*, 2025, 62(9): 2233-2258. DOI: 10.7544/issn1000-1239.202550449.
- [28] GEBRU T, MORGENSTERN J, VECCHIONE B, et al. Datasheets for Datasets[J]. *Communications of the ACM*, 2021, 64(12): 86-92. DOI: 10.1145/3458723.
- [29] WILKINSON M D, DUMONTIER M, AALBERSBERG I J, et al. The FAIR Guiding Principles for Scientific Data Management and Stewardship[J]. *Scientific Data*, 2016, 3: 160018. DOI: 10.1038/sdata.2016.18.
- [30] ZHANG H, DONG Y, XIAO C, et al. Jellyfish: Instruction-Tuning Local Large Language Models for Data Preprocessing[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2024: 8754-8782. DOI: 10.18653/v1/2024.emnlp-main.497.
- [31] LI P, HE Y, YAN C, et al. Auto-Tables: Synthesizing Multi-Step Transformations to Relationalize Tables without Using Examples[J]. *Proceedings of the VLDB Endowment*, 2023, 16(11): 3391-3403. DOI: 10.14778/3611479.3611534.
- [32] KRISHNAN S, WANG J, WU E, et al. ActiveClean: interactive data cleaning for statistical modeling[J]. *Proceedings of the VLDB Endowment*, 2016, 9(12): 948-959. DOI: 10.14778/2994509.2994514.
- [33] CHAI C, LIU J, TANG N, et al. GoodCore: Data-effective and Data-efficient Machine Learning through Coreset Selection over Incomplete Data[J]. *Proceedings of the ACM on Management of Data*, 2023, 1(2): 157:1-157:27. DOI: 10.1145/3589302.
- [34] CHEN D, HUANG Y, MA Z, et al. Data-Juicer: A One-Stop Data Processing System for Large Language Models[C]//Companion of the 2024 International Conference on Management of Data. New York: ACM, 2024: 120-134. DOI: 10.1145/3626246.3653385.