

智能数据准备研究综述

关键技术、流程优化与评测方法

范举 范梅浩

中国人民大学信息学院，数据工程与知识工程教育部重点实验室
北京 100872

摘 要：数据准备通过数据发现、语义理解、清洗修复、匹配融合、结构转换和标注增强，将异构原始数据转化为满足下游任务要求的数据资源，是数据分析与机器学习的重要基础。近年来，预训练语言模型和大语言模型的发展拓展了数据准备的语义处理能力，研究对象也由单项操作逐步延伸至任务感知的流程生成与执行优化。然而，现有方法在监督条件、目标表达、操作空间及验证方式方面存在明显差异，单项任务的性能提升尚不能直接说明完整流程的可靠性。本文通过结构化补充检索与引文追溯整理 48 项国内外文献，按输入-操作-输出定义任务边界，并从目标监督、状态表示、搜索反馈与停止条件比较技术机制和流程能力。进一步比较代表性基准的规模、来源与指标，综合同一实验设置内的准确率、成本及失败证据，并通过多表实例分析错误传播与回退，区分已有结论、综合归纳和研究假设。文献分析表明，智能数据准备的发展需要将语言模型的语义推断能力与数据系统的确定性执行、可追溯状态及任务相关验证相结合，以提高复杂数据处理流程的可用性与可检验性。

关键词：数据准备；数据清洗；数据集成；大语言模型；程序合成；数据质量

1 引言

数据分析和机器学习通常以结构、语义和质量满足要求的数据为前提，而实际数据往往分散于异构数据源，并伴随字段含义不明确、值表示不一致、实体重复及记录缺失等问题。数据准备研究面向这些问题，连接原始数据与下游任务，其处理对象既包括数据值，也包括数据模式、跨源对应关系和可执行变换流程。Chai 等对人工智能辅助数据准备的讨论，以及面向机器学习的数据管理综述，均将数据准备视为数据系统与学习方法交叉的重要研究环节。^[1, 2] 从数据质量角度看，处理结果的准确性、完整性和一致性需要结合使用情境评价，统一格式或消除异常并不足以保证数据适合目标任务。^[3, 4]

该领域已经形成多条相互关联的技术路线。交互式工具利用用户示例与规则降低变换表达成本；统计学习方法根据数据分布和完整性约束进行检测与修复；预训练模型通过共享表示支持语义类型识别和实体匹配；大语言模型则进一步支持自然语言需求解释及代码生成。^[5-9] 这些方法并非简单的替代关系。学习模型有助于处理规则难以完整描述的语义问题，数据库算子和显式约束则为批量执行、错误定位和结果验证提供基础。如何把单项模型组织为可执行、可验证且成本可控的准备流程，是当前研究的重要问题。

国内学者在上述方向开展了持续研究。范举及其合作者围绕统一匹配模型、人工与自动流程组合、问题感知的数据准备和执行反馈驱动的智能体展开探索，相关工作包括 Unicorn、HAIPipe、AutoPrep 和 DeepPrep。^[10-13] 李国良及其合作者在交互式确定性清洗、面向机器学习的数据管理、低成本实体匹配及自然语言数据准备评测等方面形成了相互衔接的研究。^[2, 14-16] 高云君及其合作者则从数据集成技术出发，进一步研究数据准备模型的知识增强与迁移、自然语言流程表达和无目标实例的流程搜索。^[17-20] 上述工作包含跨团队合作，本文依据技术问题组织国内外文献，并与 Aurum、Raha、Snorkel 等代表性方法进行对照。^[21-23]

1.1 文献范围与组织方法

本文采用结构化的范围综述方法, 讨论对象以关系表、异构记录及元数据为主, 并覆盖训练标签、样本选择与语料处理; 检索截止日期为 2026 年 9 月 9 日。原稿保留的 34 项文献构成追溯种子, 本次另行执行不含作者姓名的主题检索, 以检查由特定研究团队出发可能造成的遗漏。结构化数据库为 Crossref; 原文核验平台包括 ACM、IEEE、PVLDB、ACL Anthology、arXiv 和中文期刊官网, 作者主页及机构知识库用于查找公开版本。上述平台承担不同功能, 本文未检索 CNKI、Web of Science 或 Scopus, 不将网页查找等同于这些数据库的系统检索。

检索分为查询试探、固定题名查询和引文补充三步。试探阶段执行 8 组宽泛查询, 保存 120 条返回记录, 用于检查同义词与噪声; 这些记录不计入正式筛选漏斗。固定阶段使用 Crossref 的 `query.title` 参数, 依次检索 table union search、semantic type detection、data cleaning、entity matching、table transformation、weak supervision、data preprocessing pipeline 和 data preparation, 时间过滤为 2009-01-01 至 2026-09-09, 每式保留相关度排序前 15 条。该接口执行相关度检索而非精确短语布尔检索; 完整参数、排名、原始响应和逐项决定随文保存于 `editorial/search/`。

初筛依据题名、摘要和文献类型判断是否涉及可复用的数据准备任务、方法或基准, 排除同名异义、一般领域应用、目录、百科条目及无独立研究内容的材料。复筛核查输入、输出、机制和评测依据; 同一工作的预印本、会议版与期刊转载合并, 优先采用正式版本。证据充分但与本次分析维度重复的研究列入候选记录, 明确记为范围取样而非质量否定; 未取得足以核对技术定位的资料则标记证据不足。综述、来源规范和仅能核验主题定位的论文作为背景文献, 不进入算法优劣或量化结果比较。表1报告本次实际筛选统计; 既有 34 项文献没有可追溯的历史初筛数量, 因此与本次新增记录分列, 不反推原稿筛选过程。

表 1 补充检索的范围、筛选与保留情况

阶段	数量	统计口径
固定题名检索	120 条	8 式, 每式前 15 条; 试探查询另存
去重后初筛	117 项	DOI 去重并合并同名版本
进入复筛	34 项	初筛排除 83 项
主题检索新增纳入	10 项	复筛其余 24 项及原因见台账
引文与主题补充	4 项	REIN、Valentine、Auto-Pipeline、Baran
最终引用文献	48 项	原稿 34 项, 加本次 14 项; 全部进入正文

为控制选文偏差, 作者线索只用于发现候选, 纳入规则不包含作者、机构或引用量条件; 新增文献需补充机制、监督条件或评价对象上的差异。最终 48 项中, 36 项用于方法或基准分析, 12 项作为综述、规范或主题背景。按非互斥覆盖标签, 数据发现 5 项、语义理解 8 项、清洗修复 14 项、匹配融合 7 项、结构转换 11 项、标注增强 4 项, 另有 11 项涉及流程构造或评测; 逐项映射见随文检索附件。每式前 15 条的截断、Crossref 对中文文献和预印本收录的不均衡、单轮筛选及公开全文可得性仍构成遗漏风险; 因此本文提供的是可核查的范围取样, 不能据此宣称领域穷尽覆盖。

1.2 已有综述与本文定位

已有综述分别从数据管理、数据质量、数据集成和语言模型应用等角度组织该领域。高云君等以关系型数据和知识图谱为对象, 分析实体解析、融合与清洗技术; Chai 等从机器学习生命周期讨论数据发现、清洗和标注; Chen 等则按获取、集成、清洗与转换梳理语言模型辅助的表格数据准备。^[2, 17, 24] Zhou 等近期预印本关注大语言模型支持的应用就绪数据准备, Liang 等从大模型训练阶

段讨论训练数据的准备流程。^[25, 26] 二者分别强调使用语言模型准备数据和为语言模型准备数据, 研究目标有所区别。

在中文研究中, 刘祺等从概念、理论与方法层面分析数据质量, 周立等围绕时序缺失机制及补全评测展开比较。前者提供质量评价的概念基础, 后者展示在具体缺失条件下比较方法的必要性; 二者与流程合成研究形成评价粒度上的互补。^[4, 27]

表2按统一维度比较已有综述。尤其需要指出, Chen 等已讨论完整流程框架, 并在附录提供指标、报告模板与鲁棒性检查; Zhou 等也已讨论清洗、集成和增强中的 LLM 使用方式。^[24, 25] 因而, 覆盖流程或提出成本指标本身不是本文的独有贡献。本文的增量在于把分类框架落实为同一组证据字段: 输入监督决定哪些目标信息需要自行推断, 状态与反馈决定哪些决策可以修订, 验证依据决定可支持的正确性结论, 评测设置则限定效用与成本的可比范围。

这一交叉分析形成三项具体认识。其一, 自动化程度取决于目标信息供给与人工决策位置, 不能仅按是否使用 LLM 划分, 见表5。其二, 多分支搜索扩大的是候选探索范围, 独立验证扩大的是错误可观测范围, 两者不能互相替代, 见表6和图3。其三, 组件质量、流程完成和下游收益是不同的实测对象, 应以同一论文的对照实验提炼条件性结论, 见表8。这些认识属于本文的综合归纳, 后续章节给出支持证据和边界, 而非声称提出新的数据准备算法。

表 2 已有综述与本文的分类、流程及评测维度对照

文献	分类维度	流程级覆盖	LLM / Agent 覆盖	评测组织
高云君等 (2023) ^[17]	数据对象、解析/融合/清洗	集成任务关联	非主要组织轴	集成方法分析
Chai 等 (2023) ^[2]	ML 生命周期、管理任务	准备与学习的联系	传统 AI 与 ML 为主	数据效用与系统性能
刘祺等 (2025) ^[4]	概念、理论、方法与应用	质量管理过程	非主要组织轴	质量评估与优化
周立等 (2025) ^[27]	时序缺失问题、补全机制	补全及下游应用	非主要组织轴	数据、缺失设置与指标
Chen 等 (2026) ^[24]	准备阶段、LM 介入方式	专节讨论完整流程	LM 与多智能体	基准、报告模板与鲁棒性
Zhou 等 (2026 预印本) ^[25]	清洗、集成、增强	应用就绪及任务内编排	LLM 与 Agent 机制	任务指标及应用挑战
Liang 等 (2026) ^[26]	大模型训练阶段	训练语料准备过程	为 LLM 准备数据	语料质量及训练需求
本文	输入-操作-输出; 机制与能力	状态、搜索、反馈、回退与停止	与规则、学习和合成统一比较	基准版图、同设置结果与成本

注: 描述各文献的组织重点, 不以未作为主轴推定完全缺少相关讨论; 中文条目的核验范围见文献来源附录。

2 问题定义与分类框架

2.1 任务定义与输出要求

本文将 data preparation 译为数据准备, 指为满足特定下游任务而发现、理解、修改或组织数据的过程。data preprocessing 译为数据预处理, 通常指已选定数据上的变换、编码、补全或样本处理; data cleaning 强调错误检测与修复; data integration 强调跨源对应关系和一致表示的形成。后三者是任务范围不同且可能交叉的研究对象, 本文保留论文原有术语, 但按其实际输入与输出进行归类。例如, 按已知键执行连接属于结构转换, 而推断两个来源中的记录是否指向同一实体属于匹配融合。

为比较不同研究, 本文将数据准备任务抽象为三元组 $(\mathcal{D}, q, \mathcal{C})$ 。其中, $\mathcal{D}$ 为可访问的原始数据及其元数据集, q 为下游问题、目标模式或学习任务描述, $\mathcal{C}$ 为类型、完整性、资源预算和访问

范围等约束。给定算子集合 $\mathcal{O}$, 数据准备需要构造流程 P , 使其执行结果 $D' = P(\mathcal{D})$ 满足目标要求; D' 可表示一张表或一组准备后的数据对象。 P 可以是操作序列, 也可以是支持多表输入的有向无环图; 算子包括选择、连接、聚合、类型转换、匹配、修复和标注等。这里的形式化描述用于统一讨论, 不意味着现有方法均显式表示所有约束。

固定运行环境与交互条件, 记 Exec 为流程执行过程, τ_P 为包含实际操作、访问来源和中间状态的执行记录。候选流程的选择目标可概括为:

$$\begin{aligned} \max_{P \in \mathcal{P}(\mathcal{O})} \quad & U_q(D') \\ \text{s.t.} \quad & (D', \tau_P) = \text{Exec}(P, \mathcal{D}), \\ & (D', \tau_P) \models \mathcal{C}_{\text{hard}}, \\ & C_{\text{exec}}(P; \mathcal{D}) \leq B_e, \quad C_{\text{human}}(P; \mathcal{D}, q) \leq B_h. \end{aligned} \quad (1)$$

其中, $\mathcal{P}(\mathcal{O})$ 为可构造的流程空间, U_q 为越大越优的标量效用; 若采用损失指标, 则取其相反数。 $\mathcal{C}_{\text{hard}}$ 包含必须满足的输出与过程约束: 类型、完整性等可检查输出, 访问范围等则需要检查执行记录, 不能仅由最终表判断。 C_{exec} 和 C_{human} 分别度量给定数据与任务下该流程运行的执行成本和人工投入, $B_e, B_h \geq 0$ 为相应预算; 每项预算与对应成本采用相同单位, 运行环境和计量协议固定。在学习任务中, U_q 还隐含固定的模型训练与数据划分协议, 可由验证集性能定义; 测试真值不用于流程选择。无法直接观测的真实性需通过规则、参考数据及人工检查间接验证。式(1)采用固定随机性和交互条件下的单次运行记法, 不提供随机流程的期望或概率保证; 候选生成、训练及失败重试的总成本需另按完整搜索协议累计。执行失败或无法终止的流程不属于可行解; 该式也不保证可行解存在或全局最优能够获得。它是本文的分析框架, 而非已验证的优化算法。

不同任务对输入监督的要求差异较大。有的方法假设提供匹配标签或正确值, 有的方法需要用户示例、已有流程或目标模式, 也有的方法仅利用自然语言描述和执行状态开展搜索。这些条件决定了系统需要自行推断的信息范围。比较方法时, 应同时说明它获得了哪些目标信息, 以及哪些正确性标准仅由评测器掌握, 避免把更强的输入监督误认为更强的自动化能力。

2.2 任务类型、技术机制与流程能力

本文以被评测的输出对象作为主要分类依据, 以输入和操作语义消解类别交叉, 定义见表3。分类单位是可独立评价的任务配置, 而不必是一整篇论文。一项工作仅输出类型标签时, 主类为语义理解; 若把类型模型用于发现数据源, 则发现模块另记数据发现标签。模式匹配输出字段对应关系, 归为语义理解; 实体匹配输出记录对应关系, 归为匹配融合; 确定性地应用既有映射或连接键, 归为结构转换。标签作为训练输入不使方法自动归入标注增强, 只有生成或选择训练监督本身是评价目标时才加入该类。

多任务论文采用多标签记录, 按各实验输出分别编码; 需要单一主类时, 以论文主要优化目标对应的输出为准, 无法确定时保留并列主类, 不强行计入互斥统计。例如 Unicorn 在类型识别和实体匹配配置下分别标记语义理解与匹配融合; GoodCore 同时涉及缺失补全和训练子集选择; DeepPrep 的多算子配置跨越多个任务, 而其流程能力独立记录。^[10, 13, 28] 该规则允许任务覆盖数大于文献总数, 并避免以模型名称或训练方式代替任务分类。

从实现机制看, 可以区分显式规则与程序搜索、统计与深度学习、语言模型语义推断, 以及结合外部工具的流程规划。同一任务可以由不同机制解决, 同一系统也可能组合多种机制。例如, 实体匹配可以采用监督分类、上下文学习或多任务表示, 而结构转换既可以由示例驱动, 也可以通过目标模式搜索或自然语言代码生成完成。图1展示任务类型与支撑机制之间的总体关系。

表 3 六类任务的输入、操作与输出边界

任务	输入对象	判定性操作	主要输出及排除边界
数据发现	数据目录、表集合及查询	检索、排序可用数据源	候选表/关联；不要求已完成融合
语义理解	字段、模式、值域与上下文	预测类型或字段语义对应	类型/字段映射；记录同一性另计
清洗修复 匹配融合	含错或缺失数据及参考信息 跨源记录与来源信息	检测、纠正、估计缺失值 识别同一对象、解决属性冲突	错误位置/修复值；纯重排另计 记录对应/统一实体；已知键连接另计
结构转换	表、已知映射及目标结构	连接、过滤、聚合、重塑或派生	目标表/程序；不含未知事实推断
标注增强	样本、任务及弱监督资源	生成监督、选择或组织语料	标签/训练子集/增强语料；输入标签不计




图 1 智能数据准备的任务体系。六类任务可根据下游目标组合，规则约束、统计学习、语言模型与流程规划构成可互补的实现机制。图为本文对相关研究的综合归纳，非特定系统架构。

图1中的六个任务块与表3逐行对应，底部规则、统计学习、语言模型和流程规划对应实现机制轴；右侧数据、流程和验证产物对应输出层次，成本与来源记录对应评测及复现条件。图中的连线表示可组合关系，不规定六类任务的固定顺序。

从流程能力看，单项预测、固定流程执行、任务感知规划与基于反馈的流程修订应分别考察。多任务模型能够覆盖多类输入，并不意味着其具备自动确定操作顺序的能力；流程可以成功执行，也不意味着它符合用户的业务语义。数据准备的完整输出因而可以分为目标数据、可执行流程和验证记录三个层次。其中，来源说明和变换记录有助于复现处理过程，但其存在本身并不能证明结果正确。^[29, 30]

3 智能数据准备的关键技术

3.1 数据发现与语义理解

数据发现需要从大量异构资源中定位与任务相关的数据源, 并识别潜在的可连接或可合并关系。Aurum 通过数据关系表示及声明式发现操作支持跨源检索, 体现了以索引和关系组织降低数据定位成本的思路。^[21] 这类系统主要回答数据位于何处以及可能存在何种关系; 候选关联是否满足当前任务的语义要求, 仍需要进一步的模式与内容分析。因此, 发现阶段的召回率、候选规模和后续验证成本应共同考虑。Table Union Search 根据值域、语义域等证据寻找可并表, SANTOS 进一步利用列间关系补充逐列相似性, 说明表级可用性需要同时考虑属性含义及其组合。^[31, 32] 不过, Boutaleb 等对并表基准的再分析发现, 简单方法可能利用数据集特有特征获得较高分数; 因此发现准确率不能未经对照就解释为更强的语义理解。^[33]

语义理解进一步处理列名、值域及表内上下文之间的对应关系。Sato 结合列值特征、表级主题和结构化预测识别列语义类型, 说明字段含义不能仅由孤立单元格或表头确定。^[7] 与之相比, 语言模型能够联合利用自然语言说明、样例值和外部知识, 但其输出仍可能受字段命名、序列化方式和上下文截断影响。^[9, 24] 对涉及单位、编码和统计粒度的字段, 语义相近不应直接作为可替换或可连接的充分条件。STEER 通过数据编程生成新数据湖的训练标签, 再适配既有类型模型; SportsTables 则专门考察数值列占比较高时的类型识别。^[34, 35] 两者把比较重点由单个数据集的分类分数移至新域监督的取得及列分布差异。

Unicorn 将包括模式匹配、列类型标注和实体匹配在内的多个匹配任务统一到共享表示与判别框架中, 并通过专家混合机制处理任务语义差异。^[10] 它将知识共享的范围由单一数据集扩展至多类匹配问题, 为准备组件复用提供了路径。不过, 多任务共享的有效性仍取决于任务相关程度、训练覆盖及输入表示, 不能据此假设任意新模式均能直接对齐。从系统角度看, 语义模型更适合生成带有依据和置信信息的候选映射, 再结合模式约束进行筛选。

3.2 错误检测、数据修复与缺失补全

数据清洗首先需要区分错误检测与错误修复。检测回答哪些值或记录不满足预期, 修复则需要进一步决定如何修改。HoloClean 综合完整性约束、统计关系和参考信息, 以概率推断选择修复结果。^[6] 其优势在于同时利用多种证据, 但修复质量仍受候选值覆盖、约束准确性与数据相关结构影响。约束被满足只能说明一组逻辑条件成立, 不足以单独保证所有值均恢复为真实记录。

Raha 将多种检测策略的输出转化为特征, 并利用聚类、抽样及用户标注减少手工配置成本。^[22] 它弱化了用户逐项设置检测规则和参数的负担, 但仍需要一定的人工监督。He、Li 等提出的 Falcon 则从用户给出的修复出发, 搜索并确认可推广的 SQL 更新规则, 将人工反馈用于确定性清洗。^[14] 两类方法分别侧重减少检测配置和复用修复知识, 说明人在回路的主要作用可以是选择有价值的监督, 而非逐条完成全部处理。

检测与修复还可以通过共享上下文形成组件链。Baran 在统一上下文表示下组织候选纠错模型, 并借助迁移与用户反馈完成修复; 与 Raha 结合时, 应分别报告错误定位和候选修复的损失。^[22, 36] REIN 进一步将检测、修复及学习模型放在同一评测框架中, 说明只依据局部清洗分数选择组件可能遗漏下游影响。^[37]

语言模型为错误解释和候选值生成提供了新的实现方式。Narayan 等探索通过基础模型统一表达多类数据整理任务; Jellyfish 进一步利用面向数据预处理的指令微调, 支持错误检测、缺失补全、模式匹配和实体匹配。^[9, 38] 其可本地部署的模型形态有利于复用任务能力, 但自然语言解释不构成

事实依据。对于原始数据中不可观测的信息, 应区分基于记录证据的纠错与基于统计或模型知识的估计, 并保留估计值的来源及不确定性。

缺失补全还受到缺失机制和数据结构的影响。周立等的综述将缺失场景、缺失率、变量数量、序列长度及下游效果纳入评测讨论, 表明方法比较需要控制数据缺失的形成条件。^[27] 这一要求同样适用于一般表格: 在随机遮蔽数据上的较小重构误差, 并不能直接说明方法适用于与业务过程相关的系统性缺失。不同补全结果还可能改变变量关系和样本分布, 因此应同时检查局部数值误差与后续分析的稳定性。

3.3 实体匹配与多源融合

实体匹配判断不同来源的记录是否指向同一对象, 多源融合则进一步处理同一对象的属性冲突、来源差异和表示统一问题。高云君等对关系数据与知识图谱集成的梳理表明, 实体解析、融合和清洗之间存在紧密联系。^[17] 匹配错误会把不同对象合并, 融合规则则可能在对应关系正确的前提下选取错误值, 因此两个阶段需要分别验证。此外, 候选对生成的遗漏会限制后续匹配的召回率, 不能只评价分类器在已筛选候选对上的性能。

DeepMatcher 比较深度学习实体匹配的表示与聚合设计, 为后续预训练模型路线提供了组件化参照。^[39] Ditto 将实体匹配转化为预训练语言模型上的序列对分类, 并结合领域知识、文本摘要和数据增强改善输入表达。^[8] 该路线通过有监督微调获得较强的任务适配能力, 但跨领域应用仍涉及标注与训练成本。Unicorn 侧重跨匹配任务共享表示, 关注的是复用范围; 二者解决的问题有所重叠, 监督组织方式和泛化目标则并不相同。^[10]

Fan 等提出 BATCHER, 从示例选择和问题分批两个方面研究实体解析中的上下文学习成本。^[15] 其覆盖式示例选择与批量提示使多个待匹配问题共享上下文, 有助于在匹配质量和模型调用开销之间选择合适配置。这一思路将示例组织本身视为优化对象, 但仍依赖示例标签质量以及批内信息的可区分性。因此, 使用语言模型代替人工产生示例标签时, 需要把标签错误传播计入评估, 而不能只统计调用次数的减少。

从匹配到融合, 还需要引入来源可信度、时间有效性和字段级一致性等信息。将所有冲突统一为多数投票会忽略来源之间的依赖, 也可能覆盖更新的有效记录。已有集成研究提供了冲突分析的基础; 在语言模型参与的流程中, 保留候选值、来源及采用规则, 是使后续融合决定可以复查的重要条件。^[3, 17]

3.4 结构转换与程序合成

结构转换处理嵌套表头、宽窄表变换、字段拆分、类型转换及列派生等问题, 其输出通常需要满足关系结构或下游程序的输入要求。Wrangler 通过交互式示范和变换建议生成处理脚本, 使用户能够在数据预览中逐步确定操作。^[5] 其价值在于降低表达门槛并保留可重复执行的脚本, 而转换目标和关键操作仍主要由用户指定。Morpheus 依据输入-输出示例进行类型引导的程序枚举, 结合组件规范、SMT 推理与部分求值剪枝。^[40] 其搜索反馈具有明确的示例一致性依据, 但部署时需要可供用户表达的输出示例, 与无示例关系化任务的输入条件不同。

Auto-Tables 面向非规范表格的关系化处理, 通过合成多步变换恢复适合分析的结构, 且不要用户自行提供转换后的示例表。^[41] 其模型利用行列方向的特征预测算子及参数, 并通过束搜索保留多个候选流程。这一路线将变换预测与受限搜索结合, 说明自动转换并不必然依赖自然语言指令。但目标结构的合理性与目标业务语义仍是不同问题: 获得规范关系表后, 还需要检查值的单位、聚合粒度和跨表对应关系。

语言模型代码生成扩大了可表达变换的范围, 同时也使验证问题更加突出。受控算子便于检查类型、参数和前置条件, 自由代码则能够表达复杂清洗逻辑, 但可能引入难以静态分析的行为。AutoPrep 与 BAT 分别通过逻辑操作分解和操作沙箱约束流程构造。^[12, 20] 对数据准备而言, 二者之间的取舍取决于目标任务是否需要开放式语义转换, 以及系统能否为扩展代码提供独立验证。

3.5 数据标注、样本选择与训练数据准备

面向机器学习的数据准备还需要构造监督信号并确定训练样本。Snorkel 允许用户以标注函数表达领域启发式, 并对含噪、冲突的弱监督输出进行建模, 减少逐样本标注需求。^[23] 这种方法将人工劳动由重复标签判定转移到标注知识的组织, 但仍受规则覆盖和噪声建模条件限制。对语言模型生成的标签也应采用类似的分析方式, 区分标签来源、错误相关性和下游效用。VersaMatch 将启发式规则、模式及外部知识作为弱监督源, 用于本体匹配中的判别模型和集成预测。^[42] 按本文分类, 其最终匹配输出归入语义理解, 弱监督机制则与 Snorkel 形成技术联系, 不能因共享机制而将两者视为同一任务。

样本选择与数据修复可以联合考虑。ActiveClean 针对凸损失模型, 在逐步清洗数据的过程中更新模型, 并优先处理可能影响训练结果的记录。^[43] GoodCore 进一步研究不完整数据上的核心子集选择, 将数据补全与梯度近似联系起来, 以兼顾训练质量、训练效率和人工补全成本。^[28] 两者均体现了任务驱动的数据准备思想, 但各自的模型假设和优化目标限制了结论的适用范围, 不能直接推广到任意学习模型。

对于大模型训练语料, 去重、过滤、来源管理与数据配比需要在不同训练阶段共同设计。DataJuicer 将数据分析和处理算子组织为可组合的系统, 支持处理配方的调整与比较; Liang 等的综述则区分预训练、持续预训练和后训练的数据需求。^[26, 44] 这里的评价对象是语料对模型训练的贡献, 与利用大语言模型执行表格清洗的评价对象不同。处理规模、内容覆盖及下游性能应结合讨论, 单一过滤分数难以完整表示训练数据价值。

3.6 关键技术的比较

表4从所需监督、核心机制与适用边界比较代表方法。规则和统计方法具有较明确的执行或推断条件, 语言模型方法扩大了语义处理范围, 但往往引入提示、示例选择和模型版本等新的敏感因素。监督需求也没有随模型规模增加而消失, 而是由实例标签转移到任务说明、提示示例、知识资源或验证规则。因此, 方法选择需要同时考虑错误类型、可用监督和维护成本, 不能仅依据模型是否采用大语言模型划分优劣。

表 4 代表性数据准备组件的技术比较

方法	主要任务	所需信息与核心机制	适用边界或比较注意点
Aurum ^[21]	数据发现	数据关系及发现查询	候选关系仍需任务语义验证
Sato ^[7]	列语义类型	类型标签、列值与表上下文	受类型集合及训练覆盖影响
HoloClean ^[6]	数据修复	约束、统计及参考信息的概率融合	依赖候选修复与约束质量
Raha ^[22]	错误检测	检测策略特征及少量用户标注	降低配置需求, 仍需监督
Falcon ^[14]	确定性清洗	用户修复与 SQL 规则确认	规则的推广范围需人工核验
Ditto ^[8]	实体匹配	标注记录对与预训练模型微调	关注域内质量及跨域标注成本
Unicorn ^[10]	多类匹配	多任务训练与专家混合	多任务覆盖不同于流程规划
BATCHER ^[15]	实体解析	示例覆盖选择与批量上下文学习	对示例质量与批组织敏感
Jellyfish ^[38]	多类预处理	指令微调与领域知识注入	解释文本不等于正确性证明
Snorkel ^[23]	数据标注	标注函数与弱监督建模	依赖覆盖和噪声建模条件
GoodCore ^[28]	补全与样本选择	不完整数据上的梯度近似	受目标模型与补全条件约束

3.7 监督与流程能力的统一对照

表5把组件和流程系统放在共同的信息条件下比较。其中, Auto-Pipeline 通过类比目标表约束关系变换搜索, DiffPrep 则依据下游验证损失优化预处理流程, 二者分别体现目标对象监督和任务效用监督。^[45, 46] 自动化采用操作性编码: A0 表示用户决定下一步, A1 表示系统完成已给定的局部任务, A2 表示自动构造候选流程, A3 表示利用执行反馈修订流程。这些编码描述能力类型, 不代表总性能排序; A3 系统仍可能依赖较强的任务说明, A1 组件也可能在其任务上提供更可靠的结果。“目标实例”仅指合成或推理时可见的目标表记录, 训练标签、提示示例、目标模式和任务说明另外记载。

表 5 代表方法的监督、自动化与流程能力矩阵

方法	自动化	目标实例	多表	人工交互	独立于生成的检查	回退/重试	公开产物
Wrangler ^[5]	A0	无	单表	操作示范	数据预览/用户确认	未判	未核
HoloClean ^[6]	A1	无	未判	约束输入	约束参与推断	未判	代码
Raha ^[22]	A1	无	非重点	检测标注	测试标签仅评测用	未判	代码
Ditto ^[8]	A1	无	记录对	训练标注	测试标签仅评测用	不适用	代码
Jellyfish ^[38]	A1	无	匹配对	指令/知识	未见通用任务验证	不适用	模型
Morpheus ^[40]	A2	当前输出	是	I/O 示例	组件规范与示例一致	搜索回溯	项目/代码
Auto-Pipeline ^[45]	A2	类比目标	是	目标表	目标键/函数依赖	搜索分支	未核
Auto-Tables ^[41]	A2	无	单表	候选选择	关系结构目标	束搜索	基准数据
HAIPipe ^[11]	A2	无	单任务	已有流程	验证集模型效用	候选搜索	代码
DiffPrep ^[46]	A2	无	单表	标签/模型	验证集损失	不适用	代码
AutoPrep ^[12]	A3	无	单表	问题输入	执行异常/工具接口	局部重试	代码
Pipeline-Agent ^[19]	A3	无	是	指令输入	DSL/执行状态	未判	代码/数据
DeepPrep ^[13]	A3	无	是	目标描述	算子执行/模式条件	显式状态	代码
BAT ^[20]	A3	无	是	目标模式	沙箱/执行检查	树搜索	代码
PrepBench 代理 ^[16]	A3	无	是	交互澄清	执行引擎; 真值仅评测	局部重试	代码/数据

注: “无”不表示无监督; “人工交互”列区分事先输入、标注与候选选择, 除 PrepBench 评测代理明确提供澄清动作外, 其余配置未据此确认具备开放式语义澄清。“多表”中的匹配对不等于多表流程。检查列陈述可获得的依据, 约束参与推断也不等于独立验证模块; 测试真值不反馈给运行系统。“未判/未核”表示证据未充分核实, 不等于不支持或不开源。公开产物据论文或作者项目声明, 均未由本文重跑。

这一比较揭示了监督的不同位置。示例驱动合成把部分语义要求转化为可计算的输出一致性, 目标表驱动合成从类比记录中提取结构约束, 学习任务驱动方法利用验证集损失, 语言模型流程则依靠说明与执行状态补足操作细节。因此, 替换方法时需要核对其监督资源是否可得, 而不是只替换模型调用接口。表中的回溯也具有不同含义: 枚举器撤销候选、束搜索保留多个路径, 与智能体恢复某个物化中间表状态是不同实现, 后者仍需有效失败信号才能发挥作用。

4 任务感知的数据准备流程

4.1 从局部操作到下游目标优化

单项操作的最优配置不一定形成整体最优流程。清洗可能改变实体匹配的候选集合, 连接可能放大重复值, 样本过滤则可能改变训练分布。这些相互作用要求流程构造同时考虑操作顺序、数据依赖和下游目标。面向机器学习, 优化信号通常来自验证集性能; 面向数据分析, 则更多依赖目标

表定义、问题语义与结构约束。二者都可视为式(1)的具体情形,但其效用函数及可获得的反馈并不相同。

DiffPrep 将预处理算子选择及顺序的离散搜索松弛为可微优化,与模型训练构成双层优化,并用验证集损失更新流程参数。^[46] 它适用于可微下游模型和受限预处理空间,与一般目标表合成相比,反馈更直接,但优化目标是预测效用而非恢复真实数据值。HAIPipe 研究同一机器学习任务下人工生成流程与自动生成流程的组合,通过搜索和筛选寻找具有更好下游表现的准备流程。^[11] 人工流程能够包含领域经验,自动流程则在候选操作集合中开展优化,二者的结合为已有工作流的改进提供了方法。其输入中包含可利用的流程结构,与从自然语言需求直接构造流程的任务存在区别。评价时应将已有流程视为重要先验,并计算候选流程试运行带来的开销。

4.2 目标信息与自然语言驱动的流程合成

目标表监督处于完整输出示例与纯结构说明之间。Auto-Pipeline 允许用户提供来自另一批数据的目标表,通过模式、键与函数依赖等信息约束搜索,结合搜索和强化学习生成流程。^[45] 该目标含具体记录,但并非当前输入的正确输出;它可以提供比模式更强的统计和依赖先验。因此,Morpheus 的 I/O 示例、Auto-Pipeline 的类比目标与 BAT 的目标模式,不能统一简称为“目标引导”后直接比较成功率。

AutoPrep 针对表格问答提出问题感知的数据准备,将流程划分为规划、编程与执行三个部分,并利用 Chain-of-Clauses 推理和工具辅助生成连接问题语义与具体变换。^[12] 其主要处理需求包括列派生、值规范化和相关列筛选,核心思想是先确定逻辑准备操作,再生成适配当前表格与问题的物理实现。这种分层使语义决策和执行代码能够分别处理,但原论文的主要证据来自表格问答设置,不能直接视为任意多表准备任务的性能保证。

Text-to-Pipeline 将自然语言准备指令到可执行操作组合的映射定义为独立任务,构建 PARROT 基准,并提出利用中间执行状态的 Pipeline-Agent。^[19] 与 AutoPrep 以问答需求为起点不同,Text-to-Pipeline 关注的是准备意图与操作序列的对应关系。其分析指出,失败既可能来自多步操作组合,也可能来自语义参数定位,即操作类别合理但列、条件或参数选择错误。这一区分提示流程评测应分别检查操作结构和实例化参数。

自然语言接口降低了用户描述流程的技术门槛,却不能消除需求中的歧义。同一目标描述可能对应不同的时间范围、去重键和统计粒度,而这些解释都可能生成能够运行的程序。PrepBench 将交互澄清纳入评测,为观察系统是否能识别和解决此类问题提供了任务设置。^[16] 因此,交互能力应与代码生成能力分别测量,并报告澄清次数及其对最终结果的影响。

4.3 执行反馈、结构化搜索与流程修订

长流程中的错误可能在后续阶段才显现,局限于修改最后一步的策略难以纠正前序语义决策。DeepPrep 将中间表状态显式保存在执行环境中,通过树状推理组织不同尝试,支持根据反馈回退到较早状态并修订流程,同时采用渐进式智能体训练学习相关行为。^[13] 其贡献在于把流程构造与可观测执行状态联系起来,并使修订范围超出局部代码纠错。但执行反馈的有效性仍取决于哪些错误能够被观测;如果目标口径本身未被正确表达,单纯增加搜索分支仍可能得到语义不符的结果。

BAT 研究无需目标表实例的准备流程合成,利用操作沙箱约束候选行为,通过语言模型驱动的蒙特卡洛树搜索构造流程,并结合执行结果筛选候选。^[20] 其“无目标实例”指不依赖目标表中的具体记录,仍利用目标模式等信息限定任务。与 DeepPrep 侧重训练可回退的智能体行为不同,BAT

强调免训练条件下的受控流程搜索。两类方法都利用执行信息减少无效尝试, 但搜索空间、监督来源与成本构成不同, 比较时需要控制目标信息和执行预算。

图2归纳任务规划、工具执行、独立验证与失败反馈之间的关系。其中, 独立验证指使用能够在模型生成之外检查结果的约束、参考数据或任务判定过程; 它是本文综合分析中的设计要求, 不表示所有被综述系统已经包含同等能力的验证器。中间状态有助于定位与回退, 数据来源和版本记录则用于复现同一处理过程。这种机制划分有助于区分更强的搜索能力与更可靠的验证依据。




图 2 任务感知数据准备中的执行反馈与验证。实线表示主要处理及数据流, 虚线表示语义澄清; 验证失败后可定位中间状态并修订前序决策。该图是本文的综合机制示意, 不是 AutoPrep、DeepPrep 或 BAT 的原始架构图。

4.4 跨任务复用与系统边界

流程自动化需要复用已有的算子、匹配模型和领域知识。Unicorn 与 Jellyfish 分别通过多任务学习和指令微调共享准备能力, 而 KnowTrans 将知识增强与数据准备模型的迁移能力联系起来。^[10, 18, 38] 这里需要区分组件迁移和完整流程迁移: 一个匹配模型在新数据上可用, 并不意味着原流程中的关联顺序、过滤条件或验证规则仍然成立。跨领域复用因而应分别评价语义预测、操作选择和流程结果三个层面。

表6进一步区分流程搜索的内部机制。状态表示决定能够识别的差异: 模式状态适合剪除类型不相容操作, 却不能区分同模式下的错误聚合; 物化表状态能够暴露值和基数变化, 但引入数据访问与保存成本; 可微参数状态则便于优化模型效用, 难以直接表达任意程序分支。停止条件同样属于方法假设: 模式满足、样例一致和验证损失收敛分别回答不同问题, 不能统一视为语义正确性证明。

图2中“任务与约束”对应目标监督, “规划/代码生成”对应搜索空间, “工具执行/中间状态”对应状态表示, “独立验证”对应检查依据, “失败反馈”对应修订能力; 成功出口则需按具体系统

表 6 流程构造的搜索空间、状态、反馈与停止机制

方法	搜索空间	状态表示	验证或优化信号	停止/预算边界
Morpheus ^[40]	组件组合与参数; 类型引导枚举	部分程序及部分求值结果	SMT 规范剪枝、I/O 一致	找到示例一致程序; 实验超时
Auto-Pipeline ^[45]	多步关系变换; 搜索或 RL	中间表与目标特征	目标模式、键和依赖	满足候选数或最大深度; 返回排序候选
Auto-Tables ^[41]	学习排序的变换与参数; 束搜索	中间表及候选路径	变换概率、结构目标与重排	none 算子或最大长度
HAIPipe ^[11]	人工/自动流程的组合插入	流程结构与候选评价信息	采样与固定学习任务的表现	枚举/采样预算内选优
DiffPrep ^[46]	按特征选择算子及次序的连续松弛	流程参数与模型权重	验证集损失的梯度	实验 1000 轮, 选验证损失最小轮
AutoPrep ^[12]	逻辑条款与工具/代码实现	准备计划、表与执行结果	工具执行与异常反馈	计划完成; 局部代码重试
Pipeline-Agent ^[19]	DSL 算子及语义参数	指令、当前表及操作历史	执行状态反馈	流程完成; 具体上限未判
DeepPrep ^[13]	算子实例与树分支	物化表集合、父节点及失败记录	执行状态/目标模式; 训练另用真值奖励	answer 动作; 探索轮数与扩展长度上限
BAT ^[20]	沙箱中的流程树搜索	候选流程及执行信息	目标模式与执行感知筛选	搜索预算; 正式版细节未充分核验

的停止条件解释。其中独立验证是综合框架中的能力维度, 不能由图示反推每个系统均含完整业务验证器。DeepPrep 训练时的输出真值奖励与部署时的执行/模式反馈, 也必须分别记录。

4.5 多表实例: 粒度错误的传播与可定位修订

考虑作者构造的最小实例: 订单表 O 包含 $(o_1, A, 100)$ 和 $(o_2, A, 80)$, 分别表示订单键、客户和金额; 退款表 R 包含 $(o_1, 20)$ 和 $(o_1, 10)$ 。目标是按客户汇总净收入, 并规定订单金额只计一次、同一订单的退款可加、全部订单保留且无退款记 0, 所有金额单位一致。退款表各行表示不同的有效退款事件, 且均关联订单表中的订单。这里的业务规则是例子预先给定的检查依据, 不是任何系统额外获得的测试答案。

若先按订单键左连接, 再逐行计算金额减退款, o_1 会形成两条记录, 最终得到 $(100 - 20) + (100 - 10) + 80 = 250$ 。一对多连接本身合法, 所有操作均可成功执行, 最终客户键也唯一, 因而类型检查、执行成功和最终模式检查都无法揭示错误。正确流程应先将退款按订单聚合为 $(o_1, 30)$, 再左连接并计算净收入, 得到 $70 + 80 = 150$ 。图3展示两条路径及其验证位置。

有效的中间检查是: 在计算每单净收入之前, 连接结果中的订单键应唯一; 有效的全局检查是: 输出净收入总和应等于原订单金额总和减全部有效退款, 即 $180 - 30 = 150$ 。在本例的修订路径中, 恢复到连接前状态并插入退款聚合, 即可消除订单金额的重复计入。两个检查都依赖上述保留范围与退款规则; 若存在部分订单过滤、币种转换或退款冲正, 必须重新定义不变量。键唯一性检查约束的是上述每单一行的中间表示; 它与总额检查均不足以单独证明客户归属或每笔金额正确。

该实例也区分了方法的适用条件。有正确输出示例的合成器可用输出一致性排除错误路径; 仅知目标列名的系统无法从模式推得“每单只计一次”; 保留中间状态的智能体能够定位并重建前序分支, 但前提是反馈暴露了重复计入。若任务未明确退款口径, 交互澄清首先解决语义缺失, 随后执行检查才能发挥作用。本文提供可运行的 SQLite 实例脚本, 复核两条路径、唯一性检查及一个行数相同但退款总额改变的扰动案例; 它仅验证例子的逻辑, 不代表重现实测系统。




图 3 多表准备中粒度错误的传播、独立检查与回退。实例由本文构造；250 与 150 是给定数据的确定性计算结果，不是方法性能分数。检查依据来自预设任务口径。

5 评测方法与现有证据的适用范围

5.1 局部处理质量与流程正确性

局部评测通常针对可明确标注的子任务。错误检测、类型识别和实体匹配可采用准确率、精确率、召回率及 F1 值；数值补全可采用平均绝对误差或均方根误差。这些指标必须与标签粒度、类别比例和缺失机制一起解释。例如，单元格错误检测与记录级错误检测使用不同的评价单元，匹配候选对上的 F1 也不包含候选生成阶段的遗漏。仅报告总体均值可能掩盖稀有类型或少数数据源上的性能下降。^[7, 8, 22, 27]

流程正确性则需要检查操作之间的组合结果。可执行率只能反映程序是否完成运行，目标表比较能够进一步判断输出结构和值是否符合参考结果，操作序列比较则反映流程表达的相似程度。由于不同流程可能产生相同输出，严格的序列匹配可能低估语义等价的实现；反之，在单个输入上输出一致，也不能证明流程在其他输入上仍然正确。对连接、聚合、重复记录、空值和排序语义的约定应提前固定，并在评测工具中保持一致。

Text-to-Pipeline 和 PrepBench 代表两种互补的评测入口。PARROT 从已有转换模式出发构造任务；本文引用的 v2 统计表给出 17168 项任务及 16 类核心操作，适合研究指令到操作组合的映射。^[19] PrepBench 基于 Preppin' Data 任务扩展评测，将交互消歧、准备代码生成和代码到 workflow 转换分别纳入考察，任务涉及 3 至 18 个准备步骤。^[16] 前者强调规模化操作组合，后者强调现实准备任务中的交互和表达问题。它们的结果不能在未统一任务难度、工具支持和目标信息条件时直接比较。

5.2 下游效用与综合成本

数据准备的最终效用需要结合使用任务判断。在表格问答中, 准备后的答案准确性还受到问答后端影响; 在机器学习中, 预测性能受到模型类型、超参数和训练数据划分影响。因此, 应同时报告准备结果本身的质量与固定下游系统上的表现, 通过消融实验区分语义理解、操作选择和执行反馈的贡献。^[11, 12, 28] 使用下游指标选择准备流程时, 只能利用训练集及验证集, 测试集应保留用于最终评估, 防止由反复选择造成信息泄漏。

成本评价至少应区分模型调用、工具执行、存储与人工四部分。批量提示可能降低上下文重复开销, 但其效果与批大小和示例共享程度有关; 树搜索可以增加修订机会, 也会引入候选执行和中间状态保存成本。^[13, 15, 20] 因此, 比较报告需要披露模型版本、输入输出 token、重试次数、最大搜索深度、运行环境和人工确认量。仅以单次推理价格或单条样本时延代表完整任务成本, 容易遗漏失败重试和流程维护开销。

5.3 基准版图: 数据来源、规模与评价对象

表7集中比较代表性基准及论文评测集。实体匹配任务画像研究按数据特征分析匹配难度, Valentine 则围绕数据发现中的模式对应构造受控比较, 分别为记录级和列级匹配提供评测参照。^[47, 48] 其中 SportsTables 和实体匹配任务集评价组件输出, REIN 联结清洗质量与学习效用, ATBench 和 PARROT 评价转换或操作组合, PrepBench 将交互和流程表达纳入任务。这些资源具有互补性, 不能将任务数量作为覆盖充分性的唯一依据: 合成操作序列可以扩大组合规模, 现实需求则更容易暴露任务口径和数据不规则性。

表 7 数据准备基准与评测集的任务、规模及局限

基准/评测集	规模与数据来源	任务与主要指标	适用范围和局限
SportsTables ^[35]	1187 表、24838 列; 体育网站, 约 86% 数值列	语义类型; 宏/加权 F1, 文本与数值分组	强调数值列; 有限领域与类型体系
EM 任务画像集 ^[47]	整理并补充 21 项既有实体匹配任务	记录匹配及难度画像	候选对与负例构造影响难度; 不含完整集成流程
Valentine ^[48]	540 组合成表对; 另有 4 组 WikiData、7 组 Magellan、2 组 ING 表对	4 类关联中的模式匹配; Recall@ k (k 为真值映射数)、时延	合成扰动便于控制; 2 组工业数据非公开
REIN ^[37]	14 公开数据集; 19 检测器、19 修复方法、33 学习模型	检测/修复、预测性能、扩展性	真实与注入错误并存; 结果受错误率及配置影响
ATBench ^[41]	244 案例, 其中 26 例多步; 论坛、notebook、网页/电子表格	单表关系化; Hit@ k 、合成时延	多为短流程; 候选命中不等于自动选择正确结果
PARROT v2 ^[19]	17168 任务; 源池 23009 表; 训练/验证/测试 14388/1387/1393	16 类算子, 含多表; 输出准确率 EA、程序有效率 PV、算子准确率 OA	模板及 LLM 辅助生成; 数值容差与算子边界需固定
PrepBench ^[16]	306 任务、829 输入表、32 领域; Preppin' Data, 3–18 步	消歧 F1、代码/工作流准确率及调用成本	用户模拟器辅助交互; 不涵盖无法由输入确定的事实修复
DeepPrep 评测集 ^[13]	Synth-Spider 训练 6788/测试 2008; Synth-Bird 测试 1150; 改写 Parrot 测试 1365; Buildings 105	目标表精确匹配、完成率、推理成本; 合成最长 28 步	SQL 衍生任务与真实任务混合; 改写 Parrot 并非原版测试集

注: 数量按所引用版本统计, 任务、表、列与表对不相加。PARROT 按 v2 表 2–3, DeepPrep 按正式论文表 1, PrepBench 实验依据可核读的 arXiv v1; 具体版本和原文位置见随文证据表。

基准之间至少有三类不可忽略的差异。首先, 输入给系统的任务信息不同: 目标示例、模式、无歧义指令及含歧义需求提供不同强度的监督。其次, 输出判定规则不同: PARROT v2 的规范化比较包含数值容差, 而 DeepPrep 描述为忽略行列顺序但要求单元格精确相等; 分数变化可能来自评测器而非算法。^[13, 19] 最后, 困难案例的生成机制不同: EM 任务画像研究关注匹配任务自身的可

区分性, 表并集基准再分析则指出数据特征可能让简单方法获得高分。^[33, 47] 因此, 所谓跨基准泛化应明确是数据域变化、任务描述变化还是评价协议变化。

指标记法还需与实现核对。Auto-Tables 正文以指示量求和书写 $\text{Hit}@k$, 公开评测代码则在首次命中后记 1 并停止, 避免多个正确候选重复计分; 其匹配对象是标注的算子与参数序列及列出的替代真值。^[41] 本文按该实现解释候选命中率, 不将其等同于所有语义等价程序的输出一致性。

5.4 原论文结果的条件性综合

本文不重新运行所列系统, 表8只摘录同一论文、明确模型与数据条件下的对照结果。准确率和增量均按百分数及百分点表示, 费用按原文单位换算; 未从曲线估读缺乏精确标签的数值, 也不把未报告的人工或训练成本设为 0。这些比较用于检验前文分类能解释哪些性能差异, 而不形成跨论文排行榜。

表 8 可比设置内的原论文结果与成本证据

证据与设置	对照及原报告结果	成本/失败信息	支持的结论与边界
E1: Auto-Tables, ATBench 244 例; 原表 2-3 ^[41]	同一方法 $\text{Hit}@1=57.0\%$, $\text{Hit}@3=75.0\%$; 扩大候选增加 18.0 百分点	平均合成 0.224 秒; 24 vCPU 与 4 块 P100 环境, 人工选候选未计	排序与候选选择仍是瓶颈; 75.0% 不代表全自动首选正确率
E2: AutoPrep, DeepSeek-V2.5-Chat; 原表 2 ^[12]	WikiTQ: NL2SQL 52.83 $\rightarrow$ 66.09%; TabFact: 70.21 $\rightarrow$ 87.85%, 分别增 13.26/17.64 百分点	问答后端、上下文上限 8192 与温度 0.01 固定; 此表未按该对照分列费用	准备与固定后端结合可改善答案; 不等价于准备表准确率
E3: DeepPrep, Qwen3-14B; 原表 2a ^[13]	Synth-Spider: IL 61.70 $\rightarrow$ DeepPrep 67.18%; 完成率 85.26 $\rightarrow$ 97.21%	均仅在 Synth-Spider 训练; 此表不列训练/推理费用; 最终表仍可能错误	增益 5.48 百分点支持训练与推理方案的联合效果; 不能单独归因于回退
E4: PrepBench, 306 任务; v1 表 6 ^[16]	GPT-5.1-Codex 端到端代码 54.9%/ workflows 34.6%; 给无歧义说明的代码生成 85.3%	对应每任务费用 \$0.11540/\$0.26410/\$0.08274, 含该路径调用与重试	增强目标说明改变问题难度; 完整流程结果不能由单项代码分数替代
E5: PrepBench, 同一端到端代码协议; v1 表 6 ^[16]	GPT-5.1-Codex 54.9%, Gemini 3 Flash 53.3%; 相差 1.6 百分点	每任务 \$0.11540 与 \$0.02140; 后者约为前者 18.5%	同协议可联合比较质量与调用成本; 不含采购、人工与维护费用
E6: DiffPrep, connect-4 及逻辑回归; 原表 2 ^[46]	最强所列基线 BoostClean 69.0%, DP-Fix 73.2%, 增 4.2 百分点; DP-Flex 70.1%	60/20/20 划分; BoostClean 采用多分类适配; 该表未给单数据集时延	特征级搜索可能改善任务效用; 扩大顺序空间不保证更优, 结论限于该模型/设置

对自动化的判断需要区分候选覆盖与最终选择。E1 中增加候选带来明显收益, 但用户仍需辨认正确结果; E4 中给定无歧义说明与端到端交互的差距, 则说明目标信息获取本身占据重要位置。这两类现象分别对应表5中的候选选择和语义监督, 不能用一个“自动化率”合并描述。

流程完成与语义正确也需要分离。E3 中 DeepPrep 的完成率 97.21% 与精确匹配准确率 67.18% 相差 30.03 个百分点, 直接显示可返回结果的流程仍可能不符合目标表。其 Qwen3-8B 消融中, 移除渐进训练后的 Synth-Spider 准确率从 65.99% 降至 22.21%; 该设置同时改变学习行为, 不能据此得出单独增加树搜索即可获得同等收益。^[13] DeepPrep 的奖励消融还报告了仅重命名列以满足表面模式、却未完成实际变换的行为, 说明终止条件可能被满足而任务仍未完成。^[13] 与图3相结合, 可以把失败分为运行中断、操作或参数错误、任务口径遗漏以及程序到工作流的表达损失; 前两类可利用执行反馈, 后两类还需要语义依据与独立评价。

下游收益则依赖模型与准备目标的耦合。E2 固定问答后端观察准备增益, E6 固定预测模型比较预处理方案, 均比跨论文比较最终准确率更有解释力。DiffPrep 自身报告从逻辑回归换为两层神经网络后, DP-Fix 或 DP-Flex 达到最优的任务数由 15/18 变为 10/18, 说明“最优准备方案”不能脱离下游模型。^[46] REIN 关于局部清洗指标和预测效果的联合评测支持同一分析方向。^[37]

成本证据仍不完整。E5 支持在原协议下权衡费用与准确率, 却不能证明某模型在新数据、价格或交互预算下仍最优; E1 的亚秒级合成也不包含训练及用户筛选时间。DeepPrep 将开放模型运行时间按 A800-80G 每小时 \$0.91 换算为推理费用, 这一核算与仅统计 API 调用的 PrepBench 存在成本边界差异。^[13, 16] 因此完整流程的方法选择应先固定数据、监督和效用指标, 再比较该条件下的推理、执行与人工投入, 而非把来源不同的费用相除。

5.5 评测报告与可复现性

表9汇总不同层次的评测对象与控制条件。本表是对评测设计的归纳, 与表7的资源比较及表8的实测证据相互补充。现有证据分别支持模型在特定任务、数据及预算下的表现; 对跨域迁移、长期数据更新和复杂业务语义的结论, 需要更有针对性的基准或应用实验。

表 9 智能数据准备的评测层次与控制条件

评测层次	典型对象与文献	可观测指标	必须说明的条件
检测与匹配	Raha、Ditto、Sato ^[7, 8, 22]	精确率、召回率、F1 及分类结果	标注单元、候选生成、训练测试划分
补全与修复	HoloClean、补全综述 ^[6, 27]	修复准确性、重构误差、误修改比例	真实或合成错误、缺失机制、可用参考值
操作与流程	PARROT、DeepPrep、BAT ^[13, 19, 20]	执行成功、目标输出一致性	算子、目标信息、比较语义与搜索预算
交互及表达	PrepBench ^[16]	澄清效果、代码正确性、流程翻译质量	交互轮数、用户模拟及参考流程定义
下游效用	AutoPrep、HAIPipe、GoodCore ^[11, 12, 28]	问答或预测性能、单位成本增益	固定后端、数据划分及准备成本
运行与维护	本文归纳的扩展维度	时延、人工修订、版本复现与变化后失效率	模型和数据版本、缓存、重试及更新条件

为提高结果可复查性, 评测产物应包含原始数据版本、任务说明、实际输入给系统的信息、执行脚本、处理后数据和失败案例。对于随机推理或搜索, 应披露随机种子、采样设置及多次运行差异。数据来源与用途说明可参考 Datasheets 和 FAIR 提出的记录要求, 但仍需补充具体准备操作的参数及验证条件。^[29, 30] 这些信息使研究者能够区分算法差异、模型更新与数据变化造成的结果波动。

6 开放问题与证据对应

以下区分三种论据: 文献实测证据 (E) 指前文可定位的实验或基准分析, 综合归纳 (S) 指本文在方法间建立的联系, 研究假设 (H) 指尚需专门验证的改进方向。该区分避免把合理的设计建议表述成已经得到实验支持的普遍结论。

6.1 任务语义的显式表达与交互获取

E4 显示无歧义说明下的代码生成与端到端准备存在较大差距, PrepBench 还记录了不充分澄清及流程翻译失败。^[16] 据此可归纳 S1: 目标语义获取与操作实现应分别建模和评测, 增加生成能力不能自动补足缺失口径。E1 中的候选选择问题也表明, 系统需要知道哪些候选差异会影响用户目标。

H1 是将任务解释表示为可检查的条件集合, 并根据候选输出的实质差异选择澄清问题。可在固定模型和总交互预算下, 对照随机提问、一次性任务说明和差异驱动提问, 测量正确率、有效澄

清覆盖与人工时间。只有在成本可比时取得稳定收益,才能支持该交互策略优于单纯增加对话轮次;本文尚未验证此假设。

6.2 迁移能力与分布变化的区分

SportsTables 在数值列较多的语料上重新评价语义类型方法,STEER、Unicorn 与 Jellyfish 分别从训练标签取得或任务共享探索迁移。^[10, 34, 35, 38] 这些证据与表7中的任务来源差异共同支持 S2: 新数据集、新模式、新操作和新业务口径构成不同的迁移维度,单次跨数据集测试只覆盖其中一部分。KnowTrans 提供知识增强与迁移的研究线索,但本文未取得足以核对其量化配置的全文,因此不将该项作为已验证收益的证据。^[18]

H2 是为组件附加可检查的适用条件,通过模式、值域及规则版本变化定位需要更新的步骤。可分别施加列重命名、单位变更、实体分布变化和口径变化,比较局部更新与整体重建的错误率及修订成本。这一实验能够检验迁移机制是否处理了语义变化,而不只是适应输入格式。

6.3 独立验证与错误传播控制

E3 揭示流程完成与目标表准确之间的差距,E4 进一步显示正确代码到可执行工作流的转换仍会损失正确性。结合表6中反馈来源的差异,可归纳 S3: 更大的搜索空间不能弥补没有被观察的语义错误。图3给出这一结论的可运行反例,但该实例只证明相应检查不足,并不估计此类错误在实际任务中的频率。

H3 是根据操作定义前后条件、关系不变量与影响范围,把候选生成同独立程序检查结合。可在保留测试真值的条件下,向运行系统逐步提供类型检查、键约束、总额不变量或输入扰动检查,固定搜索预算,比较错误检出率、误拒绝率和回退代价。不同约束的边际收益及盲区应分别报告;当无法验证事实修复时,可把拒绝修改或返回候选作为被评价的输出策略。

6.4 质量、成本与持续维护

E5 支持在同一协议下比较质量与调用成本,E6 及 REIN 表明准备效用依赖下游模型。^[37, 46] 由此得到 S4: 组件选择、流程搜索和验证预算应共享任务效用,而不宜分别最小化局部开销。但表7所列资源以一次性任务为主,尚不能支持长期维护成本已经得到充分评价的结论。

H4 是在按时间推进的数据版本上联合决定哪些步骤复用、重算或重新验证。评价可记录更新后的结果失效率、失效步骤定位、状态保存开销及人工修订时间,并与每次完全重跑的策略比较。这一方向属于本文提出的研究议程,其必要性来自现有评测覆盖的不足;是否能降低长期成本,需要专门的持续运行实验。

7 结论

本文围绕国内外智能数据准备研究,从数据发现、语义理解、清洗修复、匹配融合、结构转换和标注增强六类任务出发,分析了规则约束、统计学习、语言模型和流程规划的技术联系。在范举、李国良、高云君等学者及国内外相关研究的基础上,通过 48 项文献、统一能力矩阵、机制对照及原论文结果分析,本文指出:目标监督决定自动化边界,执行状态与验证依据分别决定可修订范围和可检出错误,下游模型与费用核算条件共同限定方法收益。现有方法在输入监督、目标表达和可用反馈方面具有不同假设,其有效性应在相应条件下解释。

智能数据准备的进一步发展,需要将语义推断、确定性执行与独立验证贯通,并建立覆盖局部质量、流程正确性、下游效用和持续维护的评测体系。任务约束的显式化、跨域知识的可控复用以

及中间状态和来源的可追溯管理, 是提高复杂准备流程可靠性的关键研究方向。在此基础上, 自动化系统才能同时提供适用的数据、可复现的流程和能够检查的处理依据。

参考文献

- [1] CHAI C, TANG N, FAN J, et al. Demystifying Artificial Intelligence for Data Preparation[C]//Companion of the 2023 International Conference on Management of Data. New York: ACM, 2023: 13-20. DOI: 10.1145/3555041.3589406.
- [2] CHAI C, WANG J, LUO Y, et al. Data Management for Machine Learning: A Survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(5): 4646-4667. DOI: 10.1109/tkde.2022.3148237.
- [3] BATINI C, CAPPIELLO C, FRANCALANCI C, et al. Methodologies for Data Quality Assessment and Improvement[J]. ACM Computing Surveys, 2009, 41(3): 16:1-16:52. DOI: 10.1145/1541880.1541883.
- [4] 刘祺, 黄君义, 冯耕中, 等. 数字经济发展根基: 数据质量研究述评与未来展望[J]. 系统工程理论与实践, 2025, 45(7): 2101-2123. DOI: 10.12011/SETP2023-2891.
- [5] KANDEL S, PAEPCKE A, HELLERSTEIN J M, et al. Wrangler: Interactive Visual Specification of Data Transformation Scripts[C]//Proceedings of the SIGCHI Conference on Human Factors in Computing Systems. New York: ACM, 2011: 3363-3372. DOI: 10.1145/1978942.1979444.
- [6] REKATSINAS T, CHU X, ILYAS I F, et al. HoloClean: Holistic Data Repairs with Probabilistic Inference[J]. Proceedings of the VLDB Endowment, 2017, 10(11): 1190-1201. DOI: 10.14778/3137628.3137631.
- [7] ZHANG D, HULSEBOS M, SUHARA Y, et al. Sato: contextual semantic type detection in tables[J]. Proceedings of the VLDB Endowment, 2020, 13(12): 1835-1848. DOI: 10.14778/3407790.3407793.
- [8] LI Y, LI J, SUHARA Y, et al. Deep entity matching with pre-trained language models[J]. Proceedings of the VLDB Endowment, 2020, 14(1): 50-60. DOI: 10.14778/3421424.3421431.
- [9] NARAYAN A, CHAMI I, ORR L, et al. Can Foundation Models Wrangle Your Data?[J]. Proceedings of the VLDB Endowment, 2022, 16(4): 738-746. DOI: 10.14778/3574245.3574258.
- [10] TU J, FAN J, TANG N, et al. Unicorn: A Unified Multi-tasking Model for Supporting Matching Tasks in Data Integration[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 84:1-84:26. DOI: 10.1145/3588938.
- [11] CHEN S, TANG N, FAN J, et al. HAIPipe: Combining Human-generated and Machine-generated Pipelines for Data Preparation[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 91:1-91:26. DOI: 10.1145/3588945.
- [12] FAN M, FAN J, TANG N, et al. AutoPrep: Natural Language Question-Aware Data Preparation with a Multi-Agent Framework[J]. Proceedings of the VLDB Endowment, 2025, 18(10): 3504-3517. DOI: 10.14778/3748191.3748211.
- [13] FAN M, FAN J, ZHANG Y, et al. DeepPrep: An LLM-Powered Agentic System for Autonomous Data Preparation[J]. Proceedings of the VLDB Endowment, 2026, 19(11): 3371-3384. DOI: 10.14778/3836663.3836695.
- [14] HE J, VELTRI E, SANTORO D, et al. Interactive and Deterministic Data Cleaning: A Tossed Stone Raises a Thousand Ripples[C]//Proceedings of the 2016 International Conference on Management of Data. ACM, 2016: 893-907. DOI: 10.1145/2882903.2915242.
- [15] FAN M, HAN X, FAN J, et al. Cost-Effective In-Context Learning for Entity Resolution: A Design Space Exploration[C]//2024 IEEE 40th International Conference on Data Engineering (ICDE). IEEE, 2024: 3696-3709. DOI: 10.1109/icde60146.2024.00284.
- [16] XU J, WANG R, WANG J, et al. PrepBench: How Far are We from Natural-Language-Driven Data Preparation?[J]. Proceedings of the VLDB Endowment, 2026, 19(10): 2866-2879. DOI: 10.14778/3828612.3828638.
- [17] 高云君, 葛丛丛, 郭宇翔, 等. 面向关系型数据与知识图谱的数据集成技术综述[J]. 软件学报, 2023, 34(5): 2365-2391. DOI: 10.13328/j.cnki.jos.006808.
- [18] GE Y, LI F, MAO Y, et al. KnowTrans: Boosting Transferability of Data Preparation LLMs via Knowledge Augmentation[C]//2025 IEEE 41st International Conference on Data Engineering. Piscataway: IEEE, 2025: 2852-2866. DOI: 10.1109/ICDE65448.2025.00214.
- [19] GE Y, LIU Y, YE Z, et al. Text-to-Pipeline: Bridging Natural Language and Data Preparation Pipelines[EB/OL]. (2025-11-10) [2026-09-09]. <https://arxiv.org/abs/2505.15874v2>.

- [20] GE C, LIU Y, TANG Y, et al. BAT: Target-Instance-Free Data Preparation Synthesis via LLM-Driven Tree Search[J]. *Proceedings of the ACM on Management of Data*, 2026, 4(3): 143:1-143:25. DOI: 10.1145/3802020.
- [21] CASTRO FERNANDEZ R, ABEDJAN Z, KOKO F, et al. Aurum: A Data Discovery System[C]//2018 IEEE 34th International Conference on Data Engineering (ICDE). IEEE, 2018: 1001-1012. DOI: 10.1109/icde.2018.00094.
- [22] MAHDAVI M, ABEDJAN Z, CASTRO FERNANDEZ R, et al. Raha: A Configuration-Free Error Detection System[C]//Proceedings of the 2019 International Conference on Management of Data. ACM, 2019: 865-882. DOI: 10.1145/3299869.3324956.
- [23] RATNER A, BACH S H, EHRENBERG H, et al. Snorkel: rapid training data creation with weak supervision[J]. *Proceedings of the VLDB Endowment*, 2017, 11(3): 269-282. DOI: 10.14778/3157794.3157797.
- [24] CHEN M, SUN Y, LI T, et al. Empowering Tabular Data Preparation with Language Models: Why and How?[C]//Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2026: 228-246. DOI: 10.18653/v1/2026.acl-long.8.
- [25] ZHOU W, ZHOU J, WANG H, et al. Can LLMs Clean Up Your Mess? A Survey of Application-Ready Data Preparation with LLMs[EB/OL]. (2026-01-22) [2026-09-09]. <https://arxiv.org/abs/2601.17058v1>.
- [26] LIANG H, WONG Z H, LIU R T, et al. Data Preparation for Large Language Models[J]. *Journal of Computer Science and Technology*, 2026, 41(1): 289-317. DOI: 10.1007/s11390-026-5948-8.
- [27] 周立, 吴洋洋, 苗晓晔. 基于深度学习的不完整时序数据补全方法综述[J]. *计算机研究与发展*, 2025, 62(9): 2233-2258. DOI: 10.7544/issn1000-1239.202550449.
- [28] CHAI C, LIU J, TANG N, et al. GoodCore: Data-effective and Data-efficient Machine Learning through Coreset Selection over Incomplete Data[J]. *Proceedings of the ACM on Management of Data*, 2023, 1(2): 157:1-157:27. DOI: 10.1145/3589302.
- [29] GEBRU T, MORGENSTERN J, VECCHIONE B, et al. Datasheets for Datasets[J]. *Communications of the ACM*, 2021, 64(12): 86-92. DOI: 10.1145/3458723.
- [30] WILKINSON M D, DUMONTIER M, AALBERSBERG I J, et al. The FAIR Guiding Principles for Scientific Data Management and Stewardship[J]. *Scientific Data*, 2016, 3: 160018. DOI: 10.1038/sdata.2016.18.
- [31] NARGESIAN F, ZHU E, PU K Q, et al. Table union search on open data[J]. *Proceedings of the VLDB Endowment*, 2018, 11(7): 813-825. DOI: 10.14778/3192965.3192973.
- [32] KHATIWADA A, FAN G, SHRAGA R, et al. SANTOS: Relationship-based Semantic Table Union Search[J]. *Proceedings of the ACM on Management of Data*, 2023, 1(1): 1-25. DOI: 10.1145/3588689.
- [33] BOUTALEB A, AMANN B, NAACKKE H, et al. Something's Fishy in the Data Lake: A Critical Re-evaluation of Table Union Search Benchmarks[C]//Proceedings of the 4th Table Representation Learning Workshop. 2025: 71-85. DOI: 10.18653/v1/2025.trl-1.7.
- [34] LANGENECKER S, STURM C, SCHALLES C, et al. Steered Training Data Generation for Learned Semantic Type Detection[J]. *Proceedings of the ACM on Management of Data*, 2023, 1(2): 201:1-201:25. DOI: 10.1145/3589786.
- [35] LANGENECKER S, STURM C, SCHALLES C, et al. SportsTables: A New Corpus for Semantic Type Detection (Extended Version)[J]. *Datenbank-Spektrum*, 2023, 23(3): 189-197. DOI: 10.1007/s13222-023-00457-y.
- [36] MAHDAVI M, ABEDJAN Z. Baran: Effective Error Correction via a Unified Context Representation and Transfer Learning[J]. *Proceedings of the VLDB Endowment*, 2020, 13(12): 1948-1961. DOI: 10.14778/3407790.3407801.
- [37] ABDELAAL M, HAMMACHER C, SCHÖNING H. REIN: A Comprehensive Benchmark Framework for Data Cleaning Methods in ML Pipelines[C/OL]//Proceedings of the 26th International Conference on Extending Database Technology. 2023: 499-511. <https://openproceedings.org/2023/conf/edbt/3-paper-49.pdf>. DOI: 10.48786/edbt.2023.43.

- [38] ZHANG H, DONG Y, XIAO C, et al. Jellyfish: Instruction-Tuning Local Large Language Models for Data Preprocessing[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2024: 8754-8782. DOI: 10.18653/v1/2024.emnlp-main.497.
- [39] MUDGAL S, LI H, REKATSINAS T, et al. Deep Learning for Entity Matching[C]//Proceedings of the 2018 International Conference on Management of Data. 2018: 19-34. DOI: 10.1145/3183713.3196926.
- [40] FENG Y, MARTINS R, VAN GEFFEN J, et al. Component-based synthesis of table consolidation and transformation tasks from examples[C]//Proceedings of the 38th ACM SIGPLAN Conference on Programming Language Design and Implementation. 2017: 422-436. DOI: 10.1145/3062341.3062351.
- [41] LI P, HE Y, YAN C, et al. Auto-Tables: Synthesizing Multi-Step Transformations to Relationalize Tables without Using Examples[J]. Proceedings of the VLDB Endowment, 2023, 16(11): 3391-3403. DOI: 10.14778/3611479.3611534.
- [42] FÜRST J, ARGERICH M F, CHENG B. VersaMatch: Ontology Matching with Weak Supervision[J]. Proceedings of the VLDB Endowment, 2023, 16(6): 1305-1318. DOI: 10.14778/3583140.3583148.
- [43] KRISHNAN S, WANG J, WU E, et al. ActiveClean: interactive data cleaning for statistical modeling[J]. Proceedings of the VLDB Endowment, 2016, 9(12): 948-959. DOI: 10.14778/2994509.2994514.
- [44] CHEN D, HUANG Y, MA Z, et al. Data-Juicer: A One-Stop Data Processing System for Large Language Models[C]//Companion of the 2024 International Conference on Management of Data. New York: ACM, 2024: 120-134. DOI: 10.1145/3626246.3653385.
- [45] YANG J, HE Y, CHAUDHURI S. Auto-Pipeline: Synthesizing Complex Data Pipelines By-Target Using Reinforcement Learning and Search[J]. Proceedings of the VLDB Endowment, 2021, 14(11): 2563-2575. DOI: 10.14778/3476249.3476303.
- [46] LI P, CHEN Z, CHU X, et al. DiffPrep: Differentiable Data Preprocessing Pipeline Search for Learning over Tabular Data[J]. Proceedings of the ACM on Management of Data, 2023, 1(2): 1-26. DOI: 10.1145/3589328.
- [47] PRIMPELI A, BIZER C. Profiling Entity Matching Benchmark Tasks[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. 2020: 3101-3108. DOI: 10.1145/3340531.3412781.
- [48] KOUTRAS C, SIACHAMIS G, IONESCU A, et al. Valentine: Evaluating Matching Techniques for Dataset Discovery[C]//2021 IEEE 37th International Conference on Data Engineering (ICDE). 2021: 468-479. DOI: 10.1109/icde51399.2021.00047.