

智能数据准备研究综述

范举 范梅浩

中国人民大学信息学院，数据工程与知识工程教育部重点实验室
北京 100872

1 引言

数据分析和机器学习依赖适合使用的数据，而实际记录常分散在不同系统中，并伴随含义不明、格式不一、重复和缺失等问题。例如，销售、财务和售后部门分别记录订单、回款与退款，汇总收入前需要确定记录之间的关系和统一的统计口径。智能数据准备利用规则、学习模型和交互反馈，把这些原始记录整理为能够支持分析的数据，其作用涉及结果可靠性、处理效率和团队协作。^[1, 2] 数据质量研究强调，准确、完整和一致等要求需要结合使用情境判断，表格整齐或程序运行成功并不足以说明数据适合目标用途。^[3, 4]

该领域的研究已经由辅助单项操作扩展到组织完整流程。交互工具根据用户示范生成脚本，学习模型处理难以穷举的语义关系，大语言模型则从大量文本中学习语言规律，支持需求解释和程序生成。范举及合作者围绕统一匹配、人工与自动流程组合、问题感知准备和执行反馈开展研究，李国良及合作者关注交互清洗、低成本匹配和自然语言准备评测，高云君及合作者从数据集成拓展到知识增强、流程表达与搜索。^[5-15] 这些工作与国际研究共同推动了语义推断和数据系统执行能力的结合。

从发展阶段看，研究重点正在由固定数据上的局部识别转向带有目标和反馈的完整任务。现有方法已经能够组合多步操作，但在跨部门口径、跨领域迁移和持续更新条件下的稳定性仍缺少充分证据。因此，当前进展应从任务覆盖、结果可靠性和所需人工投入共同判断，不能仅由生成程序的复杂程度衡量。

1.1 文献范围与筛选

本文讨论关系表、异构记录及元数据，并覆盖标签、样本选择和训练语料准备。文献库包含 48 项国内外研究，检索截止日期为 2026 年 9 月 9 日。既有 34 项文献作为追溯种子，另以不含作者姓名的主题查询补充检索，减少从特定团队出发的选择偏差。结构化检索使用 Crossref，出版版本与原文通过 ACM、IEEE、PVLDB、ACL Anthology、arXiv、中文期刊官网及作者机构页面核查。

固定查询采用 Crossref 的题名相关度接口，检索 table union search、semantic type detection、data cleaning、entity matching、table transformation、weak supervision、data preprocessing pipeline 和 data preparation。时间范围为 2009 年 1 月 1 日至检索截止日，每式保留相关度前 15 条，共 120 条，去重后 117 项。初筛排除同名异义、一般应用介绍和非独立研究材料 83 项，复筛 34 项，按机制、监督条件和评测差异纳入 10 项，另经引文与主题追溯补充 4 项。复筛其余 24 项记为范围取样未纳入，不据此否定其质量。查询参数、版本合并及逐项决定保存在随文检索台账中。

作者和机构不作为纳入条件。48 项中 36 项用于方法或基准分析，12 项作为综述、规范及主题背景。查询截断、Crossref 收录差异及公开全文可得性仍带来遗漏风险，本文不宣称穷尽覆盖，也不反推既有 34 项文献的历史筛选数量。不同研究的结果仅在目标信息、数据和模型条件可比时讨论。

1.2 已有综述与本文侧重

已有综述从不同层次解释数据准备。高云君等围绕关系数据和知识图谱讨论解析、融合与清洗, Chai 等从机器学习生命周期组织数据管理问题。^[2, 12] 刘祺等讨论数据质量的概念与方法, 周立等比较时序缺失条件及补全评测, 为界定质量和控制实验条件提供了参照。^[4, 16] Chen 等分析语言模型参与表格准备的阶段、完整流程和评测, Zhou 等关注应用就绪的数据准备, Liang 等则讨论为大模型训练准备数据。^[17-19] 后者的对象是训练语料, 与利用语言模型清洗表格有所区别。

本文进一步联系任务输出、输入监督、流程状态和验证依据, 分析单项能力如何转化为完整任务的收益。已有综述已经讨论流程与成本, 本文的侧重点在于说明这些维度之间的关系: 目标信息决定系统需要推断什么, 中间状态决定能够修订什么, 验证依据决定能够发现什么错误。后文据此比较方法与实验, 区分候选探索、流程完成和任务正确, 避免仅以是否使用大模型判断自动化水平。

2 基本概念与应用需求

数据准备是围绕特定用途发现、理解、修改和组织数据的过程。数据清洗侧重错误检测与修复, 数据集成侧重跨源对应与一致表示, 数据预处理通常指分析或训练前的具体变换。三者可以交叉, 本文按输入、操作和输出对象确定任务边界。例如, 推断两条记录是否属于同一客户是匹配, 按已经确定的客户编号连接表格是结构转换。

数据准备可分为六类任务。数据发现输出相关资源及候选关联, 语义理解输出列类型或字段对应, 清洗修复输出错误位置及修复值, 匹配融合输出记录对应或统一实体, 结构转换输出目标表或程序, 标注增强输出标签、训练子集或处理后的语料。标签作为模型输入不意味着该工作属于标注任务, 只有生成或选择监督信息本身是评价目标时才归入该类。多任务研究按可独立评价的输出分别归类, 流程能力另行记录, 不强行进行互斥统计。

图1将数据来源、准备任务与应用用途联系起来。六类任务可以按目标组合, 图中连线不规定固定顺序。同一来源可能支持不同用途, 也可能需要不同处理规则。数据准备的产物因此不仅包括结果表, 还包括可重复执行的步骤及其来源、修改和核验记录。

在工作报表中, 智能工具可以识别对应字段、统一日期和金额格式、发现重复记录, 但按下单时间还是到账时间统计仍需业务确认。在商品比较和客户资料整合中, 名称相似只是候选线索, 规格、单位和对象身份需要进一步核对。出行信息整理还涉及站点别名、更新时间与使用日期。这些场景说明, 数据准备处理的是信息在具体条件下能否共同使用, 而不仅是文件能否合并。

科研与模型训练对来源和可比条件的要求更严格。不同实验可能采用不同单位、采样范围和记录方式, 合并前需要说明其关系。训练样本中的重复内容、缺失信息和错误标签则可能影响模型判断。上述应用是对技术需求的概括, 并不对应特定商业产品的部署效果。对使用者而言, 智能化的价值在于减少重复操作, 同时保留判断依据, 使结果能够被复查和更新。




图 1 智能数据准备的任务与应用

3 关键技术及其发展

3.1 数据发现与语义理解

数据发现首先回答相关数据位于何处、不同资源可能存在何种联系。Aurum 通过关系索引与发现操作组织跨源检索, Table Union Search 根据值域和语义证据寻找能够合并的表, SANTOS 进一步利用列间关系补充逐列相似性。^[20-22] 这些方法逐步将发现依据由单列特征扩展到表内关系, 但候选相似不等于符合当前任务。扩大候选集合可能提高召回, 也会增加后续核验成本。

语义理解把候选关系转化为具体含义判断。Sato 结合列值、表级主题和结构化预测识别列类型, Unicorn 在模式匹配、列类型标注和实体匹配之间共享表示。^[5, 23] 前者利用同表上下文, 后者扩大跨任务知识复用的范围。语言模型可以联合读取说明、表头和样例值, 但单位、编码和统计粒度仍需明确依据, 语义相近不能直接作为字段可替换的条件。^[17, 24]

跨领域应用使监督获取成为重要问题。STEER 通过数据编程生成新数据湖的训练标签, 再适配类型模型; SportsTables 集中考察数值列较多时的识别表现。^[25, 26] 这些工作说明, 迁移能力既涉及表示方法, 也涉及新域标签和数据特征。并表基准的再分析还发现, 简单方法可能利用数据集特有线索取得较高分, 因此不能把基准得分直接解释为普遍的语义理解能力。^[27]

3.2 错误检测、修复与补全

检测回答哪里可能有错, 修复进一步决定如何修改, 两者需要分别评价。HoloClean 综合约束、统计关系和参考信息推断修复值, Raha 组织多种检测策略并利用少量用户标注降低配置负担, Falcon 从用户修复中形成可推广的确定性更新规则。^[9, 28, 29] 三类方法分别强调多证据推断、监督选择和修复经验复用, 适用条件取决于哪些信息能够获得。

Baran 通过统一上下文表示和迁移组织纠错候选, 与检测系统结合时仍需区分错误定位和修复选择的损失。^[30] 基础模型和 Jellyfish 将错误检测、缺失补全与匹配表达为语言任务, 增强了多任务复用能力。^[24, 31] 不过, 模型给出的解释并不构成事实证据。已知记录支持的纠错和对不可观测值的估计应分开保存, 尤其不能把满足约束视为恢复真实值的充分条件。

补全方法还受到缺失形成机制的限制。随机遮蔽得到的重构误差, 未必代表业务选择性缺失下的效果。周立等对缺失场景、缺失率和下游评价的梳理说明, 比较前需要控制数据形成条件。^[16] REIN 进一步把检测、修复和学习效果放在同一框架下观察, 表明局部质量与后续用途需要共同评价。^[32]

3.3 实体匹配与多源融合

实体匹配判断不同记录是否指向同一对象, 融合继续处理属性冲突、来源差异和表示统一。错误匹配会把不同对象合并, 错误的融合规则则可能在对象对应正确时选错属性值, 两者的失败来源不同。^[12] 候选生成也会限制最终召回, 不能仅评价预先筛选后的记录对。

DeepMatcher 比较表示与聚合设计, Ditto 通过预训练模型微调完成记录对分类, Unicorn 侧重跨匹配任务的知识共享。^[5, 33, 34] 这几类方法都利用学习表示, 但训练组织和泛化目标不同。BATCHER 则从示例选择和问题分批出发, 让多个实体解析问题共享提示上下文, 以权衡匹配质量与调用开销。^[10] 减少重复上下文并不消除示例标签成本, 批内问题的区分和示例质量仍影响结果。

融合还需考虑信息的时间有效性及来源之间的依赖。简单多数投票可能覆盖较新的有效记录, 也可能放大相互转载的信息。保留冲突候选、来源及选取规则, 能够让融合决定被复查。^[3, 12] 这也说明, 匹配模型的分类分数不能代表完整集成流程的可靠性。

3.4 结构转换与程序生成

结构转换处理字段拆分、类型转换、宽窄表重塑、连接与聚合等操作。Wrangler 根据交互示范生成脚本, Morpheus 根据输入输出示例搜索满足组件规范的程序。^[35, 36] 前者由用户逐步确定操作, 后者将部分目标转化为可计算的示例一致性。它们都需要用户表达目标, 但提供目标信息的方式不同。

Auto-Tables 不要求转换后的示例表, 而是学习算子与参数并保留多个候选, 将非规范表格恢复为适合分析的关系结构。^[37] 该路线说明自动转换不必依赖自然语言接口, 但结构规范仍不等于业务含义正确。语言模型生成代码扩大了可表达操作的范围, 也增加了验证复杂度。受控操作集合便于检查类型和前置条件, 自由代码适合表达更复杂的处理, 选择取决于任务需求与可获得的验证依据。^[7, 15]

3.5 标注、选样与训练数据准备

标签用于说明样本的类别或预期结果, 例如标明评论的情感倾向。Snorkel 让用户以规则表达领域知识, 并对含噪、冲突的弱标签建模, 减少逐样本标注。^[38] VersaMatch 也利用规则、模式及外部知识形成弱监督, 但其最终目标是本体匹配, 应按输出归入语义理解。^[39] 共享监督机制并不意味着任务相同。

ActiveClean 在凸损失模型训练中逐步清洗重要记录, GoodCore 将不完整数据的补全与训练子集选择结合, 兼顾模型效果、训练效率和补全投入。^[40, 41] 它们体现了按用途安排准备资源的思路, 也受到下游模型及优化假设的限制。Data-Juicer 将语料分析与处理组织为可组合流程, 相关综述进

一步区分预训练、持续预训练和后训练的数据需求。^[19, 42] 语料去重、过滤和配比应围绕训练贡献评价, 不能用单一过滤分数表示全部价值。

图2综合比较三类实现路线的依据、处理方式和能力边界。规则与工具适合目标明确的重复操作, 学习方法处理从样本和上下文中归纳的关系, 任务智能体则围绕目标连续调用工具并依据反馈修订。智能体是能够观察执行结果、决定后续动作的程序, 多任务模型本身未必具有这种流程能力。三类方法相互补充, 监督需求也可能由实例标签转移到任务说明、提示示例和核验规则。对部署者而言, 首先需要确认这些资源是否可得。有大量可靠标签时可以适配局部模型, 有稳定操作规范时可以复用工具, 有复杂需求时再组织交互与流程搜索。把模型换成规模更大的版本, 并不会自动提供缺失的业务知识, 也未必减少检查和维护负担。



图 2 数据准备方法的能力与适用条件

4 任务感知的数据准备流程

4.1 目标信息与流程构造

单项操作的改进不一定产生更好的整体结果。清洗会改变匹配候选, 连接可能放大重复记录, 过滤会改变训练样本分布, 因此流程需要同时考虑目标、顺序和数据依赖。DiffPrep 依据验证集损失优化预处理选择与顺序, HAIPipe 搜索人工流程和自动流程的组合。^[6, 43] 两者都利用固定学习任务的表现选择候选, 但前者依赖可微模型与受限操作空间, 后者把已有流程作为重要先验。

目标表合成提供另一类监督。Morpheus 使用当前输入的正确输出示例, Auto-Pipeline 使用另一批数据的类比目标表, 并从中提取模式、键和依赖约束。^[36, 44] 类比目标含具体记录, 却不是当前任务的正确答案。与之相比, BAT 不使用目标表实例, 仍需要目标模式等信息。这些条件决定系统需要自行推断的范围, 不能统一称为“目标引导”后直接比较成功率。

AutoPrep 面向表格问答, 将问题语义分解为逻辑准备操作, 再生成工具或代码实现。^[7] Text-to-Pipeline 则研究自然语言准备意图与操作组合之间的映射, 并利用中间执行状态组织后续步骤。^[14] 前者强调服务固定问答任务, 后者强调指令到流程的对应。自然语言降低了表达门槛, 但日期范围、去重标准和统计粒度仍可能含糊, PrepBench 因而将交互澄清与代码生成分别评价。^[11]

4.2 状态、反馈与停止条件

中间状态决定系统能观察到什么。只记录模式可以排除类型不相容的操作, 却难以发现相同模式下的错误聚合; 保存实际中间表能够暴露值和记录数量变化, 同时增加存储与访问成本。DeepPrep 保存中间状态, 通过树状推理回到较早步骤修订, BAT 则在受控操作环境中开展语言模型驱动树的搜索。^[8, 15] 前者结合训练学习修订行为, 后者侧重免训练搜索, 两者的监督和成本构成不同。

搜索回溯也有不同含义。撤销候选程序、同时保留多条路径和恢复已经保存的中间表, 分别作用于候选空间与执行状态。它们都需要有效失败信号, 增加分支不能弥补未被观察到的语义错误。同样, 满足目标模式、找到示例一致程序、验证损失不再改善或达到预算上限, 都是具体停止条件, 不能统一解释为任务已经正确完成。方法选择应连同允许操作、状态保存、反馈来源和停止规则一起考察。多表能力也需要按处理对象区分: 比较来自两张表的记录对, 与规划跨表连接、聚合和清洗流程属于不同能力。公开代码、模型和基准可以支持复查, 尚未核实某项功能时则应保留判断, 不能从论文未强调该功能推断系统不支持。

图3归纳任务说明、方案生成、工具执行与结果核验的关系。图中的规则检查和来源对照是可采用的验证依据, 并不表示所有系统已经具备同等验证能力。语义不明确时先确认目标, 操作有误时修订方案, 再从适当中间状态执行。处理记录有助于复现, 但其存在本身不证明结果正确。




图 3 数据准备流程中的核验与修订

4.3 多步错误传播的实例

以一位客户的两笔订单为例, 金额分别为 100 和 80, 第一笔订单有两条退款记录, 金额为 20 和 10。任务要求保留两笔订单、计入全部有效退款, 并计算该客户净收入, 不涉及币种转换和退款冲正。直接把订单与退款连接, 再逐行相减求和, 会把第一笔订单金额计入两次, 得到 250。若先按订单汇总退款, 再连接并计算, 正确结果为 150。两条流程都能运行, 最终客户字段也可以唯一, 表面结构检查无法揭示重复计入。

有效检查应与任务条件对应。在本例计算每单净收入之前, 每个订单应只出现一次, 最终总额还应等于原订单金额减去全部有效退款。发现重复后, 恢复到连接前状态并增加退款聚合即可修订。如果订单范围或退款规则改变, 检查条件也必须更新。这个作者构造的算术实例说明了检查与回退的关系, 不表示真实任务中的错误频率; 随文 SQLite 脚本可核对两条路径及退款金额变化后的结果。

有输出示例的系统可以据此排除错误路径, 仅知列名的系统则无法推得“每单只计一次”。保存状态的智能体能够重建前序步骤, 前提仍是核验发现了问题。跨域复用时也有类似限制: Unicorn、Jellyfish 与 KnowTrans 分别研究任务共享或知识迁移, 但组件可迁移不意味着关联顺序、过滤条件和验证规则能够直接沿用。^[5, 13, 31]

5 评测基准与结果分析

5.1 评价对象与可比条件

评测需要区分局部质量、流程正确性、下游效用和成本。错误检测、类型识别与匹配通常评价准确性或召回, 补全关注修复误差和误修改比例; 这些结果依赖标注粒度、类别比例与缺失机制。流程完成率只反映是否运行结束, 输出比较进一步检查结构和值, 操作序列比较则衡量程序表达。不同程序可能产生相同结果, 在单个输入上结果一致也不保证对其他输入仍正确。

下游问答或预测指标还受到后端模型影响, 比较时需要固定数据划分、模型和目标信息。用于选择流程的验证集与最终测试集应分开, 避免反复选择利用测试答案。成本应同时记录模型调用、工具执行、存储和人工投入, 包括搜索、失败重试与候选确认。公开代码或模型有助于复查, 但不能代替版本、环境和参数说明, 本文也未重新执行所综述系统。

5.2 代表性基准

组件基准分别覆盖列、记录和修复任务。SportsTables 包含 1187 张表、24838 列, 约 86% 为数值列, 用于考察语义类型识别。^[26] 实体匹配任务画像整理并补充 21 项任务, 强调候选和负例构造对难度的影响。^[45] Valentine 包含 540 组合成表对, 并加入 WikiData、Magellan 及 ING 数据, 比较数据发现中的模式匹配与时延, 其中两组工业数据不公开。^[46] 其召回按真实映射数量确定截断位置, 与任意固定阈值下的分类指标不同。REIN 以 14 个数据集组织 19 类检测器、19 类修复方法和 33 种学习模型, 联系清洗质量与预测效果。^[32]

流程基准则逐步扩展操作组合和交互条件。ATBench 包含 244 个表格关系化案例, 其中 26 个为多步任务, 评价候选命中与合成时间。^[37] PARROT 的 v2 版本包含 17168 项任务、16 类操作, 源表池为 23009 张表, 用输出、程序有效性和操作准确性评价流程。^[14] PrepBench 基于 Preppin' Data 扩展 306 项任务、829 张输入表及 32 个领域, 流程含 3 至 18 步, 分别评价澄清、代码和工作流转换。^[11] 前者便于规模化研究操作组合, 后者更关注含糊需求与流程表达。

DeepPrep 使用 SQL 衍生任务及其他准备数据, 其中 Synth-Spider 测试集为 2008 项、Synth-Bird 为 1150 项, 改写 Parrot 为 1365 项, Buildings 为 105 项。^[8] 改写 Parrot 与原 PARROT 测试集并非同一版本。PARROT 输出比较允许数值容差, DeepPrep 采用单元格精确比较, 得分差异可能来自判定协议。任务数也不能替代覆盖分析, 合成规模、来源差异、目标信息及长期更新需求应分别考察。

5.3 原论文结果支持的认识

候选生成与最终选择是不同能力。Auto-Tables 在 ATBench 上的首选命中率为 57.0%, 前三个候选中至少命中一个的比例为 75.0%。^[37] 后者按作者代码在首次命中后计一次, 不能解释为全自动首选正确率。原论文平均合成时间为 0.224 秒, 对应 24 个虚拟处理器和 4 块 P100 的环境, 并未计入人工筛选时间。增加候选扩大了探索范围, 同时保留了选择正确结果的负担。

目标信息同样改变任务难度。PrepBench 的 v1 实验中, GPT-5.1-Codex 在端到端代码任务上的准确率为 54.9%, 给定无歧义说明后为 85.3%, 端到端工作流任务则为 34.6%。^[11] 三种设置每任务调用费用分别为 0.11540、0.08274 和 0.26410 美元, 包含相应路径的调用与重试。该结果显示, 单项代码能力不能代表包含澄清和流程转换的整体表现, 更多调用也不必然带来更高准确率。

流程完成与结果正确之间仍有明显差距。DeepPrep 在 Qwen3-14B 和 Synth-Spider 设置下的完成率为 97.21%, 目标表准确率为 67.18%。^[8] 同一训练数据下, 模仿学习基线的准确率为 61.70%, 差值支持训练与推理方案的联合收益, 不能单独归因于回退。原论文还报告过只重命名列以满足表面模式的失败行为, 表明停止条件可能满足, 而所需变换仍未完成。

下游收益应在固定后端中解释。AutoPrep 采用 DeepSeek-V2.5-Chat 时, 将自然语言转 SQL 基线在 WikiTQ 上的答案准确率从 52.83% 提高到 66.09%, 在 TabFact 上从 70.21% 提高到 87.85%。^[7] 这些变化衡量准备与问答结合的效果, 并非准备表本身的准确率。该对照固定问答后端与提示设置, 未逐项分列费用, 因而不能据此估算准备环节的成本收益。DiffPrep 在 connect-4、逻辑回归和 60/20/20 数据划分下, 固定顺序变体取得 73.2%, 适配多分类的 BoostClean 为 69.0%, 扩大顺序搜索的变体为 70.1%。^[43] 搜索空间扩大未必改善特定任务, 准备方案需要与下游模型共同选择。

成本比较也需要一致边界。PrepBench 同一端到端代码协议中, Gemini 3 Flash 准确率为 53.3%, 每任务费用为 0.02140 美元, 与上述 GPT 配置相比表现相近而调用费更低。^[11] 这只能支持原数据、模型版本和核算条件下的权衡, 不能外推为当前价格或跨任务排名。原论文未报告的人工、训练及维护开销也不能记为零。总体上, 现有证据支持按任务条件选择方法, 尚不足以证明某一路线在完整质量和成本上普遍占优。

6 研究挑战与发展方向

任务语义的获取仍是流程自动化的基础困难。PrepBench 的对照显示, 明确说明与端到端交互存在较大差距, 据此可以归纳出目标解释和操作实现需要分别评价。^[11] 未来可将关键条件记录为可检查的任务说明, 在不同解释会改变结果时发起澄清。例如, “活跃客户”应明确时间范围及登录、消费或订阅标准。这种选择性提问能否降低总投入, 仍需在固定交互预算下与一次性说明、增加对话轮次等策略比较。

迁移需要区分名称变化、数据分布变化和业务规则变化。SportsTables、STEER 及多任务模型分别提供了不同数据特征、监督获取和知识共享的研究证据。^[5, 25, 26] 由这些工作可进一步归纳, 组件适配与整套流程复用属于不同问题。未来可以为组件记录适用字段、单位、来源和规则版本, 在

数据变化后定位需要重算或核验的步骤。局部更新是否优于整体重建, 应分别通过列重命名、单位变更及目标口径变化验证, 不能仅用一次跨数据集测试概括。

独立验证与错误传播控制决定修订是否有效。DeepPrep 的完成率与准确率差距, 以及前述退款反例, 都说明更充分的执行并不等于更充分的语义检查。^[8] 研究可将类型、键、总额和来源约束与候选生成结合, 明确每类检查的覆盖范围。在固定搜索预算下, 需要同时测量错误检出、误拒绝和回退成本。对于依据不足的事实修复, 保留候选或暂不修改也应作为可评价的输出, 而非强制生成一个确定值。

持续维护是现有评测覆盖较少的环节。数据新增、字段定义调整和模型更新都可能使已有流程失效, 重新生成全部结果也可能造成重复投入。Datasheets 与 FAIR 强调来源、用途及可复用的信息记录, 为长期管理提供基础, 但准备过程仍需保存操作、参数与人工确认。^[47, 48] 未来可在连续数据版本上比较复用、局部重算和完全重跑, 评价变化后的错误率、状态保存成本与人工修订时间。这属于根据评测不足提出的研究方向, 尚不能认为长期成本收益已经得到充分验证。

技术改进还需要组织协作的支持。为常用字段维护定义、单位和责任部门, 为更新设置版本, 为已知错误保存检查规则, 能够为模型提供稳定依据。在人机分工上, 规则明确的操作可由工具批量执行, 关键业务条件和高影响修改由人员确认。评价重点应是减少整项任务中的重复劳动和返工, 而不是单纯减少人工点击或提高自动生成比例。这些要求将数据管理、学习方法与领域知识联系起来, 也是研究从实验走向持续应用需要补足的条件。

7 结语

智能数据准备连接原始数据与分析应用, 其研究已经从单项检测、匹配和变换扩展到目标解释、流程构造及反馈修订。对 48 项文献的分析表明, 目标监督决定自动化边界, 中间状态和验证依据分别影响可修订范围与错误发现能力, 下游模型及成本口径共同限定方法收益。未来应在具体使用条件下发展可解释的任务表达、可复用的准备组件和可检查的执行流程, 并通过覆盖质量、效用与维护成本的评测检验进步。


参考文献

- [1] CHAI C, TANG N, FAN J, et al. Demystifying Artificial Intelligence for Data Preparation[C]//Companion of the 2023 International Conference on Management of Data. New York: ACM, 2023: 13-20. DOI: 10.1145/3555041.3589406.
- [2] CHAI C, WANG J, LUO Y, et al. Data Management for Machine Learning: A Survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(5): 4646-4667. DOI: 10.1109/tkde.2022.3148237.
- [3] BATINI C, CAPPIELLO C, FRANICALANCI C, et al. Methodologies for Data Quality Assessment and Improvement[J]. ACM Computing Surveys, 2009, 41(3): 16:1-16:52. DOI: 10.1145/1541880.1541883.
- [4] 刘祺, 黄君义, 冯耕中, 等. 数字经济发展根基: 数据质量研究述评与未来展望[J]. 系统工程理论与实践, 2025, 45(7): 2101-2123. DOI: 10.12011/SETP2023-2891.
- [5] TU J, FAN J, TANG N, et al. Unicorn: A Unified Multi-tasking Model for Supporting Matching Tasks in Data Integration[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 84:1-84:26. DOI: 10.1145/3588938.
- [6] CHEN S, TANG N, FAN J, et al. HAIPipe: Combining Human-generated and Machine-generated Pipelines for Data Preparation[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 91:1-91:26. DOI: 10.1145/3588945.
- [7] FAN M, FAN J, TANG N, et al. AutoPrep: Natural Language Question-Aware Data Preparation with a Multi-Agent Framework[J]. Proceedings of the VLDB Endowment, 2025, 18(10): 3504-3517. DOI: 10.14778/3748191.3748211.
- [8] FAN M, FAN J, ZHANG Y, et al. DeepPrep: An LLM-Powered Agentic System for Autonomous Data Preparation[J]. Proceedings of the VLDB Endowment, 2026, 19(11): 3371-3384. DOI: 10.14778/3836663.3836695.
- [9] HE J, VELTRI E, SANTORO D, et al. Interactive and Deterministic Data Cleaning: A Tossed Stone Raises a Thousand Ripples[C]//Proceedings of the 2016 International Conference on Management of Data. ACM, 2016: 893-907. DOI: 10.1145/2882903.2915242.
- [10] FAN M, HAN X, FAN J, et al. Cost-Effective In-Context Learning for Entity Resolution: A Design Space Exploration[C]//2024 IEEE 40th International Conference on Data Engineering (ICDE). IEEE, 2024: 3696-3709. DOI: 10.1109/icde60146.2024.00284.
- [11] XU J, WANG R, WANG J, et al. PrepBench: How Far are We from Natural-Language-Driven Data Preparation?[J]. Proceedings of the VLDB Endowment, 2026, 19(10): 2866-2879. DOI: 10.14778/3828612.3828638.
- [12] 高云君, 葛丛丛, 郭宇翔, 等. 面向关系型数据与知识图谱的数据集成技术综述[J]. 软件学报, 2023, 34(5): 2365-2391. DOI: 10.13328/j.cnki.jos.006808.
- [13] GE Y, LI F, MAO Y, et al. KnowTrans: Boosting Transferability of Data Preparation LLMs via Knowledge Augmentation[C]//2025 IEEE 41st International Conference on Data Engineering. Piscataway: IEEE, 2025: 2852-2866. DOI: 10.1109/ICDE65448.2025.00214.
- [14] GE Y, LIU Y, YE Z, et al. Text-to-Pipeline: Bridging Natural Language and Data Preparation Pipelines[EB/OL]. (2025-11-10) [2026-09-09]. <https://arxiv.org/abs/2505.15874v2>.
- [15] GE C, LIU Y, TANG Y, et al. BAT: Target-Instance-Free Data Preparation Synthesis via LLM-Driven Tree Search[J]. Proceedings of the ACM on Management of Data, 2026, 4(3): 143:1-143:25. DOI: 10.1145/3802020.
- [16] 周立, 吴洋洋, 苗晓晔. 基于深度学习的完整时序数据补全方法综述[J]. 计算机研究与发展, 2025, 62(9): 2233-2258. DOI: 10.7544/issn1000-1239.20250449.
- [17] CHEN M, SUN Y, LI T, et al. Empowering Tabular Data Preparation with Language Models: Why and How?[C]//Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2026: 228-246. DOI: 10.18653/v1/2026.acl-long.8.
- [18] ZHOU W, ZHOU J, WANG H, et al. Can LLMs Clean Up Your Mess? A Survey of Application-Ready Data Preparation with LLMs[EB/OL]. (2026-01-22) [2026-09-09]. <https://arxiv.org/abs/2601.17058v1>.

- [19] LIANG H, WONG Z H, LIU R T, et al. Data Preparation for Large Language Models[J]. Journal of Computer Science and Technology, 2026, 41(1): 289-317. DOI: 10.1007/s11390-026-5948-8.
- [20] CASTRO FERNANDEZ R, ABEDJAN Z, KOKO F, et al. Aurum: A Data Discovery System[C]//2018 IEEE 34th International Conference on Data Engineering (ICDE). IEEE, 2018: 1001-1012. DOI: 10.1109/icde.2018.00094.
- [21] NARGESIAN F, ZHU E, PU K Q, et al. Table union search on open data[J]. Proceedings of the VLDB Endowment, 2018, 11(7): 813-825. DOI: 10.14778/3192965.3192973.
- [22] KHATIWADA A, FAN G, SHRAGA R, et al. SANTOS: Relationship-based Semantic Table Union Search[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 1-25. DOI: 10.1145/3588689.
- [23] ZHANG D, HULSEBOS M, SUHARA Y, et al. Sato: contextual semantic type detection in tables[J]. Proceedings of the VLDB Endowment, 2020, 13(12): 1835-1848. DOI: 10.14778/3407790.3407793.
- [24] NARAYAN A, CHAMI I, ORR L, et al. Can Foundation Models Wrangle Your Data?[J]. Proceedings of the VLDB Endowment, 2022, 16(4): 738-746. DOI: 10.14778/3574245.3574258.
- [25] LANGENECKER S, STURM C, SCHALLES C, et al. Steered Training Data Generation for Learned Semantic Type Detection[J]. Proceedings of the ACM on Management of Data, 2023, 1(2): 201:1-201:25. DOI: 10.1145/3589786.
- [26] LANGENECKER S, STURM C, SCHALLES C, et al. SportsTables: A New Corpus for Semantic Type Detection (Extended Version)[J]. Datenbank-Spektrum, 2023, 23(3): 189-197. DOI: 10.1007/s13222-023-00457-y.
- [27] BOUTALEB A, AMANN B, NAACKKE H, et al. Something's Fishy in the Data Lake: A Critical Re-evaluation of Table Union Search Benchmarks[C]//Proceedings of the 4th Table Representation Learning Workshop. 2025: 71-85. DOI: 10.18653/v1/2025.trl-1.7.
- [28] REKATSINAS T, CHU X, ILYAS I F, et al. HoloClean: Holistic Data Repairs with Probabilistic Inference[J]. Proceedings of the VLDB Endowment, 2017, 10(11): 1190-1201. DOI: 10.14778/3137628.3137631.
- [29] MAHDAVI M, ABEDJAN Z, CASTRO FERNANDEZ R, et al. Raha: A Configuration-Free Error Detection System[C]//Proceedings of the 2019 International Conference on Management of Data. ACM, 2019: 865-882. DOI: 10.1145/3299869.3324956.
- [30] MAHDAVI M, ABEDJAN Z. Baran: Effective Error Correction via a Unified Context Representation and Transfer Learning[J]. Proceedings of the VLDB Endowment, 2020, 13(12): 1948-1961. DOI: 10.14778/3407790.3407801.
- [31] ZHANG H, DONG Y, XIAO C, et al. Jellyfish: Instruction-Tuning Local Large Language Models for Data Preprocessing[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2024: 8754-8782. DOI: 10.18653/v1/2024.emnlp-main.497.
- [32] ABDELAAL M, HAMMACHER C, SCHÖNING H. REIN: A Comprehensive Benchmark Framework for Data Cleaning Methods in ML Pipelines[C/OL]//Proceedings of the 26th International Conference on Extending Database Technology. 2023: 499-511. <https://openproceedings.org/2023/conf/edbt/3-paper-49.pdf>. DOI: 10.48786/edbt.2023.43.
- [33] MUDGAL S, LI H, REKATSINAS T, et al. Deep Learning for Entity Matching[C]//Proceedings of the 2018 International Conference on Management of Data. 2018: 19-34. DOI: 10.1145/3183713.3196926.
- [34] LI Y, LI J, SUHARA Y, et al. Deep entity matching with pre-trained language models[J]. Proceedings of the VLDB Endowment, 2020, 14(1): 50-60. DOI: 10.14778/3421424.3421431.
- [35] KANDEL S, PAEPCKE A, HELLERSTEIN J M, et al. Wrangler: Interactive Visual Specification of Data Transformation Scripts[C]//Proceedings of the SIGCHI Conference on Human Factors in Computing Systems. New York: ACM, 2011: 3363-3372. DOI: 10.1145/1978942.1979444.
- [36] FENG Y, MARTINS R, VAN GEFFEN J, et al. Component-based synthesis of table consolidation and transformation tasks from examples[C]//Proceedings of the 38th ACM SIGPLAN Conference on Programming Language Design and Implementation. 2017: 422-436. DOI: 10.1145/3062341.3062351.

- [37] LI P, HE Y, YAN C, et al. Auto-Tables: Synthesizing Multi-Step Transformations to Relationalize Tables without Using Examples[J]. Proceedings of the VLDB Endowment, 2023, 16(11): 3391-3403. DOI: 10.14778/3611479.3611534.
- [38] RATNER A, BACH S H, EHRENBERG H, et al. Snorkel: rapid training data creation with weak supervision[J]. Proceedings of the VLDB Endowment, 2017, 11(3): 269-282. DOI: 10.14778/3157794.3157797.
- [39] FÜRST J, ARGERICH M F, CHENG B. VersaMatch: Ontology Matching with Weak Supervision[J]. Proceedings of the VLDB Endowment, 2023, 16(6): 1305-1318. DOI: 10.14778/3583140.3583148.
- [40] KRISHNAN S, WANG J, WU E, et al. ActiveClean: interactive data cleaning for statistical modeling[J]. Proceedings of the VLDB Endowment, 2016, 9(12): 948-959. DOI: 10.14778/2994509.2994514.
- [41] CHAI C, LIU J, TANG N, et al. GoodCore: Data-effective and Data-efficient Machine Learning through Coreset Selection over Incomplete Data[J]. Proceedings of the ACM on Management of Data, 2023, 1(2): 157:1-157:27. DOI: 10.1145/3589302.
- [42] CHEN D, HUANG Y, MA Z, et al. Data-Juicer: A One-Stop Data Processing System for Large Language Models[C]//Companion of the 2024 International Conference on Management of Data. New York: ACM, 2024: 120-134. DOI: 10.1145/3626246.3653385.
- [43] LI P, CHEN Z, CHU X, et al. DiffPrep: Differentiable Data Preprocessing Pipeline Search for Learning over Tabular Data[J]. Proceedings of the ACM on Management of Data, 2023, 1(2): 1-26. DOI: 10.1145/3589328.
- [44] YANG J, HE Y, CHAUDHURI S. Auto-Pipeline: Synthesizing Complex Data Pipelines By-Target Using Reinforcement Learning and Search[J]. Proceedings of the VLDB Endowment, 2021, 14(11): 2563-2575. DOI: 10.14778/3476249.3476303.
- [45] PRIMPELI A, BIZER C. Profiling Entity Matching Benchmark Tasks[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. 2020: 3101-3108. DOI: 10.1145/3340531.3412781.
- [46] KOUTRAS C, SIACHAMIS G, IONESCU A, et al. Valentine: Evaluating Matching Techniques for Dataset Discovery[C]//2021 IEEE 37th International Conference on Data Engineering (ICDE). 2021: 468-479. DOI: 10.1109/icde51399.2021.00047.
- [47] GEBRU T, MORGENSTERN J, VECCHIONE B, et al. Datasheets for Datasets[J]. Communications of the ACM, 2021, 64(12): 86-92. DOI: 10.1145/3458723.
- [48] WILKINSON M D, DUMONTIER M, AALBERSBERG I J, et al. The FAIR Guiding Principles for Scientific Data Management and Stewardship[J]. Scientific Data, 2016, 3: 160018. DOI: 10.1038/sdata.2016.18.

作者简介



范举

范举，中国人民大学信息学院教授、博士生导师，数据工程与知识工程教育部重点实验室成员。研究方向为数据治理技术与系统、智能数据库系统及数据与人工智能的交叉问题。围绕数据发现、清洗、融合和智能数据准备开展研究，关注人机协作与数据科学智能体。主持国家自然科学基金及产学研合作项目，讲授数据科学导论、数据思维等课程。



范梅浩

范梅浩，中国人民大学信息学院计算机科学与技术专业博士生，师从范举教授。主要研究基于大语言模型的自动化数据准备，关注表格理解、任务需求表达、多步骤流程生成与执行反馈。参与 AutoPrep、DeepPrep 等系统及低成本实体解析研究，相关成果发表于 VLDB、ICDE 等数据管理领域国际会议。研究目标是减少复杂表格处理中的重复劳动，提高准备流程的可靠性与可复查性。

照片由作者提供。