

智能数据准备研究综述

范举 范梅浩

中国人民大学信息学院，数据工程与知识工程教育部重点实验室
北京 100872

摘 要：数据准备面向数据分析与机器学习的使用需求，对异构原始数据进行发现、理解、修复和组织。预训练语言模型与大语言模型的应用，使相关研究从单项数据处理扩展到根据任务需求生成和调整操作流程。不同方法所需的目标信息、操作范围和验证依据存在差异，单项处理的准确率难以反映完整流程的可靠性。本文结合结构化检索与引文追溯，梳理 48 项国内外文献，依据输入对象、操作含义与输出结果划分数据发现、语义理解、清洗修复、匹配融合、结构转换和标注增强六类任务。在此基础上，比较代表方法的监督条件、流程搜索与反馈机制，归纳现有基准的规模、来源和评价指标，并结合原论文对照实验分析处理质量、下游效用及成本。现有结果表明，目标信息的完整程度影响自动化流程的生成质量，执行完成与输出正确之间仍有差距，准备方法的收益也随下游模型和评测条件变化。据此讨论任务语义表达、跨域迁移、独立验证和持续维护中的研究问题。

关键词：数据准备；数据清洗；数据集成；大语言模型；程序合成；数据质量

1 引言

数据分析和机器学习通常以结构、语义和质量满足要求的数据为前提，而实际数据往往分散于异构数据源，并伴随字段含义不明确、值表示不一致、实体重复及记录缺失等问题。数据准备研究面向这些问题，连接原始数据与下游任务，其处理对象既包括数据值，也包括数据模式、跨源对应关系和可执行变换流程。Chai 等对人工智能辅助数据准备的讨论，以及面向机器学习的数据管理综述，均将数据准备视为数据系统与学习方法交叉的重要研究环节。^[1, 2] 从数据质量角度看，处理结果的准确性、完整性和一致性需要结合使用情境评价，统一格式或消除异常并不足以保证数据适合目标任务。^[3, 4]

数据准备方法依赖的知识与操作方式各不相同。交互式工具通过用户示例与规则表达变换需求，统计学习方法利用数据分布和完整性约束检测、修复错误。预训练模型以共享表示支持语义类型识别和实体匹配，大语言模型（large language model, LLM）则用于解释自然语言需求和生成代码。^[5-9] 学习模型可以处理难以完整写成规则的语义问题，数据库算子和显式约束负责批量执行与结果检查。当准备任务包含多个相互依赖的操作时，还需确定操作顺序、保存中间结果，并根据执行反馈调整流程。这使研究重点从单个组件的预测能力延伸到流程的构造、验证与成本控制。

国内相关研究涉及上述多类问题。范举及其合作者围绕统一匹配模型、人工与自动流程组合、问题感知的数据准备和执行反馈驱动的智能体展开探索，相关工作包括 Unicorn、HAIPipe、AutoPrep 和 DeepPrep。^[10-13] 李国良及其合作者研究交互式确定性清洗、面向机器学习的数据管理、低成本实体匹配及自然语言数据准备评测。^[2, 14-16] 高云君及其合作者则从数据集成技术出发，进一步研究数据准备模型的知识增强与迁移、自然语言流程表达和无目标实例的流程搜索。^[17-20] 上述工作包含跨团队合作，本文依据技术问题组织国内外文献，并与 Aurum、Raha、Snorkel 等代表性方法进行对照。^[21-23]

1.1 文献范围与检索方法

本文采用范围综述方法, 以关系表、异构记录及元数据为主要对象, 同时讨论训练标签、样本选择与语料处理。检索截止日期为 2026 年 9 月 9 日。在既有 34 项文献的基础上, 通过不含作者姓名的主题检索补充相关研究, 减少从特定研究团队出发选文造成的偏差。结构化检索使用 Crossref, 原文核验依托 ACM、IEEE、PVLDB、ACL Anthology、arXiv 和中文期刊官网, 公开版本由作者主页及机构知识库补充。检索范围未包含 CNKI、Web of Science 和 Scopus。

检索分为查询试探、固定题名查询和引文补充三步。试探阶段执行 8 组宽泛查询, 保存 120 条返回记录, 用于检查同义词与无关结果, 不计入正式筛选统计。固定阶段使用 Crossref 的 `query.title` 参数执行题名查询。检索词依次为 table union search、semantic type detection、data cleaning、entity matching、table transformation、weak supervision、data preprocessing pipeline 和 data preparation。时间过滤为 2009-01-01 至 2026-09-09, 每式保留相关度排序前 15 条。该接口按相关度检索, 不执行精确短语布尔匹配。完整参数、排名、原始响应和筛选记录随文保存于 `editorial/search/`。

初筛依据题名、摘要和文献类型判断是否涉及可复用的数据准备任务、方法或基准, 排除同名异义、一般领域应用、目录、百科条目及无独立研究内容的材料。复筛核查输入、输出、机制和评测依据。同一工作的预印本、会议版与期刊转载合并, 优先采用正式版本。对于资料充分但分析维度重复的研究, 保留候选记录并标明范围取样理由。未取得足以核对技术定位的资料时, 标记为证据不足。综述、来源规范和仅能核验主题定位的论文作为背景文献, 不进入算法优劣或量化结果比较。固定检索得到 120 条记录, 合并重复 DOI 及同一工作的不同版本后为 117 项。初筛排除 83 项, 复筛 34 项, 新增纳入 10 项, 其余 24 项的范围取样理由保存在筛选记录中。引文与主题检索另补充 REIN、Valentine、Auto-Pipeline 和 Baran 共 4 项, 与既有 34 项合计 48 项。既有文献缺少完整的初筛记录, 上述统计仅对应补充检索。

作者线索用于发现候选, 纳入规则不包含作者、机构或引用量条件, 补充文献以机制、监督条件或评价对象的差异为依据。最终 48 项中, 36 项用于方法或基准分析, 12 项作为综述、规范或主题背景。按非互斥任务标签统计, 数据发现 5 项、语义理解 8 项、清洗修复 14 项、匹配融合 7 项、结构转换 11 项、标注增强 4 项, 另有 11 项涉及流程构造或评测。逐项映射见随文检索附件, 任务交叉的判定原则见第 2.2 节。每式前 15 条的截断、Crossref 对中文文献和预印本收录的不均衡、单轮筛选及公开全文可得性均可能造成遗漏, 本文的范围取样因而不具有穷尽性。

1.2 相关综述与本文组织

已有综述分别从数据管理、数据质量、数据集成和语言模型应用等角度组织该领域。高云君等以关系型数据和知识图谱为对象, 分析实体解析、融合与清洗技术。Chai 等从机器学习生命周期讨论数据发现、清洗和标注, Chen 等则按获取、集成、清洗与转换梳理语言模型辅助的表格数据准备。^[2, 17, 24] Zhou 等近期预印本关注大语言模型支持的面向应用的数据准备, Liang 等从大模型训练阶段讨论训练数据的准备流程。^[25, 26] 二者分别强调使用语言模型准备数据和为语言模型准备数据, 研究目标有所区别。

在中文研究中, 刘祺等从概念、理论与方法层面分析数据质量, 周立等围绕时序缺失机制及补全评测展开比较。两篇综述分别讨论质量评价的概念基础和特定缺失条件下的方法比较, 可为流程研究中的评价指标与实验条件选择提供参照。^[4, 27]

表1从分类依据、流程范围、语言模型应用和评测内容比较相关综述。已有工作已将研究范围扩展至完整流程, Chen 等还在附录中给出指标、报告模板与鲁棒性检查, Zhou 等讨论了清洗、集

成和增强中的 LLM 使用方式。^[24, 25] 本文在这些研究基础上, 考察任务分类与方法比较之间的联系: 系统获得哪些目标信息, 保存哪些中间状态, 依据何种反馈修订, 以及实验结果能够支持何种结论。

全文据此组织为任务、机制与评测三个相互关联的部分。第 2 节依据输入和输出界定任务, 第 3 节比较单项技术及监督条件, 并在第 3.7 节分析人工决策对自动化能力的影响。第 4 节比较流程搜索与修订机制, 通过表 2 和图 1 说明增加候选分支与增加错误检查依据的不同作用。第 5 节结合基准和表 4 中的对照结果, 分别讨论组件质量、流程完成及下游收益。这种组织方式有助于说明方法差异来自算法设计、输入监督还是评测条件, 第 6 节据此讨论尚未解决的问题。比较重点在于目标信息与人工参与如何影响自动化程度, 以及中间状态和检查依据如何限制可修订的步骤与可识别的错误。组件预测、流程执行和下游收益对应不同的评价对象, 原论文结果也据此分别解释。

表 1 相关综述比较

文献	分类依据	流程范围	模型与智能体	评测重点
高云君等 (2023) ^[17]	数据集成	解析/融合/清洗	非主轴	集成方法
Chai 等 (2023) ^[2]	机器学习周期	准备与学习	智能辅助	数据效用
刘祺等 (2025) ^[4]	数据质量	质量管理	非主轴	质量评价
周立等 (2025) ^[27]	时序补全	补全与应用	非主轴	缺失设置
Chen 等 (2026) ^[24]	准备阶段	完整流程	语言模型/智能体	基准/报告规范
Zhou 等 (2026 预印本) ^[25]	清洗/集成/增强	面向应用	LLM/智能体	任务与应用
Liang 等 (2026) ^[26]	LLM 训练阶段	语料准备	为 LLM 准备数据	语料与训练
本文	任务与机制	搜索/验证/修订	跨机制比较	同设置效用/成本

注: “非主轴” 不表示完全缺少相关讨论。

2 基本概念与任务分类

2.1 数据准备的定义

本文将 data preparation 译为数据准备, 指为满足特定下游任务而发现、理解、修改或组织数据的过程。数据预处理对应 data preprocessing, 通常指已选定数据上的变换、编码、补全或样本处理。数据清洗对应 data cleaning, 侧重错误检测与修复。数据集成对应 data integration, 侧重建立跨源对应关系并形成一致表示。后三者是任务范围不同且可能交叉的研究对象, 本文保留论文原有术语, 但按其实际输入与输出进行归类。例如, 按已知键执行连接属于结构转换, 而推断两个来源中的记录是否指向同一实体属于匹配融合。

本文从原始数据及元数据、目标任务和处理约束三个方面描述数据准备问题。目标任务可以是数据分析问题、目标表结构或学习任务。目标模式描述输出表的字段、类型与结构要求, 目标实例则包含具体记录。准备流程通过选择、连接、聚合、类型转换、匹配、修复和标注等操作, 产生适合该任务的一张表或一组数据对象。流程既可以是操作序列, 也可以是支持多表输入的有向无环图。

流程评价包括任务效用、约束满足情况和处理成本。任务效用指处理结果对指定分析或学习任务的帮助, 如问答准确率或预测性能的变化。类型与完整性要求可以检查输出, 访问范围等过程要求则需要结合实际操作和数据来源判断。面向学习任务时, 在固定训练与数据划分协议下使用验证集选择流程, 测试真值仅用于最终评价。执行、人工、训练与搜索重试的成本分别计量。

不同任务对输入监督的要求差异较大。有的方法假设提供匹配标签或正确值, 有的方法需要用户示例、已有流程或目标模式, 也有的方法仅利用自然语言描述和执行状态开展搜索。这些条件决定了系统需要自行推断的信息范围。比较方法时, 应同时说明它获得了哪些目标信息, 以及哪些正确性标准仅由评测器掌握, 避免把更强的输入监督误认为更强的自动化能力。

2.2 任务划分与分析维度

本文按输入、操作语义和被评测的输出对象界定任务, 分类单位是可独立评价的配置, 而不必是一整篇论文。数据发现从数据目录、表集合与查询出发, 输出候选数据源及关联。语义理解依据字段、值域与上下文, 输出类型标签或字段映射。清洗修复针对错误与缺失, 输出错误位置、修复值或补全结果。匹配融合识别跨源记录的实体对应关系并处理冲突, 输出统一记录及来源关系。结构转换在已知模式、映射或连接键的条件下, 通过过滤、连接、聚合与重塑生成目标表或程序。标注增强利用样本与弱监督资源, 生成标签、训练子集或处理后的语料。

实际归类以被评测的输出为准。例如, 模式匹配归入语义理解, 实体匹配归入匹配融合, 按已知键连接归入结构转换。类型模型用于检索数据源时, 发现模块另记数据发现标签。标签仅作为模型输入时不计为标注增强, 只有生成或选择监督本身是评价目标时才纳入。

多任务论文按各实验输出记录多个标签。需要单一主类时, 以论文主要优化目标对应的输出为准, 无法确定时保留并列主类。例如, Unicorn 在类型识别和实体匹配配置下分别标记语义理解与匹配融合, GoodCore 同时涉及缺失补全和训练子集选择。DeepPrep 的多算子配置跨越多个任务, 其流程能力另行记录。^[10, 13, 28] 该规则允许任务覆盖数大于文献总数, 并避免以模型名称或训练方式代替任务分类。

从实现机制看, 可以区分显式规则与程序搜索、统计与深度学习、语言模型语义推断, 以及结合外部工具的流程规划。同一任务可以由不同机制解决, 同一系统也可能组合多种机制。例如, 实体匹配可以采用监督分类、上下文学习或多任务表示, 而结构转换既可以由示例驱动, 也可以通过目标模式搜索或自然语言代码生成完成。从流程能力看, 单项预测、固定流程执行、任务感知规划与基于反馈的流程修订应分别考察。多任务模型的输入覆盖范围与流程规划能力应分别评价, 执行结果是否符合业务要求则取决于任务相关检查。本文同时考察目标数据、可执行流程和验证记录, 分别对应处理结果、操作过程和检查依据。来源说明和变换记录用于复现处理过程, 结果正确性仍需单独验证。^[29, 30]

3 智能数据准备的关键技术

3.1 数据发现与语义理解

数据发现需要从大量异构资源中定位与任务相关的数据源, 并识别潜在的可连接或可合并关系。Aurum 通过数据关系表示及声明式发现操作支持跨源检索, 以索引和关系组织辅助数据定位。^[21] 检索结果包含数据位置及潜在关联, 候选关系是否满足任务要求仍需模式与内容分析。发现阶段的评价因而涉及召回率、候选规模和后续验证成本。Table Union Search 根据值域、语义域等证据寻找可并表, SANTOS 进一步利用列间关系补充逐列相似性, 说明表级可用性需要同时考虑属性含义及其组合。^[31, 32] Boutaleb 等对并表基准的再分析发现, 简单方法可能利用数据集特有特征获得较高分。^[33] 解释检索性能时, 应通过对照区分数据特征与语义建模的作用。

语义理解进一步处理列名、值域及表内上下文之间的对应关系。Sato 结合列值特征、表级主题和结构化预测识别列语义类型, 将判断依据从单元格和表头扩展到表内上下文。^[7] 与之相比, 语言模型能够联合利用自然语言说明、样例值和外部知识, 但其输出仍可能受字段命名、序列化方式和上

下文截断影响。^[9, 24] 对涉及单位、编码和统计粒度的字段, 语义相近不应直接作为可替换或可连接的充分条件。STEER 通过数据编程生成新数据湖的训练标签, 再适配既有类型模型。SportsTables 专门考察数值列占比较高时的类型识别。^[34, 35] 这两项工作分别反映了新领域标注资源和列分布对类型识别的影响。

Unicorn 将包括模式匹配、列类型标注和实体匹配在内的多个匹配任务统一到共享表示与判别框架中, 并通过专家混合机制处理任务语义差异。^[10] 共享表示可用于多类匹配问题, 其适用范围受任务相关程度、训练覆盖及输入表示限制。对于训练中未覆盖的模式, 可先由语义模型生成候选映射, 再利用模式约束筛选, 并记录预测依据与置信信息。

3.2 错误检测、数据修复与缺失补全

数据清洗首先需要区分错误检测与错误修复。检测回答哪些值或记录不满足预期, 修复则需要进一步决定如何修改。HoloClean 综合完整性约束、统计关系和参考信息, 以概率推断选择修复结果。^[6] 多种信息共同参与修复推断, 结果受候选值覆盖、约束准确性与数据相关结构影响。满足约束的候选值仍可能偏离真实记录, 约束一致性与事实准确性需分别评价。

Raha 将多种检测策略的输出转化为特征, 并利用聚类、抽样及用户标注减少手工配置成本。^[22] 它弱化了用户逐项设置检测规则和参数的负担, 但仍需要一定的人工监督。He、Li 等提出的 Falcon 则从用户给出的修复出发, 搜索并确认可推广的 SQL 更新规则, 将人工反馈用于确定性清洗。^[14] Raha 侧重减少检测配置, Falcon 侧重复用修复知识, 人工分别参与标注选择和规则确认。

检测与修复可以串联执行, 并共享数据上下文。Baran 在统一上下文表示下组织候选纠错模型, 借助迁移与用户反馈完成修复。与 Raha 结合时, 错误定位和候选修复的误差需要分别报告。^[22, 36] REIN 将检测、修复及学习模型纳入同一评测框架, 同时考察局部清洗质量和下游预测效果。^[37]

语言模型为错误解释和候选值生成提供了新的实现方式。Narayan 等探索通过基础模型统一表达多类数据整理任务, Jellyfish 利用面向数据预处理的指令微调支持错误检测、缺失补全、模式匹配和实体匹配。^[9, 38] Jellyfish 可在本地部署并复用于上述任务, 其生成的解释仍需数据证据核实。对于原始数据中不可观测的信息, 应区分基于记录证据的纠错与基于统计或模型知识的估计, 并保留估计值的来源及不确定性。

缺失补全还受到缺失机制和数据结构的影响。周立等的综述将缺失场景、缺失率、变量数量、序列长度及下游效果纳入评讨论, 表明方法比较需要控制数据缺失的形成条件。^[27] 这一要求同样适用于一般表格: 在随机遮蔽数据上的较小重构误差, 并不能直接说明方法适用于与业务过程相关的系统性缺失。不同补全结果还可能改变变量关系和样本分布, 因此应同时检查局部数值误差与后续分析的稳定性。

3.3 实体匹配与多源融合

实体匹配判断不同来源的记录是否指向同一对象, 多源融合则进一步处理同一对象的属性冲突、来源差异和表示统一问题。高云君等对关系数据与知识图谱集成的梳理表明, 实体解析、融合和清洗之间存在紧密联系。^[17] 匹配错误会把不同对象合并, 融合规则则可能在对应关系正确的前提下选取错误值, 因此两个阶段需要分别验证。此外, 候选对生成的遗漏会限制后续匹配的召回率, 不能只评价分类器在已筛选候选对上的性能。

DeepMatcher 比较深度学习实体匹配的表示与聚合设计, 为后续预训练模型路线提供了组件化参照。^[39] Ditto 将实体匹配转化为预训练语言模型上的序列对分类, 并结合领域知识、文本摘要和

数据增强改善输入表达。^[8] Ditto 通过有监督微调适配匹配任务, 跨领域使用时仍涉及标注与训练成本。Unicorn 侧重跨匹配任务共享表示, 两者的监督组织方式和泛化目标有所不同。^[10]

Fan 等提出 BATCHER, 从示例选择和问题分批两个方面研究实体解析中的上下文学习成本。^[15] 其覆盖式示例选择与批量提示使多个待匹配问题共享上下文, 有助于在匹配质量和模型调用开销之间选择合适配置。示例标签质量和批内信息的可区分性会影响上述策略的效果。使用语言模型代替人工生成示例标签时, 还应评价标签错误的传播, 单纯减少调用次数不足以反映整体收益。

从匹配到融合, 还需要引入来源可信度、时间有效性和字段级一致性等信息。将所有冲突统一为多数投票会忽略来源之间的依赖, 也可能覆盖更新的有效记录。已有集成研究讨论了属性冲突及其处理依据。^[3, 17] 在语言模型参与的流程中, 同样需要保留候选值、来源及选用规则, 以便复查融合决定。

3.4 结构转换与程序合成

结构转换处理嵌套表头、宽窄表变换、字段拆分、类型转换及列派生等问题, 其输出通常需要满足关系结构或下游程序的输入要求。Wrangler 通过交互式示范和变换建议生成处理脚本, 使用户能够在数据预览中逐步确定操作。^[5] 其价值在于降低表达门槛并保留可重复执行的脚本, 而转换目标和关键操作仍主要由用户指定。Morpheus 依据输入输出 (I/O) 示例进行类型引导的程序枚举, 结合组件规范、可满足性模理论推理与部分求值剪枝。^[40] 其搜索反馈具有明确的示例一致性依据, 但部署时需要可供用户表达的输出示例, 与无示例关系化任务的输入条件不同。

Auto-Tables 面向非规范表格的关系化处理, 通过合成多步变换恢复适合分析的结构, 且不要用户自行提供转换后的示例表。^[41] 其模型利用行列方向的特征预测算子及参数, 并通过束搜索保留多个候选流程。Auto-Tables 将变换预测与受限搜索结合, 以关系结构为目标生成操作。关系化后的表仍需检查单位、聚合粒度和跨表对应关系, 才能判断其是否适合具体业务。

语言模型代码生成扩大了可表达变换的范围, 同时也使验证问题更加突出。受控算子便于检查类型、参数和前置条件, 自由代码则能够表达复杂清洗逻辑, 但可能引入难以静态分析的行为。AutoPrep 与 BAT 分别通过逻辑操作分解和操作沙箱约束流程构造。^[12, 20] 对数据准备而言, 二者之间的取舍取决于目标任务是否需要开放式语义转换, 以及系统能否为扩展代码提供独立验证。

3.5 数据标注与训练数据准备

面向机器学习的数据准备还需要构造监督信号并确定训练样本。Snorkel 允许用户以标注函数表达领域启发式, 并对含噪、冲突的弱监督输出进行建模, 减少逐样本标注需求。^[23] 这种方法将人工劳动由重复标签判定转移到标注知识的组织, 但仍受规则覆盖和噪声建模条件限制。对语言模型生成的标签也应采用类似的分析方式, 区分标签来源、错误相关性和下游效用。VersaMatch 将启发式规则、模式及外部知识作为弱监督源, 用于本体匹配中的判别模型和集成预测。^[42] VersaMatch 的评测对象是匹配输出, 按本文分类归入语义理解。它与 Snorkel 的联系在于弱监督机制, 任务目标有所不同。

样本选择与数据修复可以联合考虑。ActiveClean 针对凸损失模型, 在逐步清洗数据的过程中更新模型, 并优先处理可能影响训练结果的记录。^[43] GoodCore 进一步研究不完整数据上的核心子集选择, 将数据补全与梯度近似联系起来, 以兼顾训练质量、训练效率和人工补全成本。^[28] 两项研究均依据学习任务选择待处理数据, 其结论适用于各自的模型假设和优化目标。

对于大模型训练语料, 去重、过滤、来源管理与数据配比需要在不同训练阶段共同设计。Data-Juicer 将数据分析和处理算子组织为可组合的系统, 支持处理配置的调整与比较。Liang 等的综述

区分预训练、持续预训练和后训练的数据需求。^[26, 44] 这里的评价对象是语料对模型训练的贡献, 与利用大语言模型执行表格清洗的评价对象不同。处理规模、内容覆盖及下游性能应结合讨论, 单一过滤分数难以完整表示训练数据价值。

3.6 技术路线比较

规则和统计方法具有较明确的执行或推断条件, 语言模型方法扩大了语义处理范围, 但引入提示、示例选择和模型版本等敏感因素。监督资源既包括实例标签, 也包括任务说明、知识资源和验证规则。例如, Raha 需要检测标注, Ditto 需要记录对监督, Snorkel 依赖标注函数。Unicorn 与 Jellyfish 扩大了任务覆盖, 流程规划则需要另外确定操作顺序。^[8, 10, 22, 23, 38] 方法选择应结合错误类型、监督资源和维护成本, 区分局部预测质量与任务组合能力。

3.7 监督条件与流程能力

人工决定下一步、系统完成局部任务、自动构造流程和利用反馈修订流程, 反映了不同的人工参与方式与系统能力。这些能力的比较需结合可用的目标信息。Morpheus 使用当前输入的正确输出示例, Auto-Pipeline 使用其他批次的类比目标表, DiffPrep 依据标签与验证损失选择预处理流程。^[40, 45, 46] 任务说明、训练标签和提示示例均不同于运行时可见的目标表记录, 替换方法前需要核对这些信息是否可得。

数据范围和交互方式也应纳入比较。Ditto、Jellyfish 中的记录对匹配以已给定的记录为输入, 完整多表流程还涉及跨表操作的组合。Auto-Tables 与 AutoPrep 主要围绕单表, Morpheus、Auto-Pipeline、Pipeline-Agent、DeepPrep 和 BAT 则涉及多表配置。^[8, 12, 13, 19, 20, 38, 40, 41, 45] Wrangler 的操作示范、Raha 的标注和 Auto-Tables 的候选选择均包含人工投入, 但不能直接等同于 PrepBench 配置中的开放式任务澄清。^[5, 16, 22, 41]

验证与回退的作用取决于具体实现。HoloClean 将约束用于修复推断, 独立验证则要求在候选生成之外检查结果。^[6] 测试真值只在评测时使用, 与运行时可获得的反馈应严格区分。枚举器撤销候选、束搜索保留分支、代码局部重试和恢复物化表状态分别支持不同的修订范围, 具体流程机制见表2。公开资源可用于复查方法实现。HoloClean、Raha、Ditto 及多种流程方法提供代码, Jellyfish 提供模型, Auto-Tables 提供基准。本文核对了资源入口, 但未重新运行这些系统, 逐项资源与核验范围见随文证据附件。

4 任务感知的数据准备流程

4.1 面向下游任务的流程优化

单项操作的最优配置不一定形成整体最优流程。清洗可能改变实体匹配的候选集合, 连接可能放大重复值, 样本过滤则可能改变训练分布。这些相互作用要求流程构造同时考虑操作顺序、数据依赖和下游目标。面向机器学习, 优化信号通常来自验证集性能。面向数据分析, 则更多依赖目标表定义、问题语义与结构约束。两类场景的优化目标与反馈来源不同, 需要分别确定流程选择和结果验证的依据。

DiffPrep 将预处理算子选择及顺序的离散搜索松弛为可微优化, 与模型训练构成双层优化, 并用验证集损失更新流程参数。^[46] 它适用于可微下游模型和受限预处理空间, 与一般目标表合成相比, 反馈更直接, 但优化目标是预测效用而非恢复真实数据值。HAIPipe 研究同一机器学习任务下人工生成流程与自动生成流程的组合, 通过搜索和筛选寻找具有更好下游表现的准备流程。^[11] 人工流程能够包含领域经验, 自动流程则在候选操作集合中开展优化, 二者的结合为已有工作流的改进提供

了方法。HAIPipe 依赖已有流程, 这一输入提供了操作结构方面的先验。评价其性能时, 除最终模型表现外, 还需计入候选流程试运行的开销。

4.2 目标引导的流程合成

目标表监督处于完整输出示例与纯结构说明之间。Auto-Pipeline 允许用户提供来自另一批数据的目标表, 通过模式、键与函数依赖等信息约束搜索, 结合搜索和强化学习生成流程。^[45] 类比目标表含有其他批次的具体记录, 可提供模式之外的统计和依赖信息。Morpheus 的 I/O 示例、Auto-Pipeline 的类比目标与 BAT 的目标模式提供不同程度的监督, 成功率比较需控制目标信息。

AutoPrep 针对表格问答提出问题感知的数据准备, 将流程划分为规划、编程与执行三个部分, 并利用 Chain-of-Clauses 推理和工具辅助生成连接问题语义与具体变换。^[12] 其主要处理需求包括列派生、值规范化和相关列筛选, 核心思想是先确定逻辑准备操作, 再生成适配当前表格与问题的物理实现。逻辑分解与物理实现分别处理语义决策和执行代码, 原论文主要在表格问答设置中评价这一设计。

Text-to-Pipeline 研究自然语言准备指令到可执行操作组合的映射, 构建 PARROT 基准, 并提出利用中间执行状态的 Pipeline-Agent。^[19] 其操作以领域专用语言 DSL 表达, 由算子及相应参数组成。与 AutoPrep 以问答需求为起点不同, Text-to-Pipeline 关注的是准备意图与操作序列的对应关系。其分析指出, 失败既可能来自多步操作组合, 也可能来自语义参数定位, 即操作类别合理但列、条件或参数选择错误。流程评测因而需分别检查操作结构和参数取值。

自然语言接口降低了用户描述流程的技术门槛, 却不能消除需求中的歧义。同一目标描述可能对应不同的时间范围、去重键和统计粒度, 而这些解释都可能生成能够运行的程序。PrepBench 将交互澄清纳入评测, 为观察系统是否能识别和解决此类问题提供了任务设置。^[16] 因此, 交互能力应与代码生成能力分别测量, 并报告澄清次数及其对最终结果的影响。

4.3 执行反馈与流程修订

长流程中的错误可能在后续阶段才显现, 局限于修改最后一步的策略难以纠正前序语义决策。DeepPrep 将中间表状态显式保存在执行环境中, 通过树状推理组织不同尝试, 支持根据反馈回退到较早状态并修订流程, 同时采用渐进式智能体训练学习相关行为。^[13] 保存中间状态使 DeepPrep 能够修订较早的操作, 而不局限于最后一步的代码。这种修订依赖可观测的错误信息。目标要求遗漏时, 增加搜索分支仍可能得到语义不符的结果。

BAT 研究无需目标表实例的准备流程合成, 利用操作沙箱约束候选行为, 通过语言模型驱动的蒙特卡洛树搜索构造流程, 并结合执行结果筛选候选。^[20] 这里的“无目标实例”指不提供目标表的具体记录, 任务仍由目标模式等信息限定。与 DeepPrep 侧重训练可回退的智能体行为不同, BAT 强调免训练条件下的受控流程搜索。两类方法都利用执行信息减少无效尝试, 但搜索空间、监督来源与成本构成不同, 比较时需要控制目标信息和执行预算。

任务规划确定候选操作与顺序, 工具执行产生中间数据, 独立验证提供与生成过程相区分的检查依据, 失败反馈则用于定位并修订前序决策。独立验证依赖生成过程之外的约束、参考数据或任务判定过程, 不同系统支持的检查范围有所差异。中间状态有助于定位与回退, 数据来源和版本记录则用于复现同一处理过程。分析流程修订时, 应分别考察可搜索的分支和可利用的检查依据。

4.4 流程复用与机制比较

流程自动化需要复用已有的算子、匹配模型和领域知识。Unicorn 与 Jellyfish 分别通过多任务学习和指令微调共享准备能力, 而 KnowTrans 将知识增强与数据准备模型的迁移能力联系起来。^[10, 18, 38] 组件适用于新数据时, 原流程中的关联顺序、过滤条件和验证规则仍可能失效。跨领域复用需分别评价语义预测、操作选择和流程结果。

表2进一步区分流程搜索的内部机制。不同状态表示保留的信息各有侧重。模式状态可用于剪除类型不相容的操作, 但不足以区分具有相同模式的不同聚合结果。物化中间表保留具体值和行数变化, 代价是数据访问与状态保存开销。可微参数则用于优化学习模型的效用, 难以直接表达任意程序分支。停止条件与上述设计相对应, 模式满足、示例一致和验证损失最小化分别衡量结构、样例输出和预测表现。

表 2 流程生成与修订机制比较

方法	目标信息	搜索方式	状态表示	反馈依据
Morpheus ^[40]	当前 I/O 示例	类型引导枚举	部分程序/结果	规范/I/O 一致
Auto-Pipeline ^[45]	类比目标表	搜索/强化学习	中间表/目标特征	键/函数依赖
Auto-Tables ^[41]	关系化目标	预测/束搜索	中间表/候选	关系结构
HAIPipe ^[11]	既有流程/模型	流程组合	流程/评价信息	验证集效用
DiffPrep ^[46]	标签/预测模型	可微双层优化	流程/模型参数	验证损失
AutoPrep ^[12]	问题/输入表	逻辑分解/重试	计划/执行结果	工具异常
Pipeline-Agent ^[19]	自然语言指令	DSL 操作生成	表/操作历史	执行状态
DeepPrep ^[13]	目标描述	算子树搜索	物化表/父节点	执行/模式
BAT ^[20]	目标模式	沙箱树搜索	候选树/执行信息	执行/结构


各方法采用不同的停止条件。Morpheus 在找到示例一致程序时停止, 实验超时为 5 分钟。Auto-Pipeline 以候选数或最大深度约束搜索, Auto-Tables 以 none 算子或最大长度终止。HAIPipe 在枚举或采样预算内选优, DiffPrep 实验运行 1000 轮并取验证损失最小轮。AutoPrep 按计划完成操作, 并在执行异常时局部重试。DeepPrep 结合 answer 动作、模式条件及探索预算终止搜索, 显式保存的状态支持回退。Pipeline-Agent 的具体步数上限及 BAT 正式版的停止细节尚缺乏足够资料核对。

DeepPrep 训练时的输出真值奖励与部署时的执行/模式反馈, 也必须分别记录。

4.5 多表实例中的错误传播与回退

以本文构造的订单退款数据为例, 订单表 O 包含 $(o_1, A, 100)$ 和 $(o_2, A, 80)$, 字段依次为订单键、客户和金额。退款表 R 包含 $(o_1, 20)$ 和 $(o_1, 10)$, 字段依次为订单键和退款金额。目标是按客户汇总净收入, 并规定订单金额只计一次、同一订单的退款可加、全部订单保留且无退款记 0, 所有金额单位一致。退款表各行表示不同的有效退款事件, 且均关联订单表中的订单。上述业务规则在执行前给定, 用作检查依据。

若先按订单键左连接, 再逐行计算金额减退款, o_1 会形成两条记录, 最终得到 $(100 - 20) + (100 - 10) + 80 = 250$ 。一对多连接本身合法, 所有操作均可成功执行, 最终客户键也唯一。类型检查、执行状态和最终模式检查均无法揭示订单金额的重复计入。正确流程应先将退款按订单聚合为 $(o_1, 30)$, 再左连接并计算净收入, 得到 $70 + 80 = 150$ 。图1展示两条路径及其验证位置。



独立检查 · 预设口径

每单净收入计算前: 订单键唯一

净收入总额: 180-30=150

检查范围: 粒度与总额

全部订单保留 · 同币种 · 无退款记0 · 退款事件有效且可加

图 1 多表实例中的错误传播与回退

在计算每单净收入之前,可检查连接结果中的订单键是否唯一。汇总后再检查净收入总和是否等于原订单金额总和减全部有效退款,即 $180 - 30 = 150$ 。在本例的修订路径中,恢复到连接前状态并插入退款聚合,即可消除订单金额的重复计入。两个检查都依赖上述订单保留范围与退款规则。若存在部分订单过滤、币种转换或退款冲正,检查条件必须重新定义。键唯一性检查只适用于上述每单一行的中间表,它与总额检查均无法单独确认客户归属或每笔金额的正确性。

不同方法可利用的纠错依据也可由此区分。有正确输出示例的合成器可以排除与示例不一致的路径,仅有目标列名的系统则缺少“每单只计一次”的判断依据。保留中间状态的智能体能够重建前序分支,但首先需要反馈揭示重复计入。任务未明确退款规则时,须先澄清语义,再执行相应检查。随文 SQLite 脚本复核上述路径、唯一性检查及一个行数相同而退款总额改变的扰动案例,仅用于验证构造实例的逻辑。

5 评测基准与结果分析

5.1 局部处理质量与流程正确性

局部评测通常针对可明确标注的子任务。错误检测、类型识别和实体匹配可采用准确率、精确率、召回率及 F1 值,其中 F1 为精确率与召回率的调和平均。数值补全可采用平均绝对误差或均方根误差。这些指标必须与标签粒度、类别比例和缺失机制一起解释。例如,单元格错误检测与记录级错误检测使用不同的评价单元,匹配候选对上的 F1 也不包含候选生成阶段的遗漏。仅报告总体均值可能掩盖稀有类型或少数数据源上的性能下降。^[7, 8, 22, 27]

流程正确性则需要检查操作之间的组合结果。可执行率只能反映程序是否完成运行,目标表比较能够进一步判断输出结构和值是否符合参考结果,操作序列比较则反映流程表达的相似程度。不

同流程可能产生相同输出, 严格的序列匹配会将部分语义等价的实现判为错误。单个输入上的输出一致性也只验证当前案例, 流程对其他输入的适用性还需单独测试。对连接、聚合、重复记录、空值和排序语义的约定应提前固定, 并在评测工具中保持一致。

Text-to-Pipeline 和 PrepBench 从不同来源构造流程评测任务。Text-to-Pipeline 的 PARROT 基准以已有转换模式为基础, v2 统计为 17168 项任务及 16 类核心操作, 用于研究指令到操作组合的映射。^[19] PrepBench 基于 Preppin' Data 任务扩展评测, 将交互消歧、准备代码生成和代码到工作流转换分别纳入考察, 任务涉及 3 至 18 个准备步骤。^[16] 前者强调规模化操作组合, 后者强调现实准备任务中的交互和表达问题。两者在任务难度、工具支持和目标信息方面的差异, 需要在解释结果时加以考虑。

5.2 下游效用与处理成本

数据准备的最终效用需要结合使用任务判断。在表格问答中, 答案准确性受到问答后端影响。在机器学习中, 预测性能与模型类型、超参数和训练数据划分有关。同时报告数据准备质量与固定下游系统上的表现, 才能区分数据处理和下游模型的作用。语义理解、操作选择和执行反馈各自的贡献则需通过消融实验分析。^[11, 12, 28] 使用下游指标选择准备流程时, 只能利用训练集及验证集, 测试集应保留用于最终评估, 防止由反复选择造成信息泄漏。

成本评价至少应区分模型调用、工具执行、存储与人工四部分。批量提示可能降低上下文重复开销, 其效果与批大小和示例共享程度有关。树搜索增加修订机会的同时, 也引入候选执行和中间状态保存成本。^[13, 15, 20] 这些开销需结合模型版本、输入输出词元数、重试次数、最大搜索深度、运行环境和人工确认量计量。仅以单次推理价格或单条样本时延代表完整任务成本, 容易遗漏失败重试和流程维护开销。

5.3 代表性评测基准

表3集中比较代表性基准及论文评测集。实体匹配任务画像研究按数据特征分析匹配难度, Valentine 则围绕数据发现中的模式对应构造受控比较, 分别为记录级和列级匹配提供评测参照。^[47, 48] SportsTables 和实体匹配任务集评价组件输出, REIN 联系清洗质量与学习效用, AutoTables 使用的 ATBench 及 PARROT 评价转换或操作组合, PrepBench 将交互和流程表达纳入任务。合成操作序列便于扩大组合规模, 现实需求则更容易暴露任务歧义和数据不规则性, 任务数量与覆盖范围应结合考察。表中 Hit@ k 表示前 k 个候选中至少一个匹配真值的任务比例。Valentine 采用的 Recall@ k 在 k 等于真值映射数时计算召回率, 具体判定方式见下文。

数据来源影响基准覆盖的范围。SportsTables 来自体育网站, 约 86% 为数值列。Valentine 的真实表对包括 4 组 WikiData、7 组 Magellan 和 2 组非公开 ING 数据。REIN 组合 19 种检测器与 19 种修复方法, 真实错误和注入错误并存。ATBench 来自论坛、计算笔记本、网页与电子表格, 多数为短流程。

PARROT v2 以模板及 LLM 辅助构造任务, 训练/验证/测试为 14388/1387/1393, 分别评价输出准确率、程序有效率与算子准确率。PrepBench 基于 Preppin' Data, 覆盖 32 领域、3–18 步, 采用用户模拟器辅助交互。表中 DeepPrep 的四个测试规模依次对应 Synth-Spider、Synth-Bird、改写 Parrot 和 Buildings。Synth-Spider 训练集为 6788 项, 合成流程最长 28 步, 改写 Parrot 则与原版 PARROT 有所不同。本文对 PARROT 采用 v2 统计, 对 DeepPrep 采用正式论文数据, 对 PrepBench 采用可核读的 arXiv v1 数据, 各版本分别记录。

表 3 代表性评测基准比较

基准/评测集	规模	任务对象	主要评价量
SportsTables ^[35] 实体匹配任务 集 ^[47]	1187 表、24838 列 21 项任务	语义类型 实体匹配	宏/加权 F1 匹配难度分析
Valentine ^[48] REIN ^[37] ATBench ^[41]	540 组合成、13 组真实表对 14 数据集、33 学习模型 244 例, 26 例多步	模式匹配 清洗与学习 单表关系化	Recall@ <i>k</i> 、时延 检测/修复/预测质量 Hit@ <i>k</i> 、时延
PARROT v2 ^[19] PrepBench ^[16] DeepPrep 评测 集 ^[13]	17168 任务、23009 源表 306 任务、829 输入表 测试 2008/1150/1365/105 项	16 类操作组合 消歧与流程 多步准备	输出/程序/算子质量 F1、准确率、成本 精确匹配、完成率

注：按所引版本统计，任务数、表数与列数分别计量。

基准差异还涉及目标信息、输出判定与任务难度。目标示例、模式、无歧义指令和含歧义需求提供不同程度的监督。在输出判定上，PARROT v2 的规范化比较包含数值容差，DeepPrep 则忽略行列顺序但要求单元格精确相等。^[13, 19] 这类规则变化可能影响得分，比较时需排除评测器差异。实体匹配任务分析关注候选记录的可区分性，表并集基准再分析则发现数据集特有特征可能使简单方法获得高分。^[33, 47] 跨基准评价因而需明确变化来自数据域、任务描述还是评价协议。

Auto-Tables 的 Hit@*k* 记法与实现也存在差异。原文以指示量求和书写该指标，公开评测代码在首次命中后记 1 并停止，以避免多个正确候选重复计分。匹配对象是标注的算子、参数序列及已列出的替代真值。^[41] 本文按实现解释候选命中率，该指标不包含对任意语义等价程序的输出检查。

5.4 代表性实验结果分析

表4汇集原论文在明确模型与数据条件下报告的对照结果，用于分析监督、流程机制与性能差异的关系。准确率以百分数表示，差值以百分点表示，费用按原文单位换算。本节未重新运行所列系统，也未从缺乏精确标注的曲线估读数值。未报告的成本保留为缺项，各组结果只在相应实验条件下比较。

表 4 原论文对照结果与成本

编号与方法	对照项	结果 (%)	报告成本
E1: Auto-Tables ^[41]	Hit@1 / Hit@3	57.0 / 75.0	0.224 秒/例
E2: AutoPrep ^[12]	WikiTQ; TabFact	52.83→66.09; 70.21→87.85	该对照未列
E3: DeepPrep ^[13]	准确率; 完成率	61.70→67.18; 85.26→97.21	该对照未列
E4: PrepBench ^[16]	代码/流程/无歧义说明	54.9 / 34.6 / 85.3	\$0.11540 / \$0.26410 / \$0.08274
E5: PrepBench ^[16]	GPT-5.1-Codex / Gemini 3 Flash	54.9 / 53.3	\$0.11540 / \$0.02140
E6: DiffPrep ^[46]	BoostClean / DP-Fix / DP-Flex	69.0 / 73.2 / 70.1	单数据集未列

注：数值与对照项依次对应。E4、E5 费用为美元/任务，箭头表示同一论文内的对照。

对自动化的判断需要区分候选覆盖与最终选择。E1 在 ATBench 的 244 例中，Hit@1 到 Hit@3 增加 18.0 个百分点，但用户仍需辨认正确候选，75.0% 不代表全自动首选正确率。E4 使用 GPT-5.1-Codex 评价 PrepBench 的 306 项任务。端到端代码、工作流和给定无歧义说明后的代码生成结

果存在差距, 表明目标信息获取与流程表达均影响性能。候选选择和语义说明分别位于结果筛选与任务输入环节, 人工投入的性质有所不同。

流程完成与语义正确也需要分离。E3 在 Synth-Spider 上比较 Qwen3-14B 的模仿学习基线 IL 与 DeepPrep, 两者仅使用 Synth-Spider 训练集。准确率提高 5.48 个百分点, 反映的是训练与推理方案的联合效果, 无法单独归因于回退。DeepPrep 的完成率 97.21% 与精确匹配准确率 67.18% 相差 30.03 个百分点, 直接显示可返回结果的流程仍可能不符合目标表。其 Qwen3-8B 消融中, 移除渐进训练后的 Synth-Spider 准确率从 65.99% 降至 22.21%。^[13] 该设置同时改变学习行为, 树搜索本身的收益尚需单独对照。DeepPrep 的奖励消融还报告了仅重命名列以满足表面模式、却未完成实际变换的行为, 说明终止条件可能被满足而任务仍未完成。^[13] 结合图1, 这些失败可区分为运行中断、操作或参数错误、任务要求遗漏以及程序到工作流的表达损失。前两类可利用执行反馈定位, 后两类通常还需任务语义和独立评价依据。

下游收益随准备目标与模型而变化。E2 固定 DeepSeek-V2.5-Chat、8192 上下文上限及 0.01 温度, 比较自然语言转 SQL 方法 NL2SQL 与加入 AutoPrep 后的问答结果。WikiTQ 和 TabFact 分别提高 13.26 与 17.64 个百分点, 测量对象是答案质量。E6 在 connect-4 上固定逻辑回归, 采用 60/20/20 划分, 并将 BoostClean 适配为多分类。DP-Fix 较该基线提高 4.2 个百分点, DP-Flex 却未进一步提高, 扩大顺序搜索空间在这一设置中没有带来额外收益。DiffPrep 自身报告从逻辑回归换为两层神经网络后, DP-Fix 或 DP-Flex 达到最优的任务数由 15/18 变为 10/18, 说明“最优准备方案”不能脱离下游模型。^[46] REIN 关于局部清洗指标和预测效果的联合评测支持同一分析方向。^[37]

成本证据仍不完整。E5 在同一端到端代码协议下比较 GPT-5.1-Codex 和 Gemini 3 Flash, 准确率相差 1.6 个百分点, 后者调用成本约为前者 18.5%。费用包含相应路径的调用和重试, 不含采购、人工与维护。这组结果可用于原协议内的质量与成本比较, 新数据或预算下的排序仍需重新评价。E1 的 0.224 秒为 24 vCPU、4 块 P100 环境中的平均合成时延, 不含训练和用户筛选时间。DeepPrep 将开放模型运行时间按 A800-80G 每小时 \$0.91 换算为推理费用, 这一核算与仅统计 API 调用的 PrepBench 存在成本边界差异。^[13, 16] 完整流程的成本比较应固定数据、监督和效用指标, 并统一推理、执行与人工投入的核算范围。

5.5 评测报告与可复现性

评测报告应分别说明局部质量、流程正确性、下游效用与运行成本, 并披露标注粒度、候选生成、错误或缺失机制、算子范围和搜索预算。交互评测还需记录澄清轮数、用户模拟方式及参考流程定义。维护评价则需考察数据更新和版本变化后的失效情况。现有基准主要评价特定任务、数据和预算下的表现, 跨域迁移、长期更新及复杂业务语义仍有待更具针对性的基准或应用实验。

为提高结果可复查性, 评测产物应包含原始数据版本、任务说明、实际输入给系统的信息、执行脚本、处理后数据和失败案例。对于随机推理或搜索, 应披露随机种子、采样设置及多次运行差异。数据来源与用途说明可参考 Datasheets 和 FAIR 提出的记录要求, 但仍需补充具体准备操作的参数及验证条件。^[29, 30] 这些信息使研究者能够区分算法差异、模型更新与数据变化造成的结果波动。

6 研究挑战与展望

现有实验已揭示任务歧义、流程执行与输出正确性之间的差距, 也显示了下游模型对准备收益的影响。以下结合方法比较讨论这些问题, 并提出尚待验证的研究设想。对长期维护等缺乏直接实测支持的方向, 讨论主要依据现有基准的覆盖范围。

6.1 任务语义表达与交互澄清

PrepBench 报告的无歧义说明下代码生成结果与端到端准备结果存在较大差距, 还记录了澄清不充分及流程翻译失败的案例。^[16] 这些结果提示, 目标语义获取与操作实现需要分别建模和评价。Auto-Tables 的候选选择问题也涉及语义判断, 即候选输出之间的哪些差异会影响用户目标。

一种待验证的方案是将任务解释写成可检查的条件, 并根据候选输出的实质差异选择澄清问题。可在固定模型和总交互预算下, 对照随机提问、一次性任务说明和依据输出差异提问, 测量正确率、澄清有效性与人工时间。这一设计是否优于单纯增加对话轮次, 取决于其能否在可比成本下稳定减少语义遗漏, 尚需专门实验。

6.2 跨域迁移与分布变化

SportsTables 在数值列较多的语料上重新评价语义类型方法, STEER、Unicorn 与 Jellyfish 分别通过获取训练标签或共享任务表示研究迁移。^[10, 34, 35, 38] 结合表3中的来源差异, 迁移问题可区分为数据集、模式、操作和业务要求的变化, 单次跨数据集测试通常只覆盖部分情形。KnowTrans 涉及知识增强与迁移, 但其具体实验配置尚未取得足够资料核对, 本文仅将其作为研究主题的补充。^[18]

组件适用条件的显式记录值得进一步研究。例如, 记录所需模式、值域及规则版本, 在数据变化后定位需要更新的步骤。其效果可通过列重命名、单位变更、实体分布变化和目标要求变化分别检验, 并比较局部更新与整体重建的错误率和修订成本。这类对照有助于区分对输入格式的适应与对语义变化的处理, 但局部更新能否保持完整流程的正确性仍是待验证问题。

6.3 独立验证与错误传播

DeepPrep 的实验显示流程完成率与目标表准确率仍有差距, PrepBench 也报告了代码到工作流转换时的正确率下降。结合表2中的反馈机制, 本文认为搜索空间与错误可观测范围需要分别研究。图1表明, 类型、执行状态和最终模式检查均可能遗漏聚合错误。这一构造实例说明了检查条件的不足, 此类错误在实际任务中的频率仍需实测。

后续研究可将候选生成与操作前后条件、关系不变量及影响范围检查结合。关系不变量指变换前后应保持的关系, 例如图1中由订单总额与退款总额确定的净收入总额。在测试真值仅用于评价的前提下, 可逐步向运行系统提供类型检查、键约束、总额不变量或输入扰动检查。固定搜索预算后, 比较错误检出率、误拒绝率和回退代价, 以检验各类检查的收益与局限。对于缺少事实核验依据的修复任务, 还可评价拒绝修改或返回多个候选的策略。

6.4 处理成本与持续维护

PrepBench 在同一协议下比较质量与调用成本, DiffPrep 和 REIN 则显示准备收益随下游模型变化。^[16, 37, 46] 这些结果提示, 组件选择、流程搜索与验证开销应结合任务效用考虑, 分别压缩局部成本可能损失整体收益。不过, 表3所列资源主要面向一次性任务, 对长期维护成本的支持仍然有限。

在连续更新的数据版本上研究操作复用、重算与重新验证, 是对现有评测的补充。可以记录更新后的结果失效率、失效步骤定位情况、状态保存开销及人工修订时间, 并与每次完全重跑的策略比较。该方向来自本文对评测覆盖不足的归纳, 能否降低长期成本仍需持续运行实验检验。

7 结论

本文梳理 48 项国内外智能数据准备文献, 依据任务输入、操作与输出划分六类任务, 比较代表方法的监督条件、流程生成与修订机制, 并归纳现有基准和原论文对照结果。单项技术主要处理数据发现、理解、修复和组织中的局部问题, 流程方法还需确定操作顺序并处理前序错误的传播。二者的评价对象和监督条件不同, 方法选择应结合可用目标信息与实际任务要求。

现有实验显示, 更完整的目标说明有助于流程生成, 但执行完成仍不足以保证输出正确。数据准备的下游收益与模型、数据和预算有关, 成本比较也受到计量范围的限制。任务语义表达、跨域迁移与独立验证仍是复杂流程中的主要问题, 持续更新条件下的维护效果则缺乏充分评测。围绕这些问题建立可复查的任务说明、执行记录和对照实验, 有助于判断智能数据准备方法在实际应用中的适用范围。

参考文献

- [1] CHAI C, TANG N, FAN J, et al. Demystifying Artificial Intelligence for Data Preparation[C]//Companion of the 2023 International Conference on Management of Data. New York: ACM, 2023: 13-20. DOI: 10.1145/3555041.3589406.
- [2] CHAI C, WANG J, LUO Y, et al. Data Management for Machine Learning: A Survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(5): 4646-4667. DOI: 10.1109/tkde.2022.3148237.
- [3] BATINI C, CAPPIELLO C, FRANICALANCI C, et al. Methodologies for Data Quality Assessment and Improvement[J]. ACM Computing Surveys, 2009, 41(3): 16:1-16:52. DOI: 10.1145/1541880.1541883.
- [4] 刘祺, 黄君义, 冯耕中, 等. 数字经济发展根基: 数据质量研究述评与未来展望[J]. 系统工程理论与实践, 2025, 45(7): 2101-2123. DOI: 10.12011/SETP2023-2891.
- [5] KANDEL S, PAEPCKE A, HELLERSTEIN J M, et al. Wrangler: Interactive Visual Specification of Data Transformation Scripts[C]//Proceedings of the SIGCHI Conference on Human Factors in Computing Systems. New York: ACM, 2011: 3363-3372. DOI: 10.1145/1978942.1979444.
- [6] REKATSINAS T, CHU X, ILYAS I F, et al. HoloClean: Holistic Data Repairs with Probabilistic Inference[J]. Proceedings of the VLDB Endowment, 2017, 10(11): 1190-1201. DOI: 10.14778/3137628.3137631.
- [7] ZHANG D, HULSEBOS M, SUHARA Y, et al. Sato: contextual semantic type detection in tables[J]. Proceedings of the VLDB Endowment, 2020, 13(12): 1835-1848. DOI: 10.14778/3407790.3407793.
- [8] LI Y, LI J, SUHARA Y, et al. Deep entity matching with pre-trained language models[J]. Proceedings of the VLDB Endowment, 2020, 14(1): 50-60. DOI: 10.14778/3421424.3421431.
- [9] NARAYAN A, CHAMI I, ORR L, et al. Can Foundation Models Wrangle Your Data?[J]. Proceedings of the VLDB Endowment, 2022, 16(4): 738-746. DOI: 10.14778/3574245.3574258.
- [10] TU J, FAN J, TANG N, et al. Unicorn: A Unified Multi-tasking Model for Supporting Matching Tasks in Data Integration[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 84:1-84:26. DOI: 10.1145/3588938.
- [11] CHEN S, TANG N, FAN J, et al. HAIPipe: Combining Human-generated and Machine-generated Pipelines for Data Preparation[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 91:1-91:26. DOI: 10.1145/3588945.
- [12] FAN M, FAN J, TANG N, et al. AutoPrep: Natural Language Question-Aware Data Preparation with a Multi-Agent Framework[J]. Proceedings of the VLDB Endowment, 2025, 18(10): 3504-3517. DOI: 10.14778/3748191.3748211.
- [13] FAN M, FAN J, ZHANG Y, et al. DeepPrep: An LLM-Powered Agentic System for Autonomous Data Preparation[J]. Proceedings of the VLDB Endowment, 2026, 19(11): 3371-3384. DOI: 10.14778/3836663.3836695.
- [14] HE J, VELTRI E, SANTORO D, et al. Interactive and Deterministic Data Cleaning: A Tossed Stone Raises a Thousand Ripples[C]//Proceedings of the 2016 International Conference on Management of Data. ACM, 2016: 893-907. DOI: 10.1145/2882903.2915242.
- [15] FAN M, HAN X, FAN J, et al. Cost-Effective In-Context Learning for Entity Resolution: A Design Space Exploration[C]//2024 IEEE 40th International Conference on Data Engineering (ICDE). IEEE, 2024: 3696-3709. DOI: 10.1109/icde60146.2024.00284.
- [16] XU J, WANG R, WANG J, et al. PrepBench: How Far are We from Natural-Language-Driven Data Preparation?[J]. Proceedings of the VLDB Endowment, 2026, 19(10): 2866-2879. DOI: 10.14778/3828612.3828638.
- [17] 高云君, 葛丛丛, 郭宇翔, 等. 面向关系型数据与知识图谱的数据集成技术综述[J]. 软件学报, 2023, 34(5): 2365-2391. DOI: 10.13328/j.cnki.jos.006808.
- [18] GE Y, LI F, MAO Y, et al. KnowTrans: Boosting Transferability of Data Preparation LLMs via Knowledge Augmentation[C]//2025 IEEE 41st International Conference on Data Engineering. Piscataway: IEEE, 2025: 2852-2866. DOI: 10.1109/ICDE65448.2025.00214.
- [19] GE Y, LIU Y, YE Z, et al. Text-to-Pipeline: Bridging Natural Language and Data Preparation Pipelines[EB/OL]. (2025-11-10) [2026-09-09]. <https://arxiv.org/abs/2505.15874v2>.

- [20] GE C, LIU Y, TANG Y, et al. BAT: Target-Instance-Free Data Preparation Synthesis via LLM-Driven Tree Search[J]. *Proceedings of the ACM on Management of Data*, 2026, 4(3): 143:1-143:25. DOI: 10.1145/3802020.
- [21] CASTRO FERNANDEZ R, ABEDJAN Z, KOKO F, et al. Aurum: A Data Discovery System[C]//2018 IEEE 34th International Conference on Data Engineering (ICDE). IEEE, 2018: 1001-1012. DOI: 10.1109/icde.2018.00094.
- [22] MAHDAVI M, ABEDJAN Z, CASTRO FERNANDEZ R, et al. Raha: A Configuration-Free Error Detection System[C]//Proceedings of the 2019 International Conference on Management of Data. ACM, 2019: 865-882. DOI: 10.1145/3299869.3324956.
- [23] RATNER A, BACH S H, EHRENBERG H, et al. Snorkel: rapid training data creation with weak supervision[J]. *Proceedings of the VLDB Endowment*, 2017, 11(3): 269-282. DOI: 10.14778/3157794.3157797.
- [24] CHEN M, SUN Y, LI T, et al. Empowering Tabular Data Preparation with Language Models: Why and How?[C]//Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2026: 228-246. DOI: 10.18653/v1/2026.acl-long.8.
- [25] ZHOU W, ZHOU J, WANG H, et al. Can LLMs Clean Up Your Mess? A Survey of Application-Ready Data Preparation with LLMs[EB/OL]. (2026-01-22) [2026-09-09]. <https://arxiv.org/abs/2601.17058v1>.
- [26] LIANG H, WONG Z H, LIU R T, et al. Data Preparation for Large Language Models[J]. *Journal of Computer Science and Technology*, 2026, 41(1): 289-317. DOI: 10.1007/s11390-026-5948-8.
- [27] 周立, 吴洋洋, 苗晓晔. 基于深度学习的不完整时序数据补全方法综述[J]. *计算机研究与发展*, 2025, 62(9): 2233-2258. DOI: 10.7544/issn1000-1239.202550449.
- [28] CHAI C, LIU J, TANG N, et al. GoodCore: Data-effective and Data-efficient Machine Learning through Coreset Selection over Incomplete Data[J]. *Proceedings of the ACM on Management of Data*, 2023, 1(2): 157:1-157:27. DOI: 10.1145/3589302.
- [29] GEBRU T, MORGENSTERN J, VECCHIONE B, et al. Datasheets for Datasets[J]. *Communications of the ACM*, 2021, 64(12): 86-92. DOI: 10.1145/3458723.
- [30] WILKINSON M D, DUMONTIER M, AALBERSBERG I J, et al. The FAIR Guiding Principles for Scientific Data Management and Stewardship[J]. *Scientific Data*, 2016, 3: 160018. DOI: 10.1038/sdata.2016.18.
- [31] NARGESIAN F, ZHU E, PU K Q, et al. Table union search on open data[J]. *Proceedings of the VLDB Endowment*, 2018, 11(7): 813-825. DOI: 10.14778/3192965.3192973.
- [32] KHATIWADA A, FAN G, SHRAGA R, et al. SANTOS: Relationship-based Semantic Table Union Search[J]. *Proceedings of the ACM on Management of Data*, 2023, 1(1): 1-25. DOI: 10.1145/3588689.
- [33] BOUTALEB A, AMANN B, NAACKKE H, et al. Something's Fishy in the Data Lake: A Critical Re-evaluation of Table Union Search Benchmarks[C]//Proceedings of the 4th Table Representation Learning Workshop. 2025: 71-85. DOI: 10.18653/v1/2025.trl-1.7.
- [34] LANGENECKER S, STURM C, SCHALLES C, et al. Steered Training Data Generation for Learned Semantic Type Detection[J]. *Proceedings of the ACM on Management of Data*, 2023, 1(2): 201:1-201:25. DOI: 10.1145/3589786.
- [35] LANGENECKER S, STURM C, SCHALLES C, et al. SportsTables: A New Corpus for Semantic Type Detection (Extended Version)[J]. *Datenbank-Spektrum*, 2023, 23(3): 189-197. DOI: 10.1007/s13222-023-00457-y.
- [36] MAHDAVI M, ABEDJAN Z. Baran: Effective Error Correction via a Unified Context Representation and Transfer Learning[J]. *Proceedings of the VLDB Endowment*, 2020, 13(12): 1948-1961. DOI: 10.14778/3407790.3407801.
- [37] ABDELAAL M, HAMMACHER C, SCHÖNING H. REIN: A Comprehensive Benchmark Framework for Data Cleaning Methods in ML Pipelines[C/OL]//Proceedings of the 26th International Conference on Extending Database Technology. 2023: 499-511. <https://openproceedings.org/2023/conf/edbt/3-paper-49.pdf>. DOI: 10.48786/edbt.2023.43.

- [38] ZHANG H, DONG Y, XIAO C, et al. Jellyfish: Instruction-Tuning Local Large Language Models for Data Preprocessing[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2024: 8754-8782. DOI: 10.18653/v1/2024.emnlp-main.497.
- [39] MUDGAL S, LI H, REKATSINAS T, et al. Deep Learning for Entity Matching[C]//Proceedings of the 2018 International Conference on Management of Data. 2018: 19-34. DOI: 10.1145/3183713.3196926.
- [40] FENG Y, MARTINS R, VAN GEFFEN J, et al. Component-based synthesis of table consolidation and transformation tasks from examples[C]//Proceedings of the 38th ACM SIGPLAN Conference on Programming Language Design and Implementation. 2017: 422-436. DOI: 10.1145/3062341.3062351.
- [41] LI P, HE Y, YAN C, et al. Auto-Tables: Synthesizing Multi-Step Transformations to Relationalize Tables without Using Examples[J]. Proceedings of the VLDB Endowment, 2023, 16(11): 3391-3403. DOI: 10.14778/3611479.3611534.
- [42] FÜRST J, ARGERICH M F, CHENG B. VersaMatch: Ontology Matching with Weak Supervision[J]. Proceedings of the VLDB Endowment, 2023, 16(6): 1305-1318. DOI: 10.14778/3583140.3583148.
- [43] KRISHNAN S, WANG J, WU E, et al. ActiveClean: interactive data cleaning for statistical modeling[J]. Proceedings of the VLDB Endowment, 2016, 9(12): 948-959. DOI: 10.14778/2994509.2994514.
- [44] CHEN D, HUANG Y, MA Z, et al. Data-Juicer: A One-Stop Data Processing System for Large Language Models[C]//Companion of the 2024 International Conference on Management of Data. New York: ACM, 2024: 120-134. DOI: 10.1145/3626246.3653385.
- [45] YANG J, HE Y, CHAUDHURI S. Auto-Pipeline: Synthesizing Complex Data Pipelines By-Target Using Reinforcement Learning and Search[J]. Proceedings of the VLDB Endowment, 2021, 14(11): 2563-2575. DOI: 10.14778/3476249.3476303.
- [46] LI P, CHEN Z, CHU X, et al. DiffPrep: Differentiable Data Preprocessing Pipeline Search for Learning over Tabular Data[J]. Proceedings of the ACM on Management of Data, 2023, 1(2): 1-26. DOI: 10.1145/3589328.
- [47] PRIMPELI A, BIZER C. Profiling Entity Matching Benchmark Tasks[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. 2020: 3101-3108. DOI: 10.1145/3340531.3412781.
- [48] KOUTRAS C, SIACHAMIS G, IONESCU A, et al. Valentine: Evaluating Matching Techniques for Dataset Discovery[C]//2021 IEEE 37th International Conference on Data Engineering (ICDE). 2021: 468-479. DOI: 10.1109/icde51399.2021.00047.