

数据准备与语言模型的交叉前沿

范举 范梅浩

中国人民大学信息学院，数据工程与知识工程教育部重点实验室
北京 100872

1 引言

数据准备是将原始数据转化为适合特定用途的数据的过程，涉及发现、查询、融合、清洗、转换和标注等任务。企业分析需要统一跨部门的记录口径，科学研究需要整理不同实验的观测，模型训练需要筛选可靠且具有代表性的样本。这些应用共同面对来源分散、语义异构、质量不稳定和人工处理成本较高的问题。数据库领域长期积累的索引、完整性约束、查询优化和人机协作方法，为解决这些问题提供了基础。^[1-3]

语言模型使数据准备与模型学习形成了更紧密的联系。一方面，模型可以辅助解释数据含义、判断跨源对应关系和生成处理程序，这一方向称为基于语言模型的数据准备，即 LM4DP。另一方面，语言模型的训练和使用依赖经过选择、清洗、标注与组织的数据，这一方向称为面向语言模型的数据准备，即 DP4LM。前者以准备任务的质量和成本为主要目标，后者考察准备好的数据能否改善模型训练与推理。同一个系统可以兼具两种作用，但两类问题的评价对象并不相同。^[4, 5]

本文沿着这两条主线梳理研究进展。LM4DP 部分按数据发现、查询、融合、清洗分类，比较规则、学习模型与语言模型的作用。DP4LM 部分围绕预训练、微调和推理说明数据选择及组织方法。随后讨论具身智能带来的新要求，将研究对象从文本和表格扩展到与语言指令关联的视觉、状态与动作轨迹。文献范围包括截至 2026 年 9 月 10 日可核验的代表性论文和公开数据资源。本文侧重技术比较，不进行完整的文献计量分析，预印本与正式发表文献在书目中分别标识。

2 基于语言模型的数据准备

LM4DP 需要解决的核心问题，是如何将任务需求、数据内容和可执行操作联系起来。语言模型有助于处理难以直接写成规则的语义问题，数据系统负责检索、计算和约束检查。两者的结合方式随着任务变化，不能仅按模型大小判断方法优劣。图1呈现四类任务的既有文献统计。本文两幅统计图均沿用《数据准备与语言模型交叉技术的研究进展与发展趋势》报告原稿。原稿未完整提供检索式和逐项统计台账，图中数量只反映其历史样本，不用于推断 2026 年的研究分布或国内外研究水平。

2.1 数据发现与语义理解

数据发现从数据库、数据湖或其他资源集合中寻找与需求相关的数据。其输出可能是包含目标信息的表，也可能是可连接的字段或可合并的数据集。这些目标需要不同证据：可连接性关注键值重叠和对应关系，可合并性关注字段含义与结构兼容，任务相关性还需要判断数据是否覆盖所需对象和时间范围。

传统方法通过倒排索引、集合相似性和统计特征组织候选检索。Aurum 构建数据关系网络支持资源发现，Table Union Search 综合值域和语义信息寻找可合并表，SANTOS 进一步利用列间关系判断表的兼容性。^[6-8] 这些方法明确了检索对象与证据组织方式，也为后续语义模型提供了候选集合。索引结构和批量计算仍决定大规模数据湖中的处理效率。




图 1 基于语言模型的数据准备研究分布（原稿统计）

语言模型可以结合表头、样例值和描述生成表示，补充关键词与字符串匹配难以识别的联系。列语义识别是其中的重要环节，Sato 通过列值与表级上下文共同判断列类型，Unicorn 在列类型标注、模式匹配和实体匹配之间共享学习到的表示。^[9, 10] 从数据发现角度看，研究重点由寻找表面相似的资源，逐步扩展到解释候选数据的含义及其与需求的关系。

不过，语义相近只适合作为候选依据。“销售额”与“到账金额”可能高度相关，却受退款、结算周期和统计粒度影响。准备系统还需读取字段说明、样例分布和来源记录，并在使用前确认单位、时间和对象范围。面向新领域时，缺少说明文档和代表性样本，仍会限制语言模型的判断。评价时应同时报告相关数据的召回、错误候选比例以及后续核验成本。

2.2 数据查询与结构转换

发现数据之后，需要从中提取、聚合并组织目标记录。自然语言到 SQL 的转换通常称为 Text2SQL，其在数据准备中的作用是把用户需求转为查询步骤。规则和模板适合结构稳定、表达范围明确的需求，NaLIR 通过自然语言解析和用户交互生成查询，体现了需求澄清在这一问题中的作用。^[11] 预训练语言模型则利用已有语言知识学习需求与数据库结构之间的对应关系。

查询生成必须满足数据库语言的结构要求。PICARD 在生成过程中进行增量解析，拒绝不符合语法约束的候选，使预训练模型的输出受到可执行语言规则的限制。^[12] DIN-SQL 将复杂需求分解为模式关联、查询生成和修正等步骤，研究如何组织上下文示例与推理过程。^[13] 两者分别强调生成约束与任务分解，说明模型能力需要通过具体机制转化为有效查询。

实际数据准备还包括拆列、展开嵌套内容、调整表格形态等结构转换。Wrangler 根据用户交互形成转换脚本，Auto-Tables 研究在没有输入输出示例时组合多步操作，将非关系形态的表整理为关系表。^[14, 15] 这类任务的交付对象是可重复执行的处理过程及结果数据，不能只检查生成文本是否合理。

查询能够运行，也可能没有满足原始需求。例如，将订单表与退款明细直接连接后汇总，可能因一笔订单对应多条退款而重复计算销售额。准备系统需要检查连接前后的记录粒度、键的唯一性和金额口径，再决定是否应先聚合后连接。这类检查依赖数据结构和业务规则，语言表达流畅无法替代对中间结果的核验。自然语言查询研究与数据准备的交叉，也由单条语句生成延伸到多步数据转换的正确性。

2.3 数据融合与实体匹配

数据融合将不同来源的记录组织为一致的数据视图, 涉及字段对应、实体匹配和冲突处理。其中, 模式匹配判断字段是否表达相同概念, 实体匹配判断记录是否描述同一对象。已知对应关系后的连接与合并属于执行操作, 应与前面的语义推断区分。^[16]

规则方法依赖标识符、属性条件和领域知识, 学习方法从已标注的记录对中识别匹配特征。预训练语言模型进一步利用属性值的上下文。Ditto 将实体匹配转化为序列对分类, 并结合领域知识、内容压缩和数据增强处理匹配任务。^[17] Unicorn 通过多任务学习复用不同匹配任务之间的知识, 减少逐项设计模型的负担。^[10] 这些方法改变了语义表示的获取方式, 但仍需要明确“同一对象”的判定标准。

大语言模型允许用任务说明与少量示例表达匹配要求。成本高效的实体解析研究进一步讨论示例选择和问题组织, 减少逐条调用所产生的费用。^[18] 对于海量记录, 更合理的处理过程通常包括候选缩减、自动判定和疑难记录复核。索引或简单模型筛除明显不相关的记录, 语义模型处理剩余歧义, 人工确认具有业务影响的冲突。

匹配分数不能直接决定融合后的真实值。两个来源可能描述同一商品, 却记录不同时间的价格或不同版本的规格。系统需要结合更新时间、来源可靠性与字段规则确定保留值, 并记录冲突及其处理依据。评价也应覆盖候选召回、匹配准确性和融合结果的一致性, 避免局部匹配收益掩盖后续错误。

2.4 数据清洗与完整流程

数据清洗包括错误检测、值修复和缺失补全。完整性约束描述记录必须满足的条件, 统计方法识别异常分布, 人工修复则补充数据之外的知识。HoloClean 综合约束、统计关系和参考信息推断修复值, Raha 利用多种检测策略与少量用户标注定位错误, Baran 组织上下文信息生成和选择纠错候选。^[19-21] 这些方法分别作用于错误定位与修复决策, 效果受可获得证据和错误类型影响。

语言模型能够辅助解释异常、转换非规范值和生成候选修复。基础模型数据整理研究与 Jellyfish 探索了将多种准备任务表达为统一语言任务的可能性。^[22, 23] 这有助于复用语义知识, 但根据上下文猜出的值仍然是估计。对于无法确认的缺失内容, 应保留缺失状态或标明估计来源, 避免将推测写回为事实。检测准确率、修复准确率和下游效果需要分别评价。

当多个准备任务串联时, 研究对象从单个操作转向完整流程。HAIPipe 结合人工与自动生成的处理步骤, DiffPrep 利用下游训练信号搜索预处理配置。^[24, 25] AutoPrep 依据自然语言问题组织表格准备, DeepPrep 进一步研究基于执行反馈的流程调整。^[26, 27] 例如, AutoPrep 在 DeepSeek-V2.5-Chat 配置下, 将 WikiTQ 问答准确率由直接查询的 52.83% 提高到 66.09%, 这一结果衡量的是准备对问答的帮助, 不能等同于所有清洗操作的正确率。^[26] 这些系统的差异涉及输入需求、搜索空间和反馈依据, 不能仅归结为是否采用智能体。这里的智能体是能够调用工具、观察执行结果并继续采取操作的程序。

PrepBench 等评测将需求歧义、多步操作和执行结果纳入考察, 促使研究从单项预测走向真实准备任务。^[28] 完整流程需要保存输入版本、操作参数和中间状态, 发现错误后才能定位影响并重新执行。对 LM4DP 而言, 语义判断、确定性操作和人工确认各有适用条件, 其共同目标是以可承担的成本得到可复查的数据。

3 面向语言模型的数据准备

DP4LM 关注进入训练或推理过程的数据如何被选择、加工和组织。预训练数据影响模型接触的知识与分布, 微调数据表达目标任务及期望行为, 推理数据提供回答当前问题所需的证据。三个阶段共享发现、清洗、融合与标注方法, 但数据价值的判断标准不同。图2按这三个阶段呈现原稿统计, 后文围绕这一分类讨论数据准备方法。




图 2 面向语言模型的数据准备研究分布 (原稿统计)

3.1 预训练语料的清洗、选择与混合

预训练数据准备通常从网页、代码、论文和其他资源中提取内容, 再进行语言识别、格式规范化、重复检测、质量筛选与混合采样。这些操作决定哪些内容实际参与训练, 以及不同来源被模型看到的频率。Dolma 公开语料组成、处理中间状态和准备工具, 使研究者能够考察具体准备决策与模型表现之间的关系。^[29] 数据处理流程的可复用性由此成为开放模型研究的重要组成部分。

规则筛选计算成本较低, 适合排除乱码、导航文本和明显重复内容, 但阈值需要适应语言与数据类型。模型筛选可以利用文本特征判断候选价值, 却会引入训练样本和评分标准的偏好。DataComp-LM 在受控的模型与训练预算下比较语料准备方案, 为区分数据改进和训练配置变化提供了实验基础。^[30] 其意义在于让筛选策略接受下游训练检验, 而非把某个质量分数直接视为通用标准。

多语言数据准备进一步暴露了统一阈值的局限。不同语言的分词方式、字符分布和网络资源量并不相同, 面向英语设计的规则可能误删其他语言的有效文本。FineWeb2 研究可适配不同语言的处理流程, 并结合重复次数与质量重新平衡数据。^[31] 这将研究重点从提高总体保留率转向同时控制低质量内容、重复训练和语言覆盖。相关结果也提示, 质量筛选需要关注哪些群体、领域或表达方式被系统性排除。

语料混合决定不同来源和领域的采样比例。DoReMi 通过代理模型学习数据混合权重, 再用于目标模型训练, 将采样配置与训练反馈联系起来。^[32] 选择少量相关数据可以减少重复学习, 但过度集中于容易获得高分的领域也可能损失覆盖。因此, 应结合模型用途比较不同混合方案, 报告各领域收益与退化, 而不仅是平均指标。

去重还需要区分训练集内部重复和训练评测之间的污染。前者影响样本利用效率, 后者可能让模型在评测时遇到训练中出现过的问题或其变体。准备流程应记录数据来源与版本, 按内容及来源

关系检查重叠,并在划分之后限制跨集合的信息传递。对网页、代码仓库和同源改写内容,仅比较字符串是否完全相同往往不足。

3.2 微调数据选择与合成

微调数据通常包含任务指令、输入和期望输出,也可能包含多个候选回答及偏好标注。准备工作的重点是保证任务覆盖、回答正确性与目标行为之间的一致性。指令选择主要利用表征相似性、模型指标、梯度信息和大模型评分四类依据。相似性方法便于控制冗余与覆盖,模型指标提供低成本估计,梯度方法联系训练过程,语言模型评分则利用任务说明进行细粒度判断。

不同评分回答的是不同问题。困惑度反映文本在指定模型下的可预测程度,较低并不必然表示信息正确、任务重要或具有新增训练价值。语义多样性也只能说明内容差异,不能保证回答质量。LESS 构建低维梯度表示,根据候选数据与目标能力示例的梯度关系选择训练样本。^[33] LESS 的论文报告,在所评测的多种任务上,选择 5% 的数据进行训练常能超过使用全部数据的结果。^[33] 这一选择依赖目标示例和代理模型,应用到新任务时仍需验证这些条件是否合适。数据价值因而应与具体学习目标联系,而不是被压缩成跨任务通用的单一分数。

合成数据缓解了人工编写指令和回答的负担。Self-Instruct 从少量种子任务出发生成指令、输入与输出,并过滤无效或高度相似的样本。^[34] 这一过程同时包含生成、去重和质量控制,不能用生成数量代替有效数据规模。种子任务的覆盖、生成模型的能力与过滤标准,共同决定合成数据的边界。

近期推理数据研究把准备对象扩展到解题过程。OpenThoughts 系统研究问题来源、选择和回答生成等环节,公开推理数据及相关实验,使数据配方能够被独立分析。^[35] 对数学、代码等可核验任务,可以结合答案检查或程序测试筛查错误。但最终答案正确并不能证明所有中间步骤可靠,过程标注还需要区分有效推理、冗余叙述和错误尝试。对于工具使用任务,数据还应记录环境输入、调用参数与执行结果,避免只保留一段无法重放的成功描述。

持续使用模型生成的数据也带来分布变化问题。递归合成数据研究在特定实验条件下观察到模型逐步丢失原始分布信息的现象。^[36] 这并不意味着所有合成数据都会导致退化,而是提示准备过程需要跟踪数据来源、生成轮次和真实数据比例。评测应分别考察正确性、覆盖和长尾任务表现,再确定合成数据的使用范围。

3.3 推理阶段的证据与示例组织

推理阶段的数据准备通常不改变模型参数,而是为当前问题构造可用上下文。检索增强生成从外部资源中查找相关文档,并将检索结果用于回答生成。^[37] 其效果取决于资源是否及时、内容能否被正确提取,以及证据是否完整地进入模型输入。除参考文档外,准备对象还包括任务示例与待处理的问题实例。

参考文档准备需要处理内容抽取、分块、索引、去重和来源保留。分块过小可能切断定义与适用条件,分块过大又会引入无关内容。表格转为文本时尤其需要保留标题、列名、单位和注释,否则数值虽然被检索到,其解释可能已经丢失。对于政策条款、产品说明和业务记录,还需关联生效时间及版本,防止把历史内容用于当前问题。检索相关性、证据支持程度和最终回答正确性应分别检验。

示例数据用于向模型表达任务边界和输出方式。相关研究比较了不同示例选择方法,说明上下文学习效果受到示例与当前问题关系的影响。^[38] 在数据准备任务中,正反例、边界情况和输出约束

往往比单纯增加示例数量更有针对性。示例选择也应避免利用测试答案, 以免将评价信息提前带入处理过程。

问题实例组织则关注如何复用上下文并减少调用成本。批量提示将多个问题置于一次调用中, 可以共享任务说明和示例, 但需要保持问题编号与答案的对应, 控制不同实例之间的干扰。^[18] 结合候选筛选、缓存和批量执行, 可以将语言判断放在更少的疑难实例上。成本评价应包括检索、准备、调用和复核, 不能仅比较单次模型推理的价格。

3.4 可复用的数据准备系统

训练数据规模和模态增加后, 准备过程也成为系统问题。Data-Juicer 将分析、过滤、去重等操作组织为可组合的处理流程, Data-Juicer 2.0 进一步扩展到图像、视频和音频, 并支持更大规模的自适应执行。^[39, 40] 系统研究关注算子复用、执行效率和中间结果管理, 使数据方案能够在实际资源条件下落地。

同一数据准备系统可以使用语言模型辅助标注, 也可以输出用于训练语言模型的数据。这是 LM4DP 与 DP4LM 在工程上的直接交汇。两者仍需分别验收: 标注是否正确属于准备质量, 使用这些标注训练后是否改善任务表现属于下游效用。保存输入快照、算子配置、过滤原因和数据版本, 是比较不同方案及分析退化原因的共同前提。

4 具身智能中的数据准备

具身智能使模型通过具有物理形态的系统感知环境并执行动作, 例如机器人根据语言指令完成抓取与整理。其数据不再是独立文本或静态表格, 而是一次任务中连续记录的图像、机器人状态、动作、时间戳和结果。这组连续记录称为轨迹。视觉语言动作模型将视觉观测和语言指令用于动作预测, 使语言与物理交互数据的对应关系成为训练基础。数据准备在这里既要处理语义, 也要保持时序和物理意义。

4.1 跨来源采集与时空对齐

Open X-Embodiment 汇集不同机构和机器人平台的数据, 为跨机器人学习提供共享资源。^[41] 不同平台的关节数量、传感器配置和控制接口并不一致, 统一存储格式只是第一步。准备过程中还需要说明动作表示、坐标系、单位、采样频率以及观测与动作之间的时间关系。同样长度的动作向量, 可能分别表示关节位置、末端位移或速度, 不能直接作为等价样本合并。

DROID 通过分布式采集扩大真实场景和任务覆盖, 其项目在后续更新中补充了部分轨迹的相机标定。^[42] 这说明数据发布之后, 几何元数据仍需要维护。如果相机参数、采样时间或坐标变换不准确, 图像、动作和状态虽然能够同时读取, 却可能描述不同的位置或时刻。数据清洗应检测缺帧、时间异常和标定问题, 同时保留原始记录及修正依据。

从数据库角度看, 跨机器人数据准备延续了模式匹配和多源融合问题, 但加入了身体结构及控制条件。数据目录需要支持按任务、对象、场景和机器人配置检索, 融合流程需要追踪转换前后的物理含义。候选数据的选择不仅取决于任务名称相似, 还取决于目标机器人能否执行对应动作, 以及观测条件是否可比。

4.2 分层标注与失败轨迹利用

单条“整理货架”指令可能对应抓取、移动、放置和调整等连续动作。为支持不同层次的学习, 需要将完整轨迹划分为任务与动作片段, 并关联对象、时间边界和执行结果。AgiBot World Colosseo

扩展了真实操作数据的任务与场景覆盖。^[43] 2026 年发布的 AgiBot World 数据资源进一步提供子任务、物体框与步骤级指令等分层标注, 并保留错误恢复相关信息。^[44, 45] 这类数据结构使研究者能够区分最终完成任务与中途发生错误的不同情况。

语言模型可以辅助生成动作描述, 多模态模型可以提出片段边界和候选标签。但描述“抓取成功”需要由物体状态、传感器记录或人工复核支持。语言上合理的动作说明不等于事件已经发生。准备系统应保留自动标注的来源和置信信息, 并优先复核指令与动作不一致、结果不明确的片段。

失败轨迹的价值也依赖学习目标。传感器损坏和不可恢复的记录缺失属于质量问题, 抓取失误、人工接管和重新尝试则可能提供行为改进线索。面向成功动作模仿、错误识别或恢复策略学习, 需要分别决定这些片段的纳入方式。因此, 具身数据清洗不能简单地把“不成功”视为“无效”, 还需记录失败原因、干预位置和后续结果。

4.3 多模态扩展、仿真与质量评测

2026 年更新的 RoboMIND 2.0 在双臂操作基础上纳入触觉、移动操作和配套仿真数据。^[46] 触觉数据补充接触过程的信息, 移动轨迹扩大操作的空间范围, 也使标注和同步要求更加复杂。这一变化说明, 具身数据准备正在从扩充演示数量转向组织能够描述交互过程的多模态记录。

仿真可以补充难以大量采集的物体布局、场景变化和操作条件。MimicGen 根据少量人工演示, 通过片段适配与重放生成更多操作数据。^[47] 合成轨迹的价值取决于其与目标环境之间的关系。准备过程需要记录仿真参数、生成方式和任务结果, 并区分真实采集与仿真生成的数据。图像逼真或轨迹平滑, 都不足以证明其具有真实环境中的训练价值。

具身数据准备的评价应连接记录质量、数据覆盖与实际任务表现。记录质量包括时间对齐、标注一致性和轨迹完整性, 覆盖涉及机器人、场景、对象与任务组合, 下游表现则需要通过任务成功和失败恢复能力检验。比较准备策略时, 应控制模型、训练预算和可用演示量, 并将相近场景或同源轨迹放在同一划分中, 减少训练与测试之间的泄漏。遥操作采集、传感器维护、存储与复核也应计入成本。在这些条件下, 才能判断新增数据、重新标注或选择子集分别带来了什么收益。

5 发展趋势与研究问题

5.1 从通用质量分数到任务相关的数据价值

数据质量具有使用情境, 同一份数据对不同任务可能有不同价值。^[3, 48] 企业分析关注统计口径, 预训练关注知识与语言覆盖, 具身学习还关注动作可执行性和交互条件。现有的数据选择与跨领域准备研究提示, 未来需要把字段级检查、数据集分布和下游效用联系起来, 解释具体处理决策改变了什么。

这一方向需要能够区分收益来源的实验。可以在固定训练预算下比较增加数据、去重、修复标注和调整采样的效果, 同时报告平均表现与低频任务表现。使用小模型或抽样数据估计准备价值具有成本优势, 但其排序能否迁移到目标模型和真实任务, 仍需独立验证。对于具身数据, 还应区分同一任务中的重复演示与新场景、新对象带来的覆盖增量。

5.2 从单项自动化到可验证的流程协作

LM4DP 和 DP4LM 都涉及多个相互依赖的准备步骤。语义判断会影响后续连接, 过滤会改变数据分布, 自动标注又可能成为下一轮训练的监督。如果只评价最终输出, 就难以定位错误出现在

哪一环。近期完整流程系统与准备基准的发展,使保存状态、解释修改及使用执行反馈成为更具体的研究问题。^[26-28]

值得研究的方向是根据不确定性和修改影响分配工作。规则可以处理确定的格式与约束,模型可以提出语义候选,人工集中确认目标不清或影响较大的决策。对模型建议的修改,应使用数据约束、参考来源或独立样本检查。核验过程与生成过程如果依赖完全相同的假设,可能同时忽略同一种错误。流程评测因而需要报告错误发现率、有效修订比例、人工投入与总成本,而不仅是程序完成率。

5.3 从静态数据集到持续维护的数据资源

网页内容、业务模式与机器人环境都会变化,一次性整理好的数据难以长期保持适用。FAIR原则强调数据的可发现、可访问、可互操作和可复用,Datasheets for Datasets 则通过文档记录数据的来源、组成及使用条件。^[49, 50] 将这些要求落实到准备流程,需要保存数据版本、处理步骤与删除或修复的影响范围。更新不仅包括追加记录,也包括纠正元数据、重新标注和淘汰不再适用的内容。

具身数据尤其需要把硬件、标定和控制配置纳入版本管理。更换相机、夹具或控制频率后,新旧数据可能不再具有相同含义。未来可结合增量处理与持续评测,研究何时应重算表示、重新筛选样本或重新执行训练。这要求数据准备系统与训练、评测系统共享必要的来源关系,同时控制维护费用。

6 结束语

数据准备与语言模型的交叉研究包含相互支撑的两个方向。LM4DP 利用语义模型辅助发现、查询、融合和清洗,DP4LM 通过数据选择、标注与组织改善模型训练和推理。具身智能将这一关系扩展到视觉、语言、状态与动作的连续交互,提出了跨机器人融合、时空对齐、失败标注和真实环境评测等要求。贯穿这些方向的核心问题,是如何把来源复杂、质量不一的数据转化为适合具体任务、能够复查且成本可承担的数据资源。


参考文献

- [1] CHAI C, TANG N, FAN J, et al. Demystifying Artificial Intelligence for Data Preparation[C]//Companion of the 2023 International Conference on Management of Data. New York: ACM, 2023: 13-20. DOI: 10.1145/3555041.3589406.
- [2] CHAI C, WANG J, LUO Y, et al. Data Management for Machine Learning: A Survey[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35(5): 4646-4667. DOI: 10.1109/tkde.2022.3148237.
- [3] BATINI C, CAPPIELLO C, FRANICALANCI C, et al. Methodologies for Data Quality Assessment and Improvement[J]. ACM Computing Surveys, 2009, 41(3): 16:1-16:52. DOI: 10.1145/1541880.1541883.
- [4] CHEN M, SUN Y, LI T, et al. Empowering Tabular Data Preparation with Language Models: Why and How?[C]//Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2026: 228-246. DOI: 10.18653/v1/2026.acl-long.8.
- [5] LIANG H, WONG Z H, LIU R T, et al. Data Preparation for Large Language Models[J]. Journal of Computer Science and Technology, 2026, 41(1): 289-317. DOI: 10.1007/s11390-026-5948-8.
- [6] CASTRO FERNANDEZ R, ABEDJAN Z, KOKO F, et al. Aurum: A Data Discovery System[C]//2018 IEEE 34th International Conference on Data Engineering (ICDE). IEEE, 2018: 1001-1012. DOI: 10.1109/icde.2018.00094.
- [7] NARGESIAN F, ZHU E, PU K Q, et al. Table union search on open data[J]. Proceedings of the VLDB Endowment, 2018, 11(7): 813-825. DOI: 10.14778/3192965.3192973.
- [8] KHATIWADA A, FAN G, SHRAGA R, et al. SANTOS: Relationship-based Semantic Table Union Search[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 1-25. DOI: 10.1145/3588689.
- [9] ZHANG D, HULSEBOS M, SUHARA Y, et al. Sato: contextual semantic type detection in tables[J]. Proceedings of the VLDB Endowment, 2020, 13(12): 1835-1848. DOI: 10.14778/3407790.3407793.
- [10] TU J, FAN J, TANG N, et al. Unicorn: A Unified Multi-tasking Model for Supporting Matching Tasks in Data Integration[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 84:1-84:26. DOI: 10.1145/3588938.
- [11] LI F, JAGADISH H V. Constructing an interactive natural language interface for relational databases[J]. Proceedings of the VLDB Endowment, 2014, 8(1): 73-84. DOI: 10.14778/2735461.2735468.
- [12] SCHOLAK T, SCHUCHER N, BAHDANAU D. PICARD: Parsing Incrementally for Constrained Auto-Regressive Decoding from Language Models[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2021: 9895-9901. DOI: 10.18653/v1/2021.emnlp-main.779.
- [13] POURREZA M, RAFIEI D. DIN-SQL: Decomposed In-Context Learning of Text-to-SQL with Self-Correction[C]//Advances in Neural Information Processing Systems:vol. 36. 2023: 36339-36348. DOI: 10.52202/075280-1577.
- [14] KANDEL S, PAEPCKE A, HELLERSTEIN J M, et al. Wrangler: Interactive Visual Specification of Data Transformation Scripts[C]//Proceedings of the SIGCHI Conference on Human Factors in Computing Systems. New York: ACM, 2011: 3363-3372. DOI: 10.1145/1978942.1979444.
- [15] LI P, HE Y, YAN C, et al. Auto-Tables: Synthesizing Multi-Step Transformations to Relationalize Tables without Using Examples[J]. Proceedings of the VLDB Endowment, 2023, 16(11): 3391-3403. DOI: 10.14778/3611479.3611534.
- [16] 高云君, 葛丛丛, 郭翔翔, 等. 面向关系型数据与知识图谱的数据集成技术综述[J]. 软件学报, 2023, 34(5): 2365-2391. DOI: 10.13328/j.cnki.jos.006808.
- [17] LI Y, LI J, SUHARA Y, et al. Deep entity matching with pre-trained language models[J]. Proceedings of the VLDB Endowment, 2020, 14(1): 50-60. DOI: 10.14778/3421424.3421431.
- [18] FAN M, HAN X, FAN J, et al. Cost-Effective In-Context Learning for Entity Resolution: A Design Space Exploration[C]//2024 IEEE 40th International Conference on Data Engineering (ICDE). IEEE, 2024: 3696-3709. DOI: 10.1109/icde60146.2024.00284.

- [19] REKATSINAS T, CHU X, ILYAS I F, et al. HoloClean: Holistic Data Repairs with Probabilistic Inference[J]. Proceedings of the VLDB Endowment, 2017, 10(11): 1190-1201. DOI: 10.14778/3137628.3137631.
- [20] MAHDAVI M, ABEDJAN Z, CASTRO FERNANDEZ R, et al. Raha: A Configuration-Free Error Detection System[C]//Proceedings of the 2019 International Conference on Management of Data. ACM, 2019: 865-882. DOI: 10.1145/3299869.3324956.
- [21] MAHDAVI M, ABEDJAN Z. Baran: Effective Error Correction via a Unified Context Representation and Transfer Learning[J]. Proceedings of the VLDB Endowment, 2020, 13(12): 1948-1961. DOI: 10.14778/3407790.3407801.
- [22] NARAYAN A, CHAMI I, ORR L, et al. Can Foundation Models Wrangle Your Data?[J]. Proceedings of the VLDB Endowment, 2022, 16(4): 738-746. DOI: 10.14778/3574245.3574258.
- [23] ZHANG H, DONG Y, XIAO C, et al. Jellyfish: Instruction-Tuning Local Large Language Models for Data Preprocessing[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: Association for Computational Linguistics, 2024: 8754-8782. DOI: 10.18653/v1/2024.emnlp-main.497.
- [24] CHEN S, TANG N, FAN J, et al. HAIPipe: Combining Human-generated and Machine-generated Pipelines for Data Preparation[J]. Proceedings of the ACM on Management of Data, 2023, 1(1): 91:1-91:26. DOI: 10.1145/3588945.
- [25] LI P, CHEN Z, CHU X, et al. DiffPrep: Differentiable Data Preprocessing Pipeline Search for Learning over Tabular Data[J]. Proceedings of the ACM on Management of Data, 2023, 1(2): 1-26. DOI: 10.1145/3589328.
- [26] FAN M, FAN J, TANG N, et al. AutoPrep: Natural Language Question-Aware Data Preparation with a Multi-Agent Framework[J]. Proceedings of the VLDB Endowment, 2025, 18(10): 3504-3517. DOI: 10.14778/3748191.3748211.
- [27] FAN M, FAN J, ZHANG Y, et al. DeepPrep: An LLM-Powered Agentic System for Autonomous Data Preparation[J]. Proceedings of the VLDB Endowment, 2026, 19(11): 3371-3384. DOI: 10.14778/3836663.3836695.
- [28] XU J, WANG R, WANG J, et al. PrepBench: How Far are We from Natural-Language-Driven Data Preparation?[J]. Proceedings of the VLDB Endowment, 2026, 19(10): 2866-2879. DOI: 10.14778/3828612.3828638.
- [29] SOLDAINI L, KINNEY R, BHAGIA A, et al. Dolma: an Open Corpus of Three Trillion Tokens for Language Model Pretraining Research[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2024: 15725-15788. DOI: 10.18653/v1/2024.acl-long.840.
- [30] LI J, FANG A, SMYRNIS G, et al. DataComp-LM: In search of the next generation of training sets for language models[C]//Advances in Neural Information Processing Systems:vol. 37. 2024: 14200-14282. DOI: 10.52202/079017-0455.
- [31] PENEDO G, KYDLÍČEK H, SABOLČEC V, et al. FineWeb2: One Pipeline to Scale Them All – Adapting Pre-Training Data Processing to Every Language[EB/OL]. (2025-06-26) [2026-09-10]. <https://arxiv.org/abs/2506.20920v1> 预印本, arXiv:2506.20920, 核读版本更新于 2025-06-26.
- [32] XIE S M, PHAM H, DONG X, et al. DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining[C]//Advances in Neural Information Processing Systems 36. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2023: 69798-69818. DOI: 10.52202/075280-3059.
- [33] XIA M, MALLADI S, GURURANGAN S, et al. LESS: Selecting Influential Data for Targeted Instruction Tuning[C/OL]//Proceedings of the 41st International Conference on Machine Learning:vol. 235. PMLR, 2024: 54104-54132. <https://proceedings.mlr.press/v235/xia24c.html>.
- [34] WANG Y, KORDI Y, MISHRA S, et al. Self-Instruct: Aligning Language Models with Self-Generated Instructions[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics, 2023: 13484-13508. DOI: 10.18653/v1/2023.acl-long.754.

- [35] GUHA E, MARTEN R, KEH S, et al. OpenThoughts: Data Recipes for Reasoning Models[EB/OL]. (2025-06-04) [2026-09-10]. <https://arxiv.org/abs/2506.04178v2> 预印本, arXiv:2506.04178, 核读版本更新于 2025-06-05.
- [36] SHUMAILOV I, SHUMAYLOV Z, ZHAO Y, et al. AI models collapse when trained on recursively generated data[J]. Nature, 2024, 631(8022): 755-759. DOI: 10.1038/s41586-024-07566-y.
- [37] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C/OL]//Advances in Neural Information Processing Systems:vol. 33. 2020: 9459-9474. https://proceedings.neurips.cc/paper_files/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf.
- [38] LIU J, SHEN D, ZHANG Y, et al. What Makes Good In-Context Examples for GPT-3?[C]//Proceedings of Deep Learning Inside Out (DeeLIO 2022): The 3rd Workshop on Knowledge Extraction and Integration for Deep Learning Architectures. Association for Computational Linguistics, 2022: 100-114. DOI: 10.18653/v1/2022.deelio-1.10.
- [39] CHEN D, HUANG Y, MA Z, et al. Data-Juicer: A One-Stop Data Processing System for Large Language Models[C]//Companion of the 2024 International Conference on Management of Data. New York: ACM, 2024: 120-134. DOI: 10.1145/3626246.3653385.
- [40] CHEN D, HUANG Y, PAN X, et al. Data-Juicer 2.0: Cloud-Scale Adaptive Data Processing for and with Foundation Models[C]//Advances in Neural Information Processing Systems:vol. 38. 2025. DOI: 10.52202/085713-2768.
- [41] Open X-Embodiment Collaboration. Open X-Embodiment: Robotic Learning Datasets and RT-X Models[EB/OL]. (2023-10-13) [2026-09-10]. <https://arxiv.org/abs/2310.08864v9> 预印本, arXiv:2310.08864, 核读版本更新于 2025-05-14.
- [42] KHAZATSKY A, PERTSCH K, NAIR S, et al. DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset[EB/OL]. (2024-03-19) [2026-09-10]. <https://arxiv.org/abs/2403.12945v2> 预印本, arXiv:2403.12945, 核读版本更新于 2025-04-22.
- [43] AgiBot-World-Contributors. AgiBot World Colosseo: A Large-scale Manipulation Platform for Scalable and Intelligent Embodied Systems[EB/OL]. (2025-03-09) [2026-09-10]. <https://arxiv.org/abs/2503.06669v4> 预印本, arXiv:2503.06669, 核读版本更新于 2025-08-04.
- [44] AGIBOT. AgiBot World 2026: Dataset Card[EB/OL]. 2026 [2026-09-10]. <https://huggingface.co/datasets/agibot-world/AgiBotWorld2026>.
- [45] AGIBOT. AGIBOT Open-Sources AGIBOT WORLD 2026 Dataset to Accelerate Embodied AI Development[EB/OL]. 2026 [2026-09-10]. <https://www.agibot.com/article/231/detail/54.html>.
- [46] HOU C, WU K, LIU J, et al. RoboMIND 2.0: A Multimodal, Bimanual Mobile Manipulation Dataset for Generalizable Embodied Intelligence[EB/OL]. (2025-12-31) [2026-09-10]. <https://arxiv.org/abs/2512.24653v3> 预印本, arXiv:2512.24653, 核读版本更新于 2026-02-27.
- [47] MANDLEKAR A, NASIRIANY S, WEN B, et al. MimicGen: A Data Generation System for Scalable Robot Learning using Human Demonstrations[C/OL]//Proceedings of The 7th Conference on Robot Learning:vol. 229. PMLR, 2023: 1820-1864. <https://proceedings.mlr.press/v229/mandlekar23a.html>.
- [48] 刘祺, 黄君义, 冯耕中, 等. 数字经济发展根基: 数据质量研究述评与未来展望[J]. 系统工程理论与实践, 2025, 45(7): 2101-2123. DOI: 10.12011/SETP2023-2891.
- [49] WILKINSON M D, DUMONTIER M, AALBERSBERG I J, et al. The FAIR Guiding Principles for Scientific Data Management and Stewardship[J]. Scientific Data, 2016, 3: 160018. DOI: 10.1038/sdata.2016.18.
- [50] GEBRU T, MORGENSTERN J, VECCHIONE B, et al. Datasheets for Datasets[J]. Communications of the ACM, 2021, 64(12): 86-92. DOI: 10.1145/3458723.

作者简介



范举

范举，中国人民大学信息学院教授、博士生导师，数据工程与知识工程教育部重点实验室成员。研究方向为数据治理技术与系统、智能数据库系统及数据与人工智能的交叉问题。围绕数据发现、清洗、融合和智能数据准备开展研究，关注人机协作与数据科学智能体。主持国家自然科学基金及产学研合作项目，讲授数据科学导论、数据思维等课程。



范梅浩

范梅浩，中国人民大学信息学院计算机科学与技术专业博士生，师从范举教授。主要研究基于大语言模型的自动化数据准备，关注表格理解、任务需求表达、多步骤流程生成与执行反馈。参与 AutoPrep、DeepPrep 等系统及低成本实体解析研究，相关成果发表于 VLDB、ICDE 等数据管理领域国际会议。研究目标是减少复杂表格处理中的重复劳动，提高准备流程的可靠性与可复查性。

照片由作者提供。